Pontificia Universidad Católica de Chile
IA Lab

Grafos de Cómputo para Algoritmos de Aprendizaje

Gabriel Sepúlveda V.

IALab, Computer Science Department, PUC

Pasos de Entrenamiento: *Forward*, *Backward* y *Weights Update*

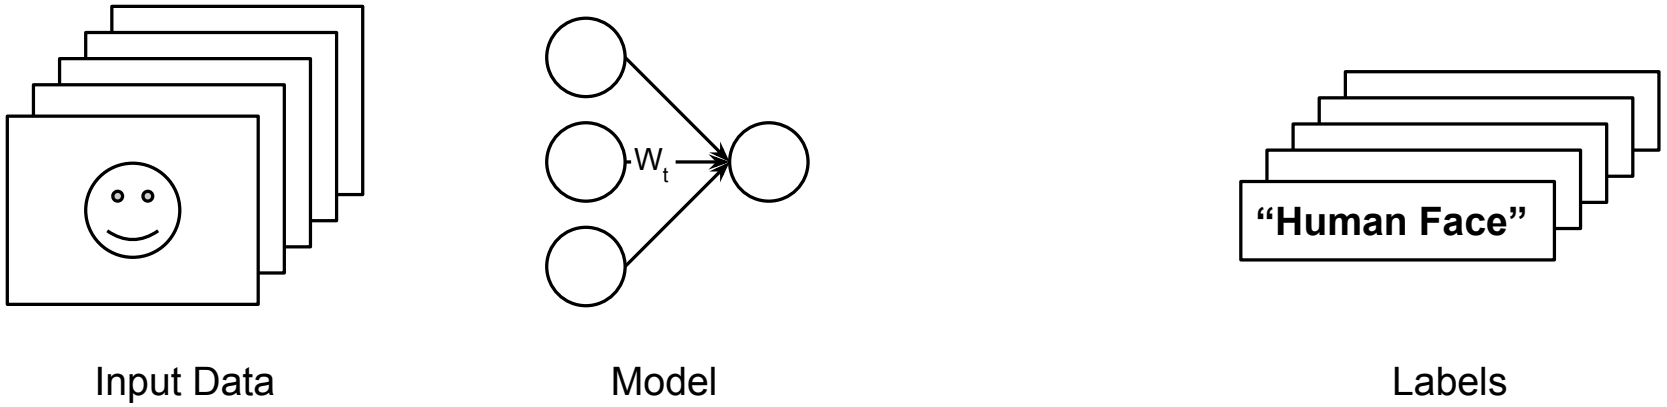

Pasos de Entrenamiento: *Forward*, *Backward* y *Weights Update*

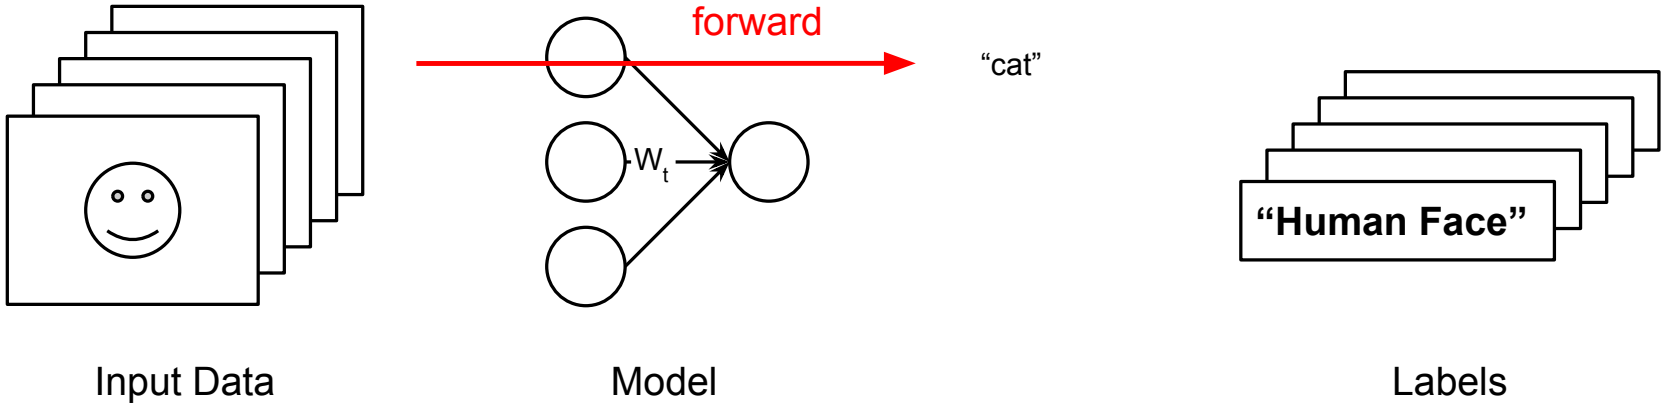

Pasos de Entrenamiento: *Forward*, *Backward* y *Weights Update*

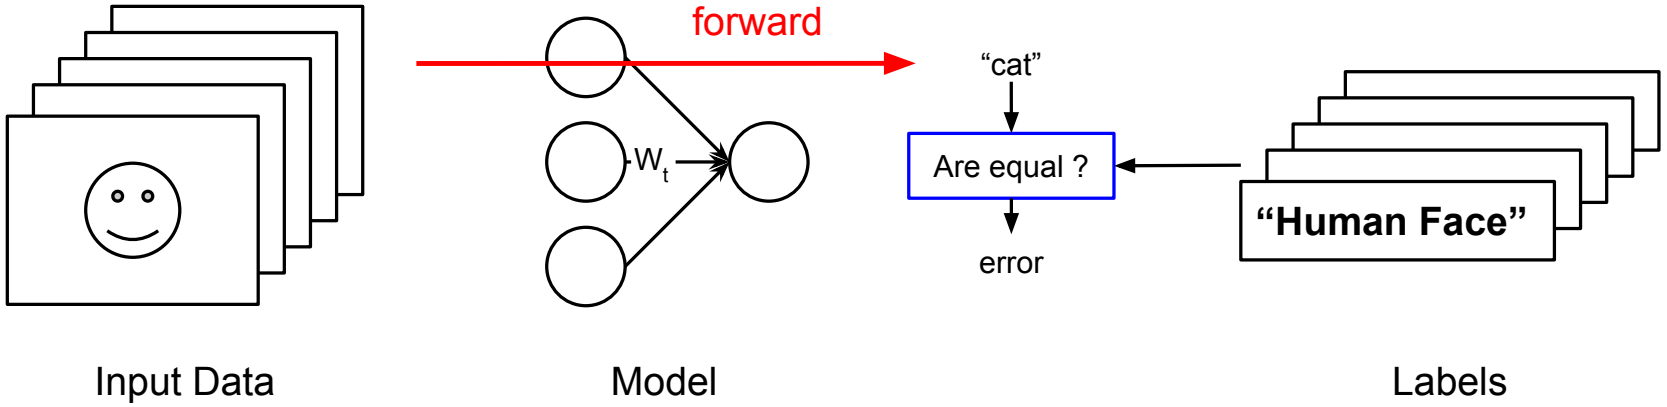

Pasos de Entrenamiento: *Forward*, *Backward* y *Weights Update*

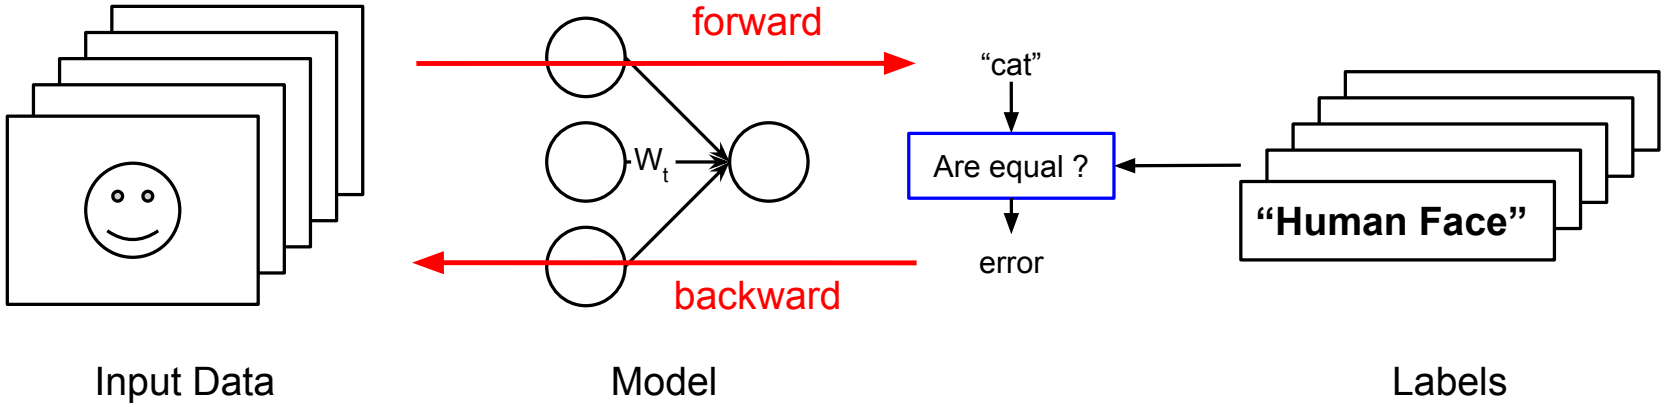

Pasos de Entrenamiento: *Forward*, *Backward* y *Weights Update*

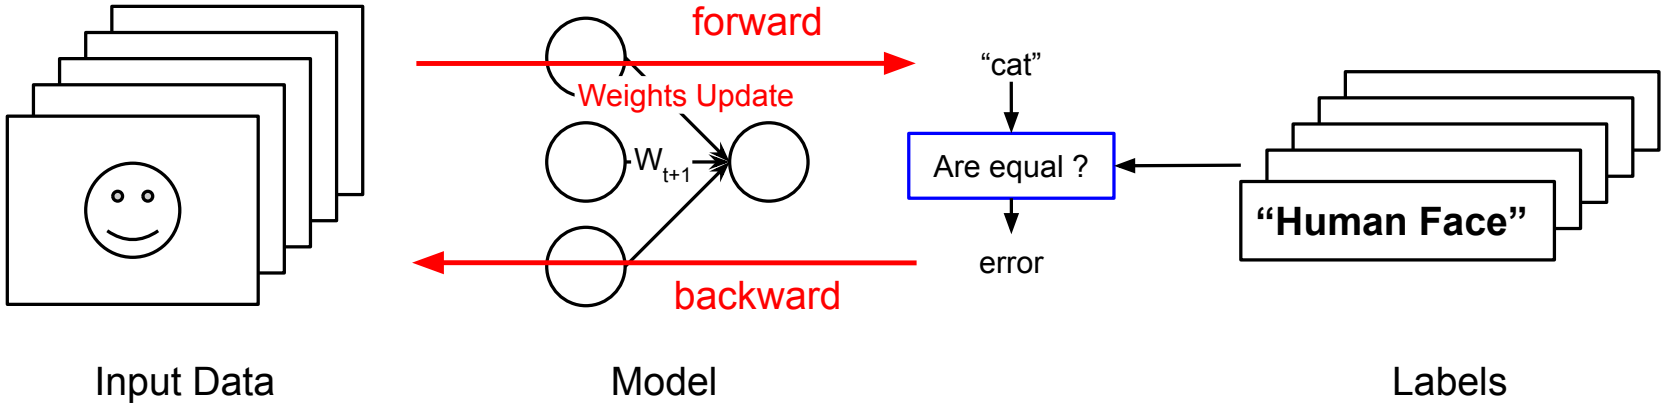

Pasos de Entrenamiento: *Forward*, *Backward* y *Weights Update*

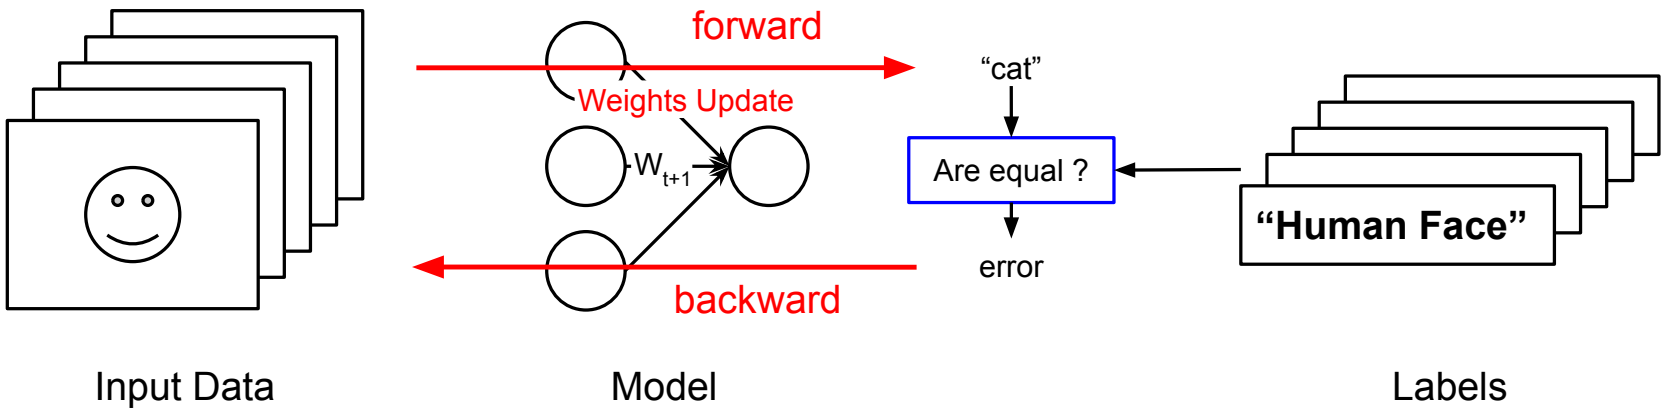

Los pesos se actualizan según el error cometido!

Pasos de Entrenamiento: *Forward*, *Backward* y *Weights Update*

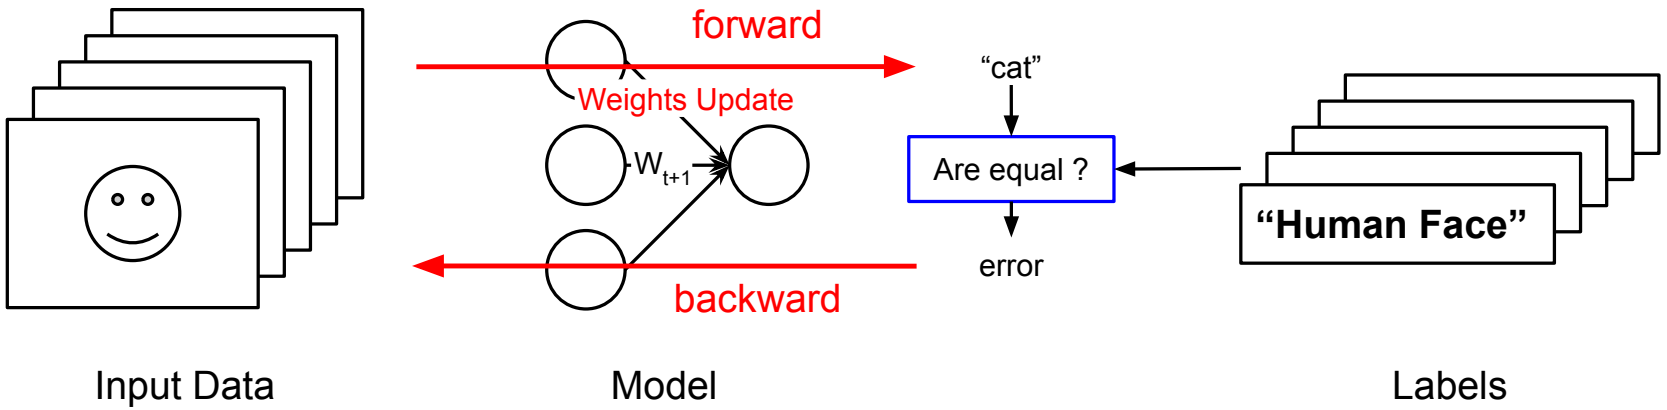

Los pesos se actualizan según el error cometido!

Entonces, necesitamos cuantificar el error y ...

Algoritmo de Aprendizaje

Learning Steps: Forward, Backward and Weights Update

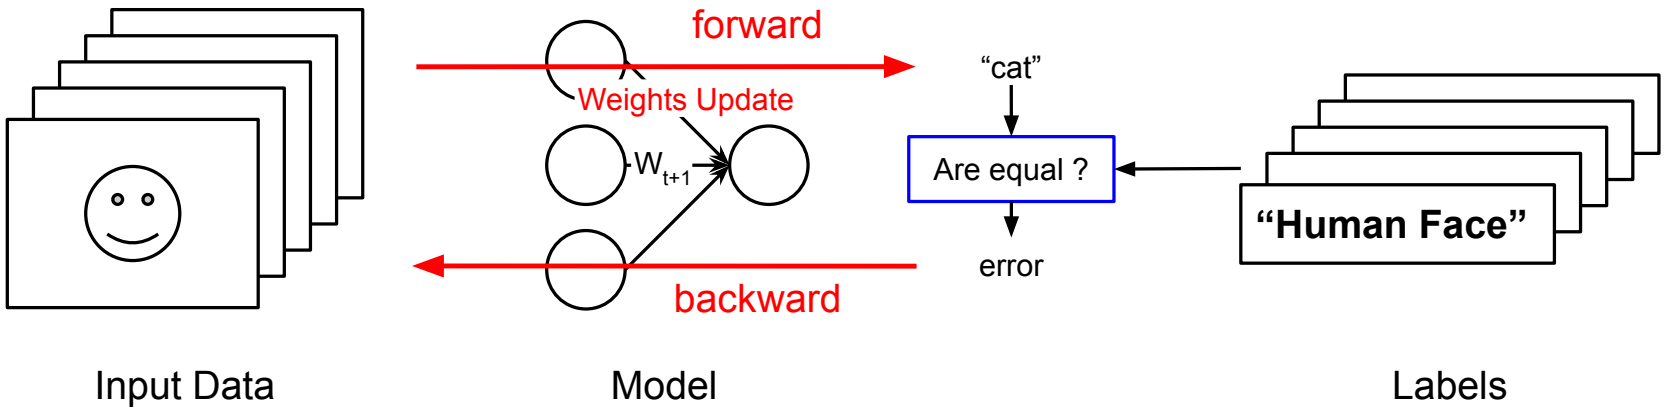

Los pesos se actualizan según el error cometido!

Entonces, necesitamos cuantificar el error y **su gradiente**

Descenso del Gradiente para Actualización de Pesos

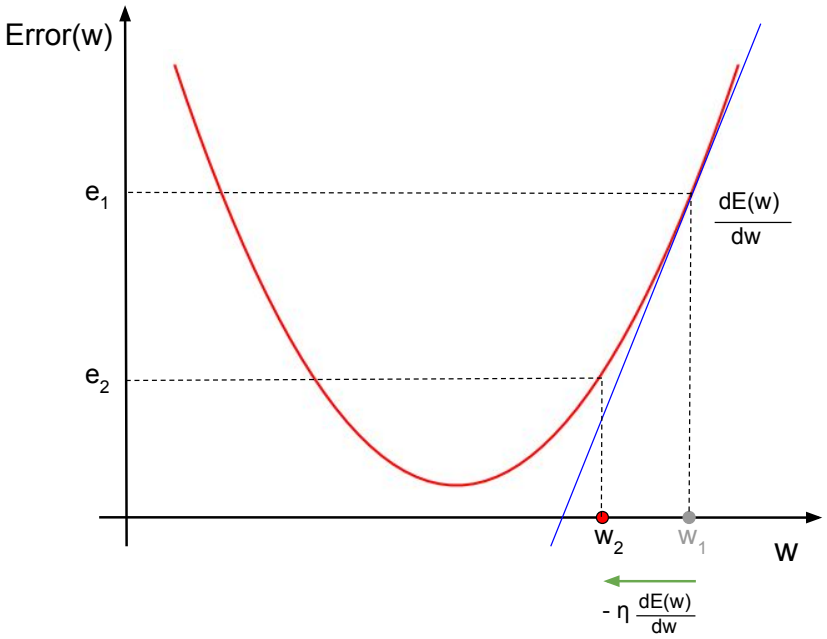

Regla Delta

$$\Delta w = -\eta \cdot \frac{\partial E(w)}{\partial w}$$

$$w \leftarrow w + \Delta w$$

Donde η se denomina *learning rate* (o tasa de aprendizaje)

Descenso del Gradiente para Actualización de Pesos

Regla Delta

$$\Delta w = -\eta \cdot \frac{\partial E(w)}{\partial w}$$

$$w \leftarrow w + \Delta w$$

Donde η se denomina *learning rate* (o tasa de aprendizaje)

Para entrenar un modelo, necesitamos encontrar el gradiente del error en función de sus pesos

Entrenaminto de un Perceptrón

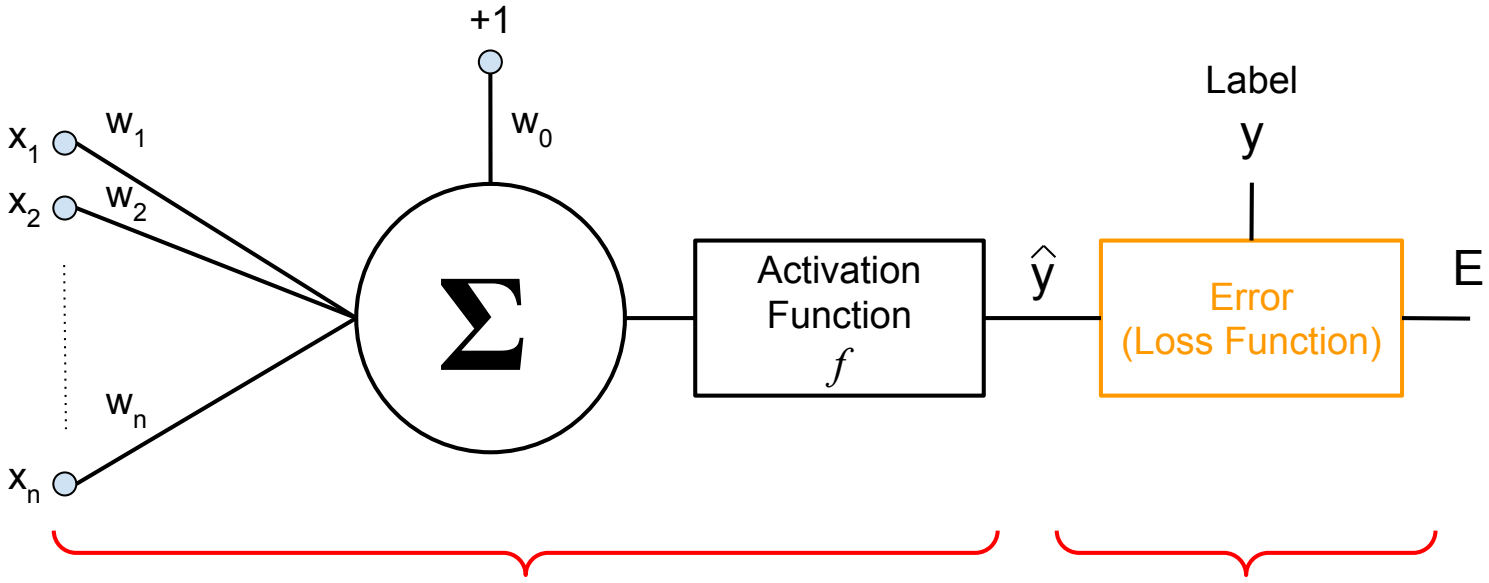

$$\hat{y} = f\left(\sum_{i=1}^{n} w_i \cdot x_i + w_0\right) \qquad E(\vec{w}) = \frac{1}{2} \cdot (y - \hat{y})^2$$

Entrenaminto de un Perceptrón

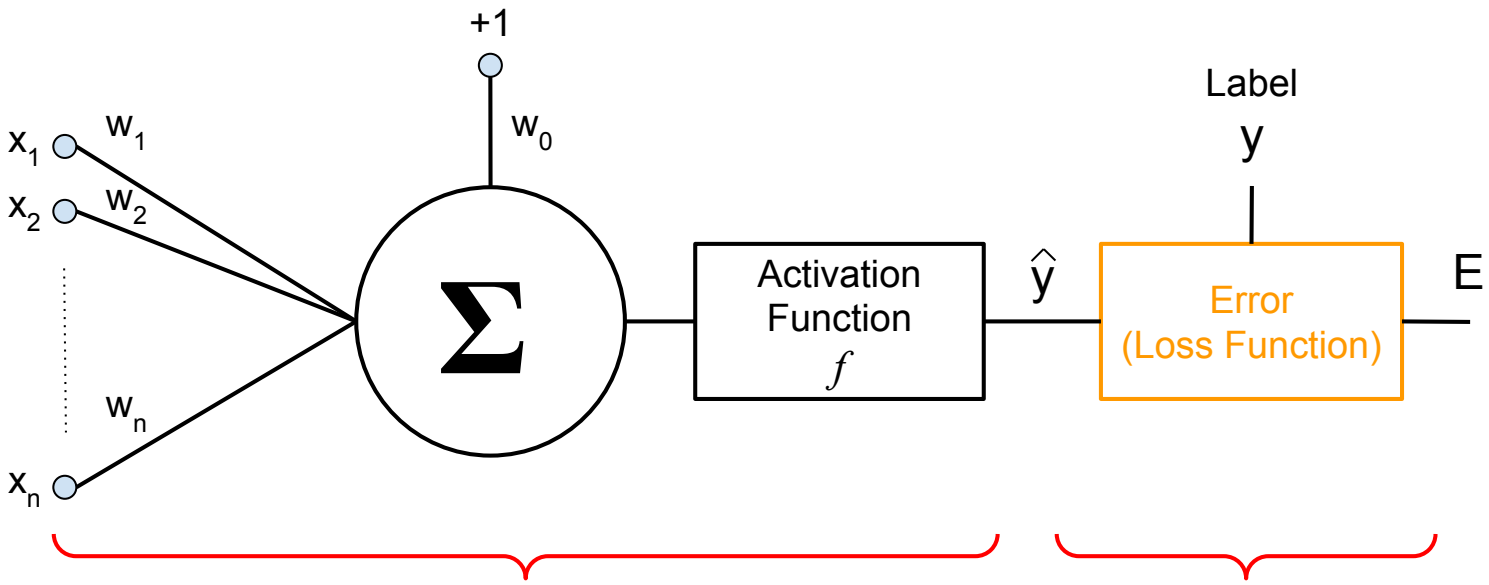

$$\hat{y} = f\left(\sum_{i=1}^{n} w_i \cdot x_i + w_0\right) \qquad E(\vec{w}) = \frac{1}{2} \cdot (y - \hat{y})^2$$

$$E(\vec{w}) = \frac{1}{2} \cdot \left(y - f\left(\sum_{i=1}^{n} w_i \cdot x_i + w_0\right)\right)^2$$

Entrenaminto de un Perceptrón

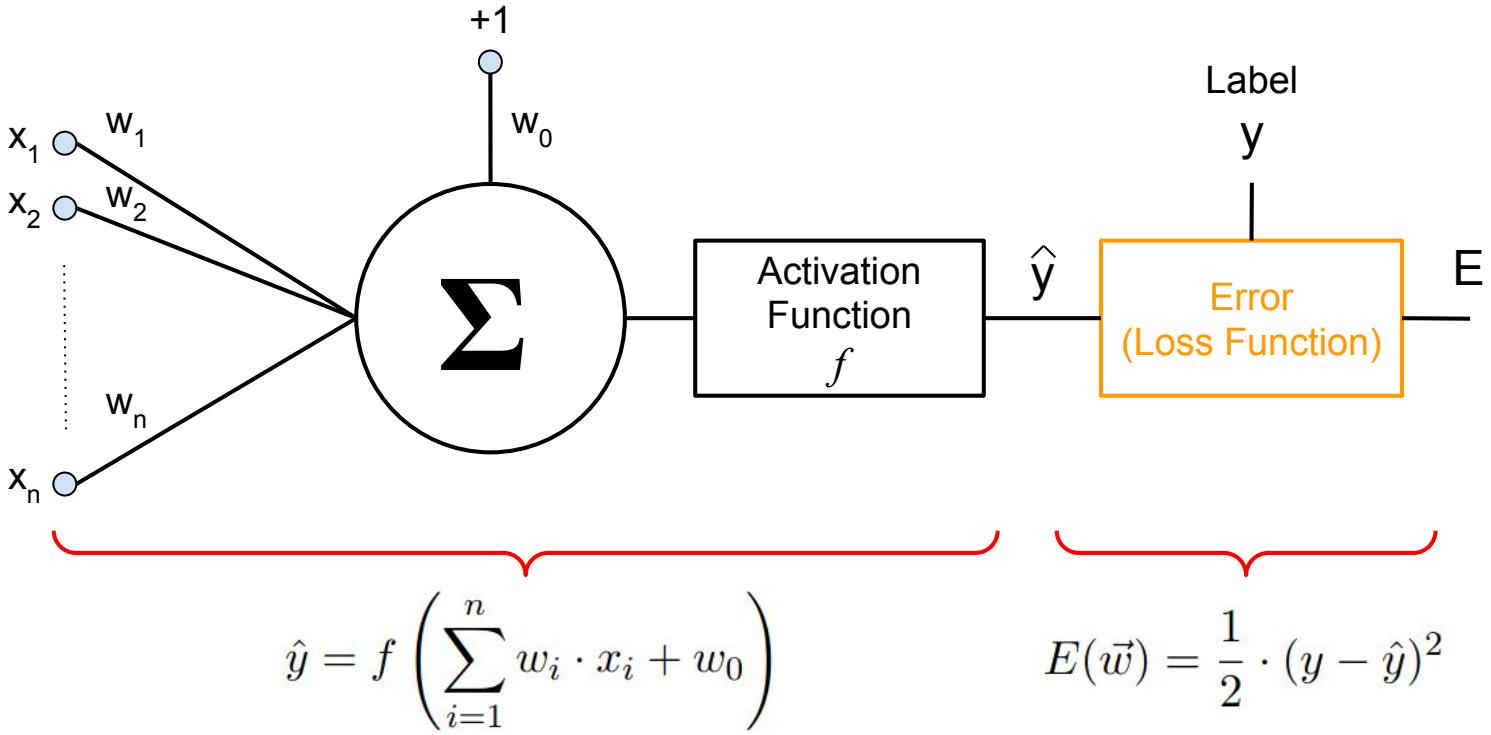

$$E(\vec{w}) = \frac{1}{2} \cdot \left(y - f\left(\sum_{i=1}^{n} w_i \cdot x_i + w_0\right)\right)^2 \implies \frac{\partial E(\vec{w})}{\partial w_i} = (y - \hat{y}) \cdot \frac{df}{dz} \cdot x_i$$

Entrenaminto de un Perceptrón

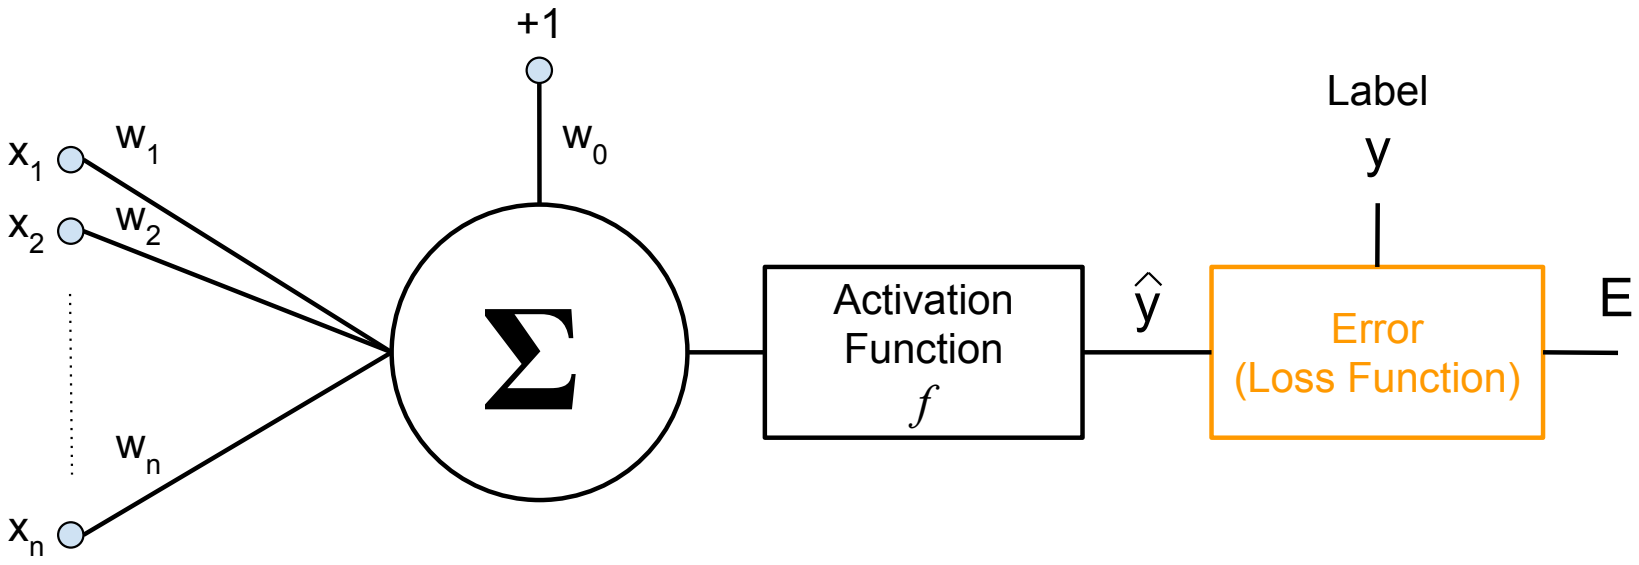

$$\Delta w_i = -\eta \cdot \frac{\partial E(\vec{w})}{\partial w_i}$$

$$w_i \leftarrow w_i + \Delta w_i$$

Descenso del Gradiente para Actualización de Pesos

¿ Cómo entrenar un Perceptrón Multicapa (MLP)?

- MLPs combinan múltiples perceptrones en varias capas
- Esto se conoce como *Deep Feed Forward Network* (DFF)
- Permiten la resolución de problemas de mayor complejidad
- En teoría, pueden aproximar cualquier función matemática
- Pero, ¿ cómo entrenar los pesos intermedios (hidden layers) ?

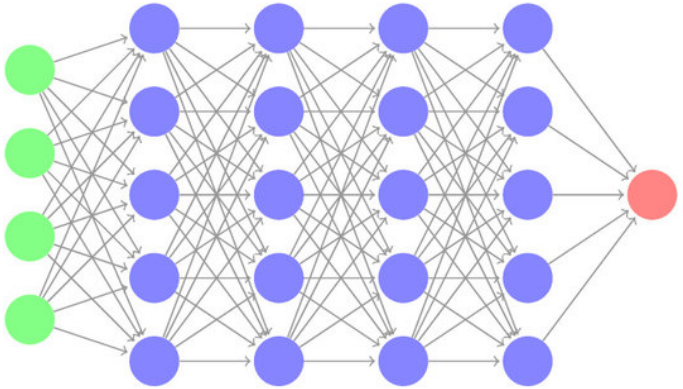

Algoritmo Backpropagation

- Aplica Regla de la Cadena de forma recursiva
- Puede ser usado en redes de tamaño arbitrario
- Puede ser usado en cualquier tipo de red y función diferenciable
- El rendimiento no está garantizado !

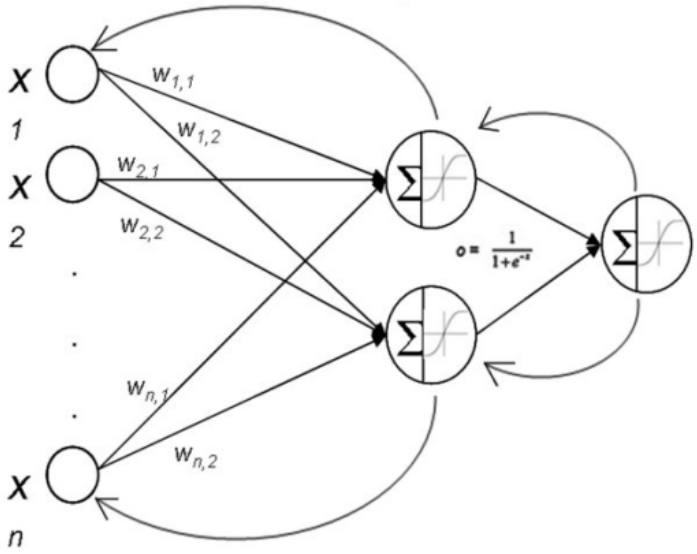

Algoritmo Backpropagation

$$E_p = \sum_j \frac{(t_{pj} - a_{pj})^2}{2}$$

$$\Delta_p w_{i \to j} = -\eta \frac{\partial E_p}{\partial w_{i \to j}}$$

$$\frac{\partial E_p}{\partial w_{i \to j}} = \frac{\partial E_p}{\partial I_{pj}} \frac{\partial I_{pj}}{\partial w_{i \to j}}$$

$$\frac{\partial I_{pj}}{\partial w_{i \to j}} = \frac{\partial}{\partial w_{i \to j}} \sum_k w_{k \to j} a_{pk} = a_{pi}$$

$$\delta_{pj} = -\frac{\partial E_p}{\partial I_{pj}}$$

$$\Delta_p w_{i \to j} = -\eta \delta_{pj} a_{pi}$$

$$\delta_{pj} = -\frac{\partial E_p}{\partial I_{pj}} = -\frac{\partial E_p}{\partial a_{pj}} \frac{\partial a_{pj}}{\partial I_{pj}}$$

$$\frac{\partial a_{pj}}{\partial I_{pj}} = f'_j(I_{pj})$$

For output units,

$$\frac{\partial E_p}{\partial a_{pj}} = -(t_{pj} - a_{pj})$$

$$\delta_{pj} = (t_{pj} - a_{pj}) f'_j(I_{pj})$$

For hidden units,

$$\sum_k \frac{\partial E_p}{\partial I_{pk}} \frac{\partial I_{pk}}{\partial a_{pj}} = \sum_k \frac{\partial E_p}{\partial I_{pk}} \frac{\partial}{\partial a_{pj}} \sum_i w_{i \to k} a_{pi} = \sum_k \frac{\partial E_p}{\partial I_{pk}} w_{j \to k} = -\sum_k \delta_{pk} w_{j-}$$

$$\delta_{pj} = (\sum_k \delta_{pk} w_{j \to k}) f'_j(I_{pj})$$

Algoritmo Backpropagation

$$E_p = \sum_j \frac{(t_{pj} - a_{pj})^2}{2}$$

$$\frac{\partial E_p}{\partial w_{i\to j}} = \frac{\partial E_p}{\partial I_{pj}} \frac{\partial I_{pj}}{\partial w_{i\to j}}$$

$$\frac{\partial I_{pj}}{\partial w_{i\to j}} = \frac{\partial}{\partial w_{i\to j}} \sum_k w_{k\to j} a_{pk} = a_{pi}$$

$$\delta_{pj} = -\frac{\partial E_p}{\partial I_{pj}}$$

$$= -\eta \delta_{pj} a_{pi}$$

$$\delta_{pj} = \frac{\partial E_p}{\partial a_{pj}} \frac{\partial a_{pj}}{\partial I_{pj}}$$

$$\frac{\partial a_{pj}}{\partial I_{pj}} =$$

output units,

$$\frac{\partial E_p}{\partial a_{pj}} = -(t_{pj} - a_{pj})$$

$$\delta_{pj} = (t_{pj} - a_{pj}) f'_j(I_{pj})$$

For

$$\sum_k \frac{\partial E_p}{\partial I_{pk}} \frac{\partial}{\partial a_{pj}} \qquad = -\sum_k \delta_{pk} w_{j-}$$

$$\delta_{pj} = (\sum_k \delta_{pk} w_{j\to k}) f'_j(I_{pj})$$

Grafos de Cómputo

- Los grafos de cómputo son representaciones que permiten expresar y evaluar funciones matemáticas
- Consisten en grafos dirigidos cuyos nodos corresponden a operaciones matemáticas, y sus aristas, al flujo de variables
- Los frameworks más populares para deep learning (Tensorflow, Torch, Theano, etc.) utilizan grafos de cómputo para implementar backpropagation

g = (x+y) * z

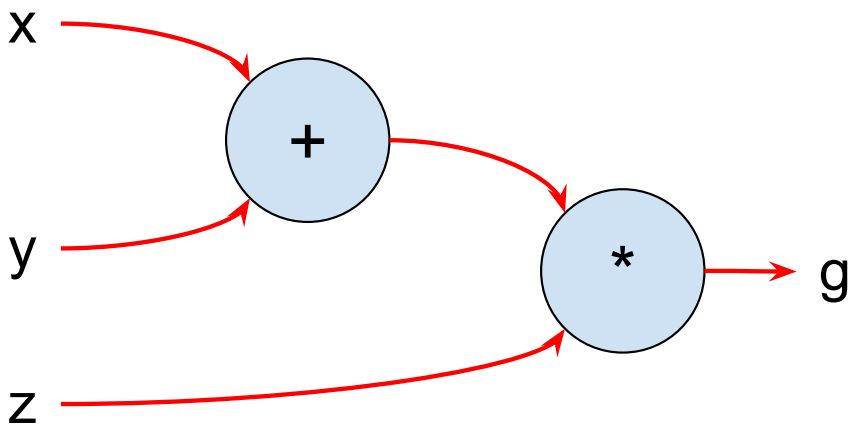

Ahora que sabemos que son los grafos de cómputo, ¿ qué función matemática está representada en el grafo de la figura ?

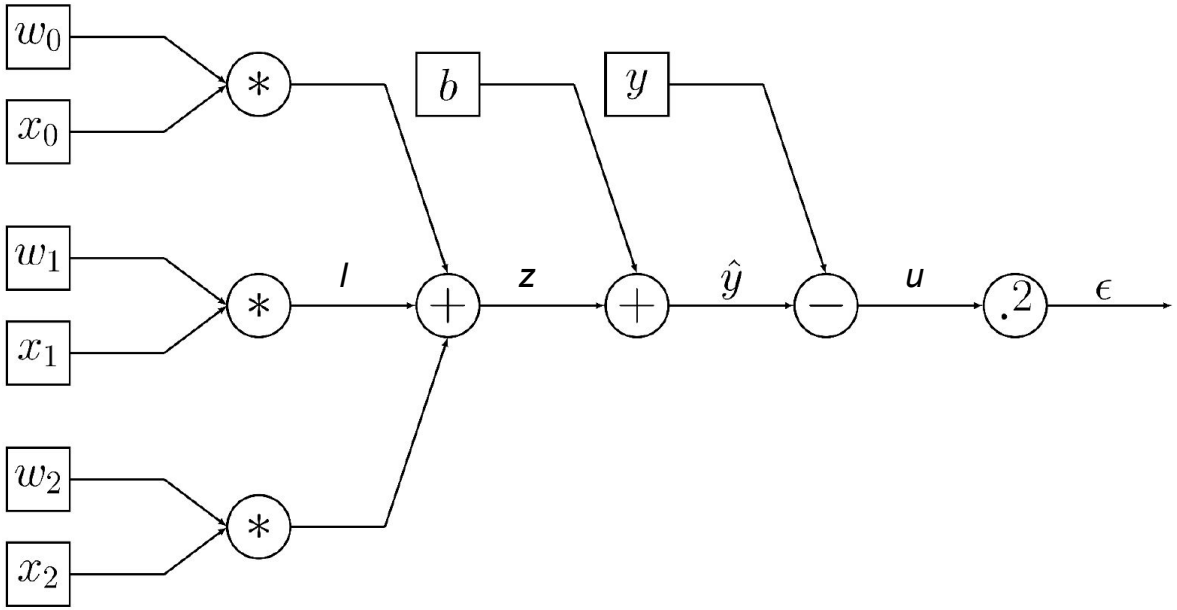

Ahora que sabemos que son los grafos de cómputo, ¿ qué función matemática está representada en el grafo de la figura ?

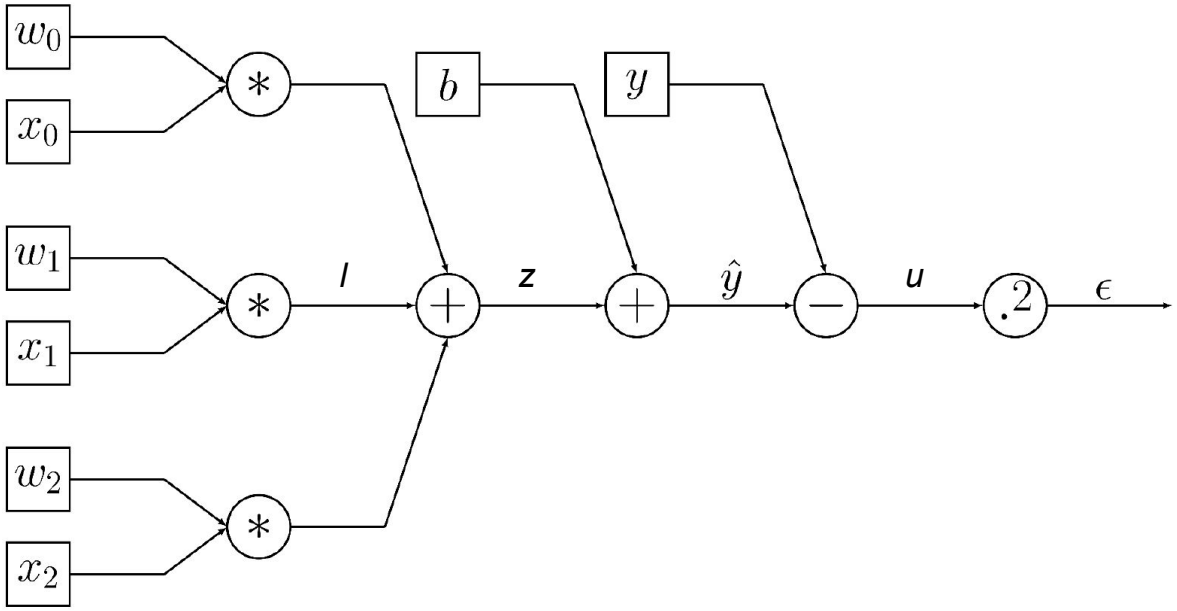

Perceptrón más función de error cuadrático:

$$E(\vec{w}) = \left(y - \left(\sum w_i \cdot x_i + b\right)\right)^2$$

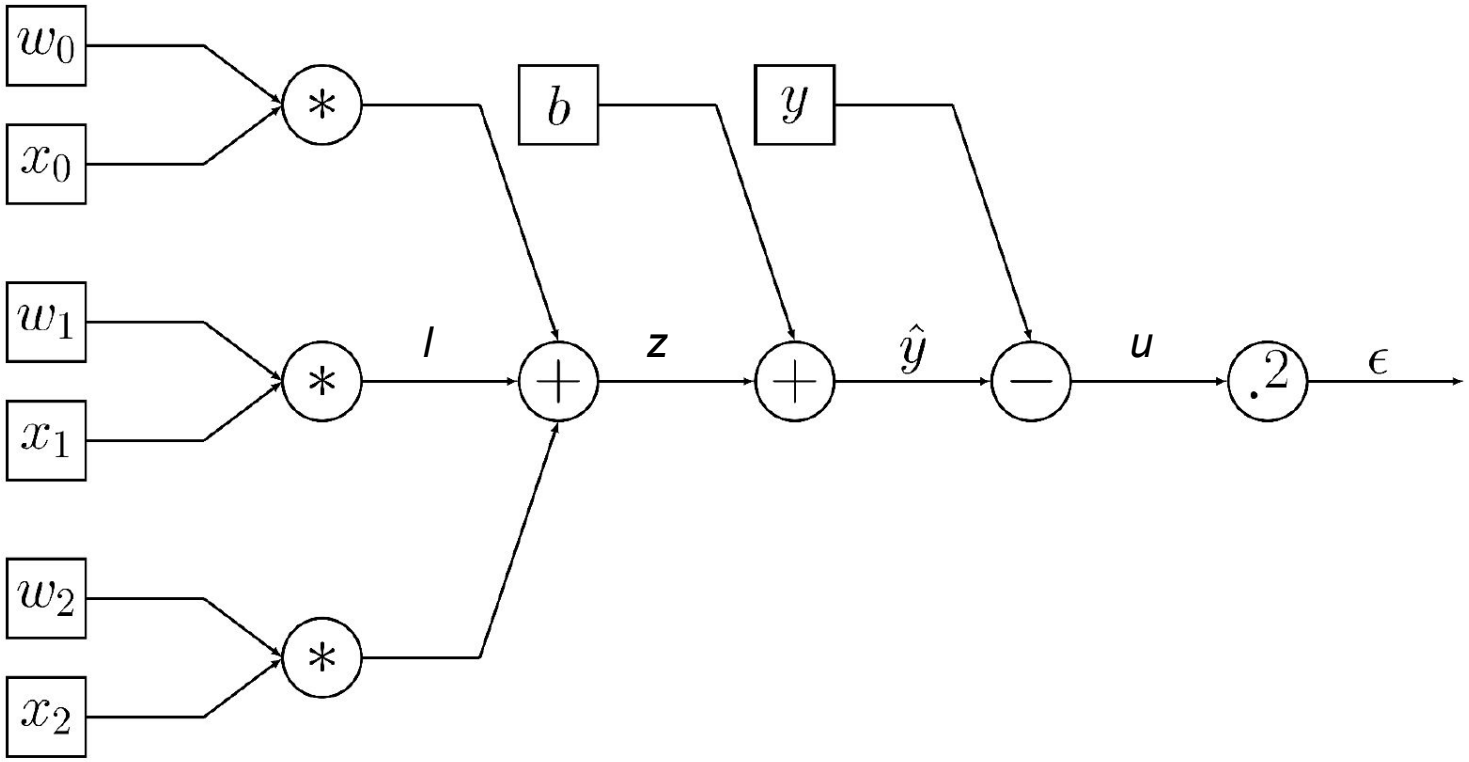

¿ Cuál es la derivada de esta función ?

$$E(\vec{w}) = \left(y - \left(\sum w_i \cdot x_i + b\right)\right)^2$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = \left(y - \left(\sum w_i \cdot x_i + b\right)\right)^2$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = \left(y - \left(\sum w_i \cdot x_i + b\right)\right)^2$$

El primer paso consiste en definir variables auxiliares con derivada conocida

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = \left(y - \left(\sum w_i \cdot x_i + b\right)\right)^2$$

El primer paso consiste en definir variables auxiliares con derivada conocida

$$l(w_i) = w_i \cdot x_i$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = \left(y - \left(\sum l(w_i) + b\right)\right)^2$$

El primer paso consiste en definir variables auxiliares con derivada conocida

$$l(w_i) = w_i \cdot x_i$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = \left(y - \left(\sum l(w_i) + b\right)\right)^2$$

El primer paso consiste en definir variables auxiliares con derivada conocida

$$l(w_i) = w_i \cdot x_i$$
$$z(l) = \sum l(w_i)$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = (y - (z(l(w_i)) + b))^2$$

El primer paso consiste en definir variables auxiliares con derivada conocida

$$l(w_i) = w_i \cdot x_i$$
$$z(l) = \sum l(w_i)$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = (y - (z(l(w_i)) + b))^2$$

El primer paso consiste en definir variables auxiliares con derivada conocida

$$l(w_i) = w_i \cdot x_i$$
$$z(l) = \sum l(w_i)$$
$$\hat{y}(z) = z + b$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = (y - \hat{y}(z(l(w_i))))^2$$

El primer paso consiste en definir variables auxiliares con derivada conocida

$$l(w_i) = w_i \cdot x_i$$
$$z(l) = \sum l(w_i)$$
$$\hat{y}(z) = z + b$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = (y - \hat{y}(z(l(w_i))))^2$$

El primer paso consiste en definir variables auxiliares con derivada conocida

$$\begin{aligned} l(w_i) &= w_i \cdot x_i \\ z(l) &= \sum l(w_i) \\ \hat{y}(z) &= z + b \\ u(\hat{y}) &= y - \hat{y} \end{aligned}$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = u(\hat{y}(z(l(w_i))))^2$$

El primer paso consiste en definir variables auxiliares con derivada conocida

$$\begin{aligned} l(w_i) &= w_i \cdot x_i \\ z(l) &= \sum l(w_i) \\ \hat{y}(z) &= z + b \\ u(\hat{y}) &= y - \hat{y} \end{aligned}$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = u(\hat{y}(z(l(w_i))))^2$$

El primer paso consiste en definir variables auxiliares con derivada conocida

$$\begin{aligned} l(w_i) &= w_i \cdot x_i \\ z(l) &= \sum l(w_i) \\ \hat{y}(z) &= z + b \\ u(\hat{y}) &= y - \hat{y} \\ E(u) &= u^2 \end{aligned}$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = E(u(\hat{y}(z(l(w_i)))))$$

El primer paso consiste en definir variables auxiliares con derivada conocida

$$\begin{aligned} l(w_i) &= w_i \cdot x_i \\ z(l) &= \sum l(w_i) \\ \hat{y}(z) &= z + b \\ u(\hat{y}) &= y - \hat{y} \\ E(u) &= u^2 \end{aligned}$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

$$E(\vec{w}) = E(u(\hat{y}(z(l(w_i)))))$$

El primer paso consiste en definir variables auxiliares con derivada conocida

$$\begin{aligned} l(w_i) &= w_i \cdot x_i \\ z(l) &= \sum l(w_i) \\ \hat{y}(z) &= z + b \\ u(\hat{y}) &= y - \hat{y} \\ E(u) &= u^2 \end{aligned}$$

Gracias a lo anterior, podemos expresar la función original como una función compuesta

$$E(\vec{w}) = E(\ u(\ \hat{y}(\ z(\ l(\ \vec{w}\ )\ )\ )\ )\ )$$

Para obtener su derivada, necesitamos aplicar la Regla de la Cadena

A partir de esta nueva expresión ...

$$E(\vec{w}) = E(\ u(\ \hat{y}(\ z(\ l(\ \vec{w}\ )\ )\ )\ )\ )$$

calculamos su derivada de la siguiente manera:

$$\frac{\partial E(\vec{w})}{\partial w_i} = \frac{\partial E(\vec{w})}{\partial u} \cdot \frac{\partial u}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial l} \cdot \frac{\partial l}{\partial w_i}$$

Grafos de Cómputo

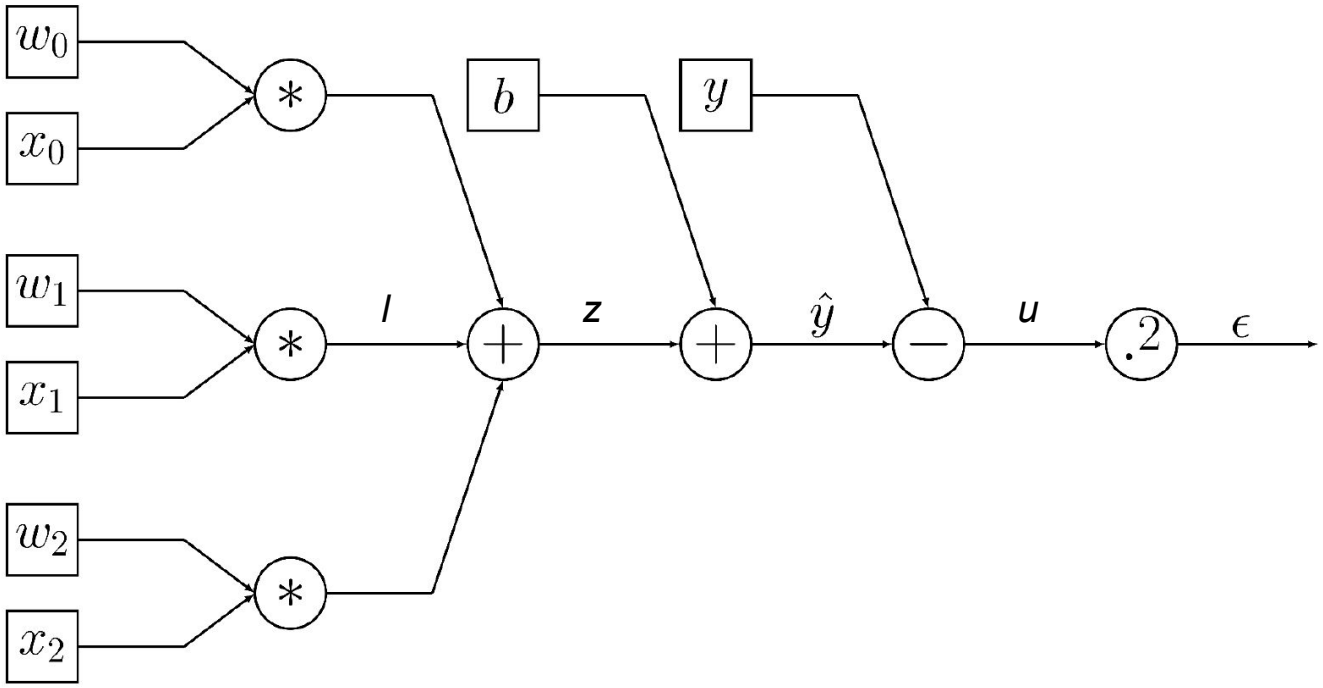

¿ Cuál es la derivada de esta función ?

$$E(\vec{w}) = \left(y - \left(\sum w_i \cdot x_i + b\right)\right)^2 \implies \frac{\partial E(\vec{w})}{\partial w_i} = \frac{\partial l}{\partial w_i} \cdot \frac{\partial z}{\partial l} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial u}{\partial \hat{y}} \cdot \frac{\partial E(\vec{w})}{\partial u}$$

Grafos de Cómputo

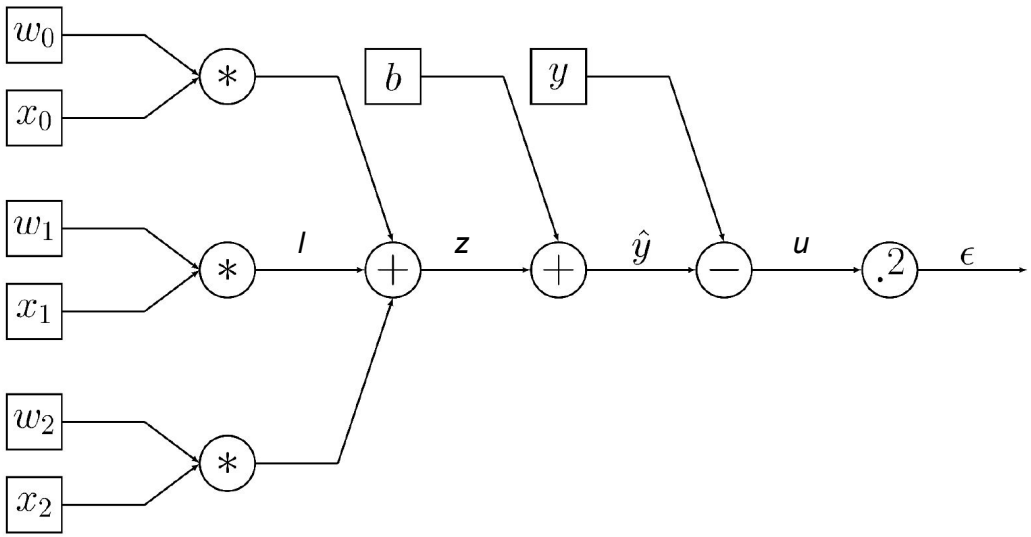

$$E(\vec{w}) = \left(y - \left(\sum w_i \cdot x_i + b\right)\right)^2 \implies \frac{\partial E(\vec{w})}{\partial w_i} = \frac{\partial l}{\partial w_i} \cdot \frac{\partial z}{\partial l} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial u}{\partial \hat{y}} \cdot \frac{\partial E(\vec{w})}{\partial u}$$

En conclusión, para propagar el gradiente necesitamos:

1. Calcular las derivadas locales a cada nodo
2. Multiplicar las derivadas locales de derecha a izquierda (*backward*) hasta alcanzar el peso (w_i) en cuestión

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

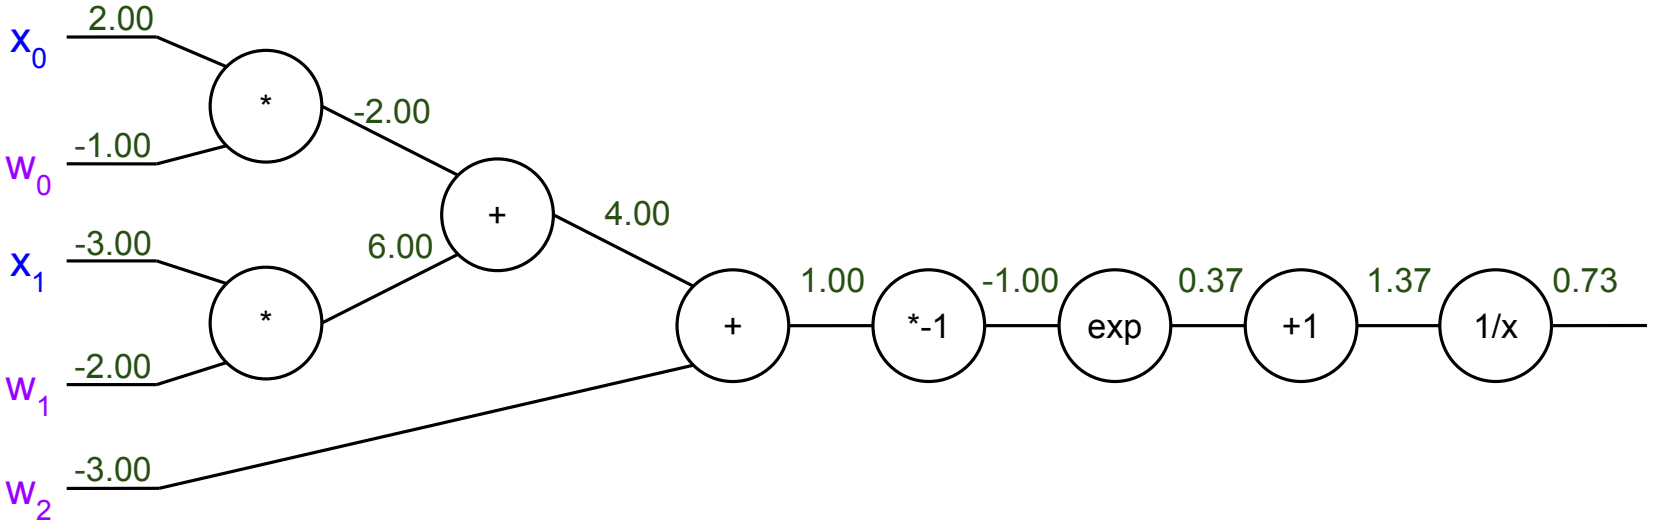

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

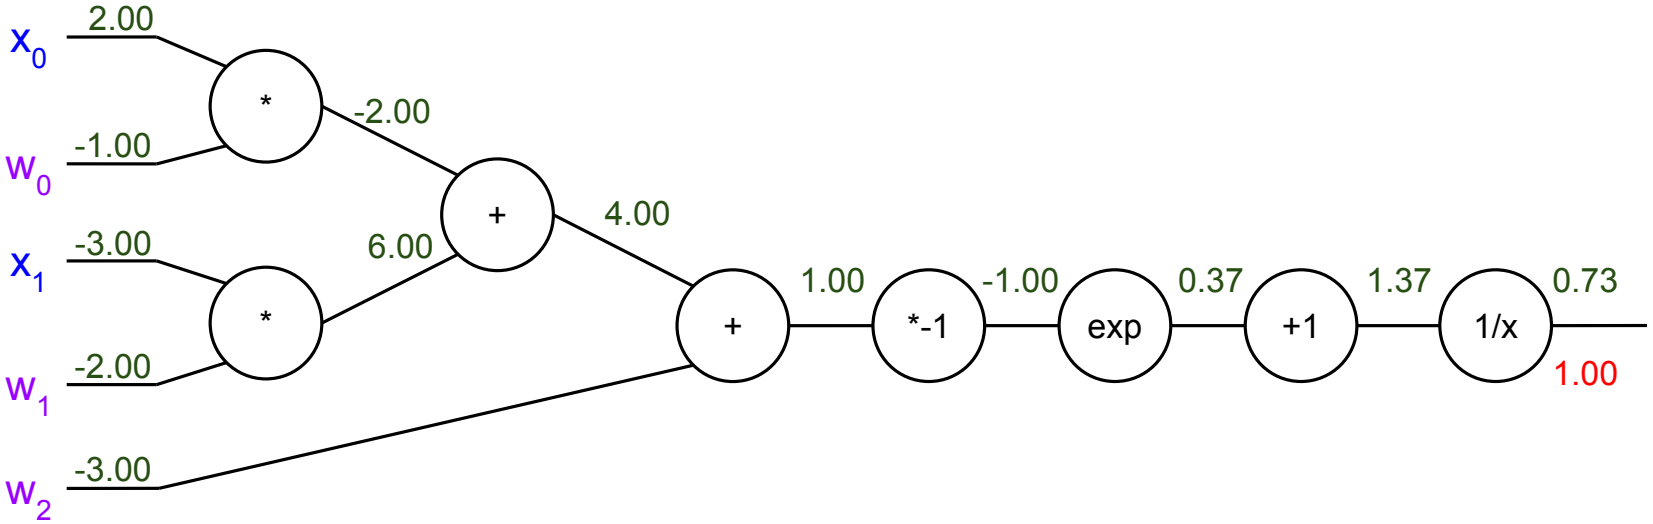

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

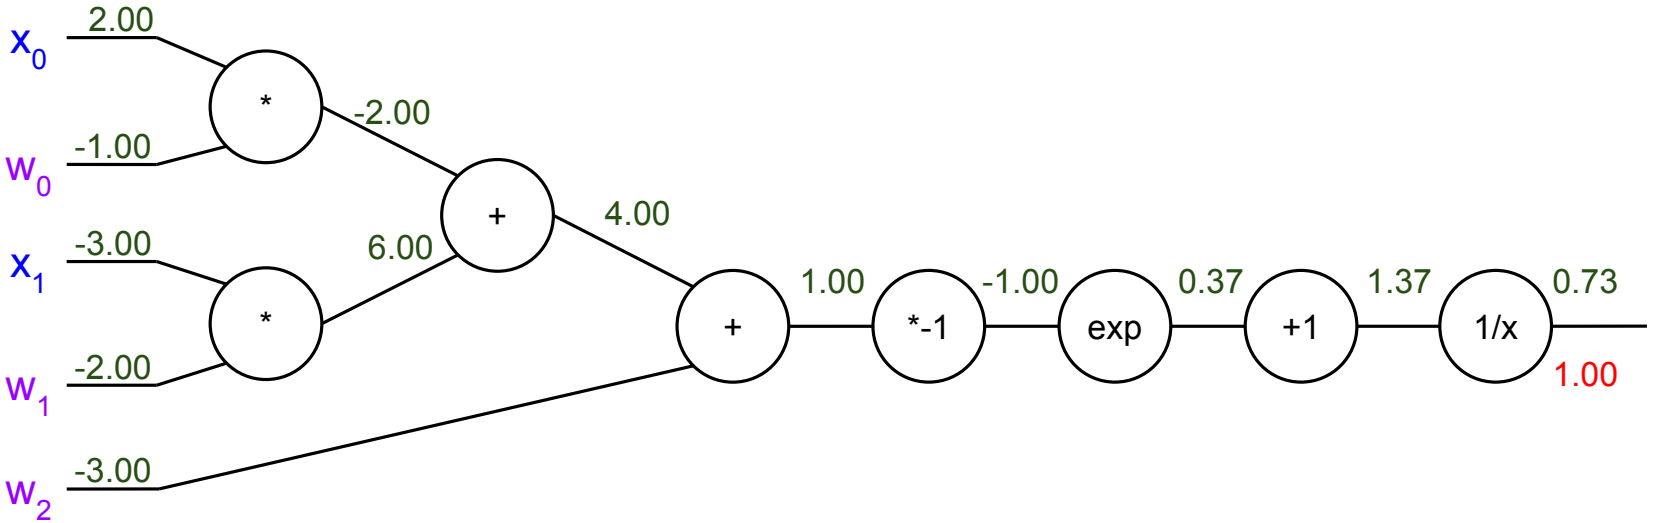

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x \qquad\qquad f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a \qquad\qquad f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

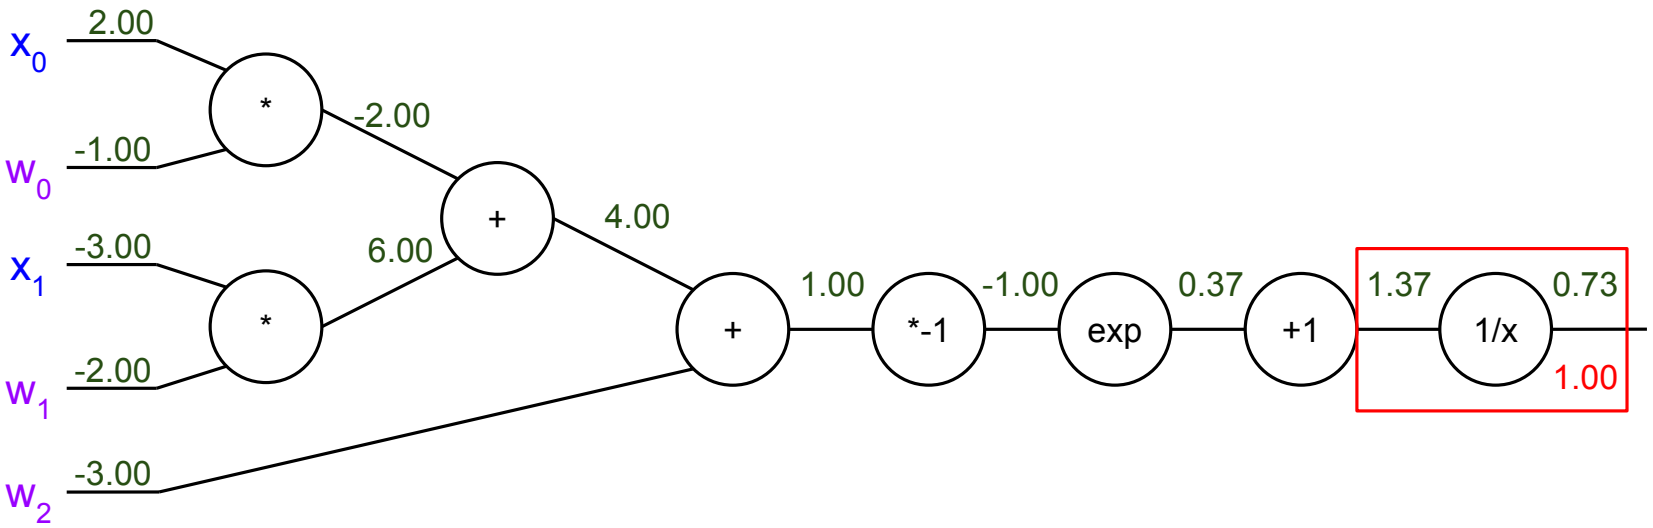

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x$$

$$\boxed{f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a$$

$$f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

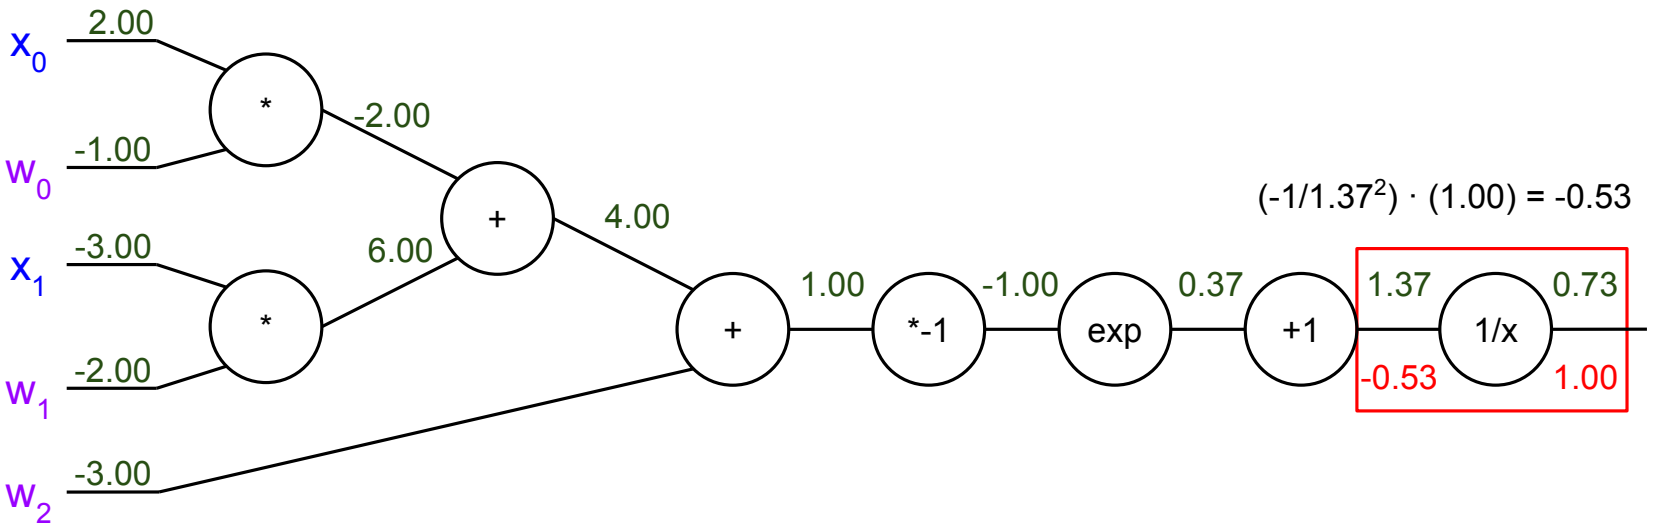

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x$$

$$\boxed{f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a$$

$$f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

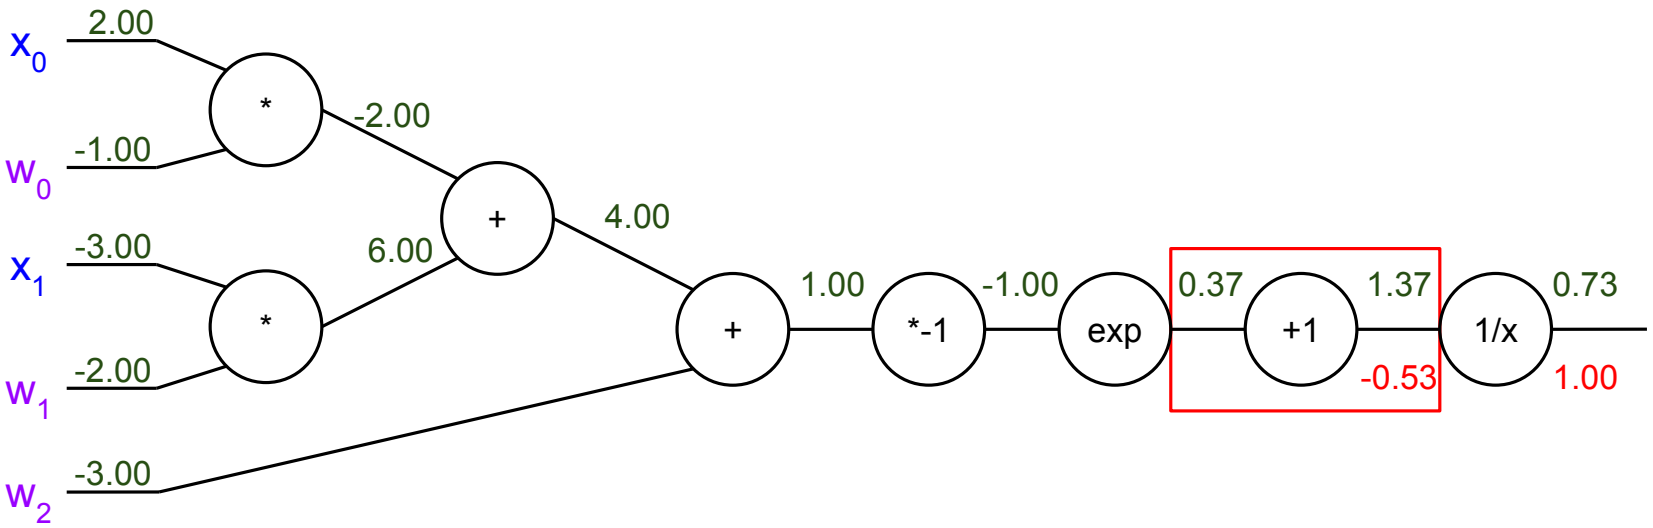

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x$$

$$f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a$$

$$\boxed{f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1}$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

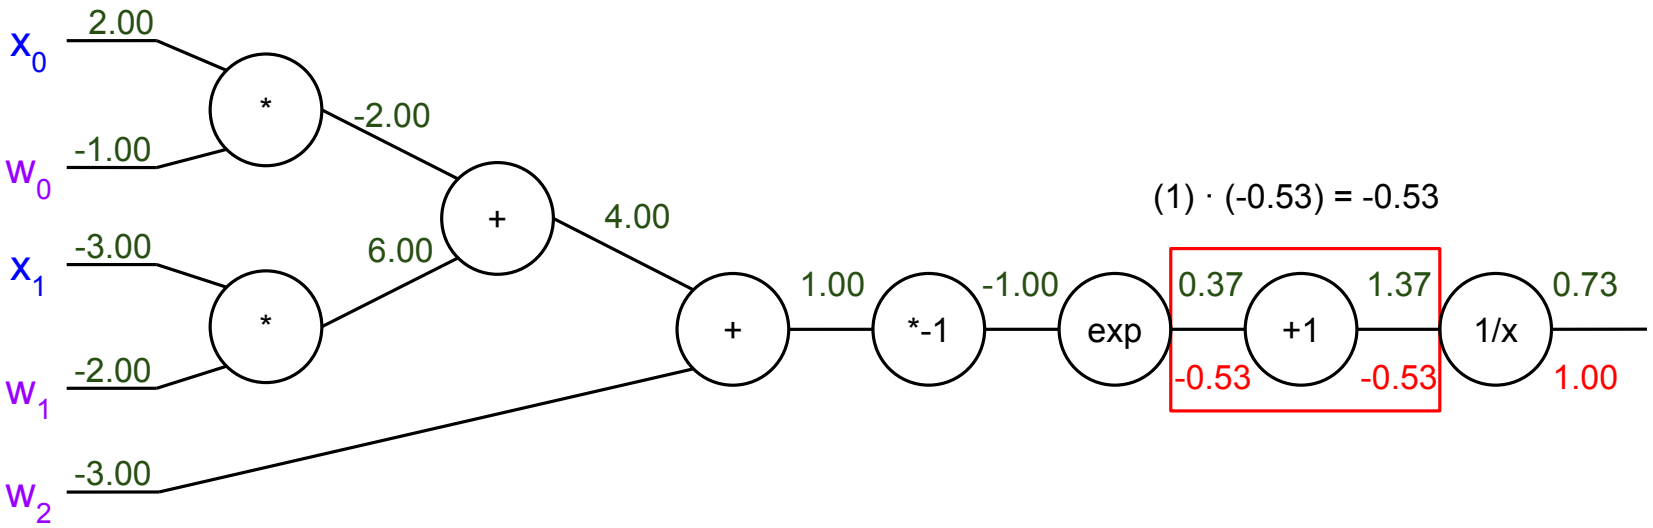

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x$$

$$f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a$$

$$\boxed{f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1}$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

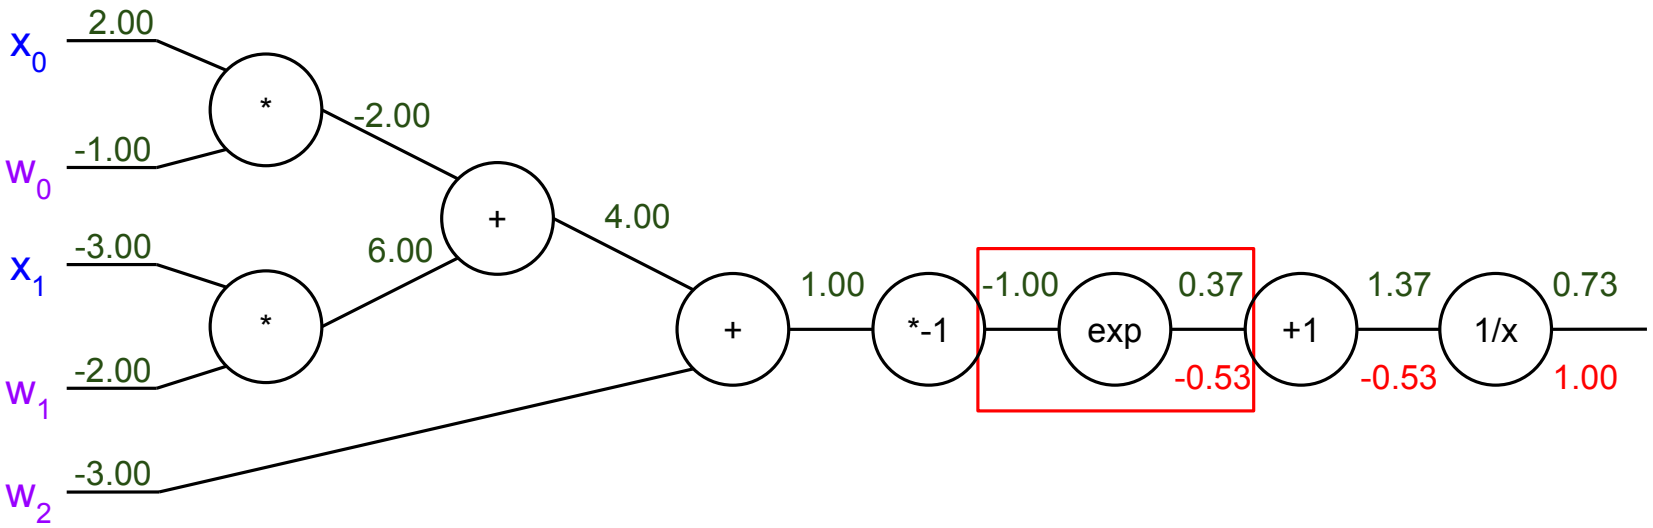

$$\boxed{f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x}$$

$$f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a$$

$$f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

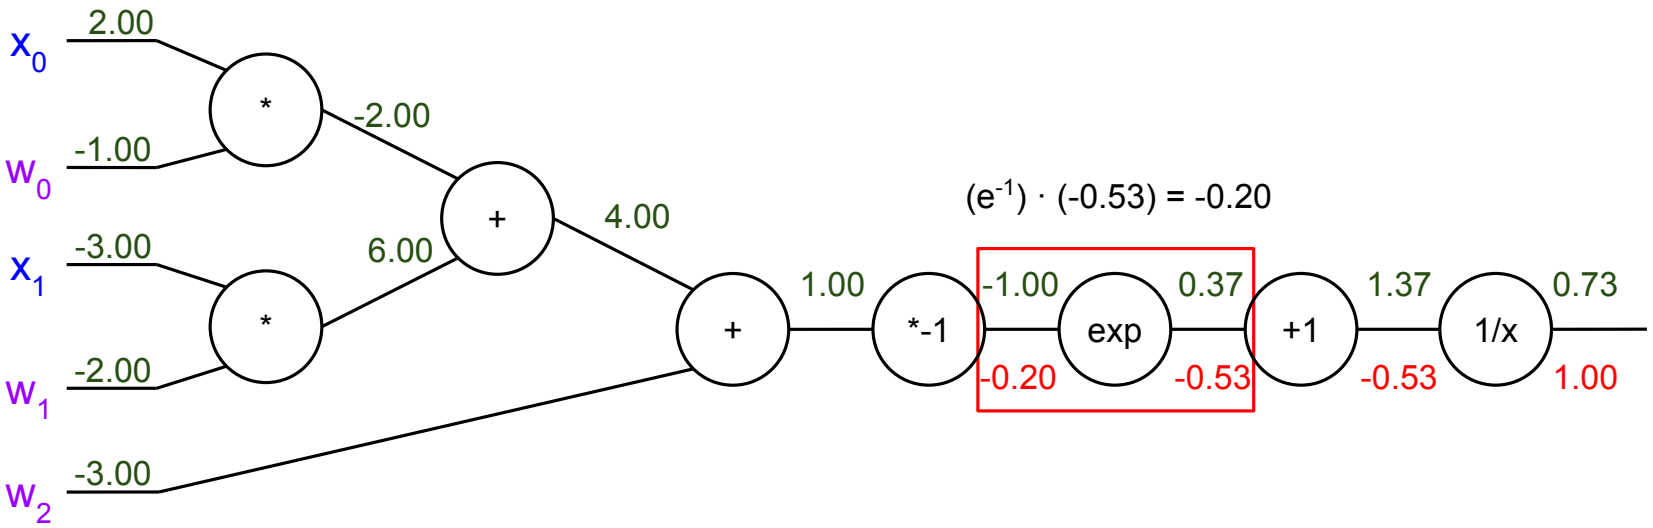

$$\boxed{f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x}$$

$$f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a$$

$$f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

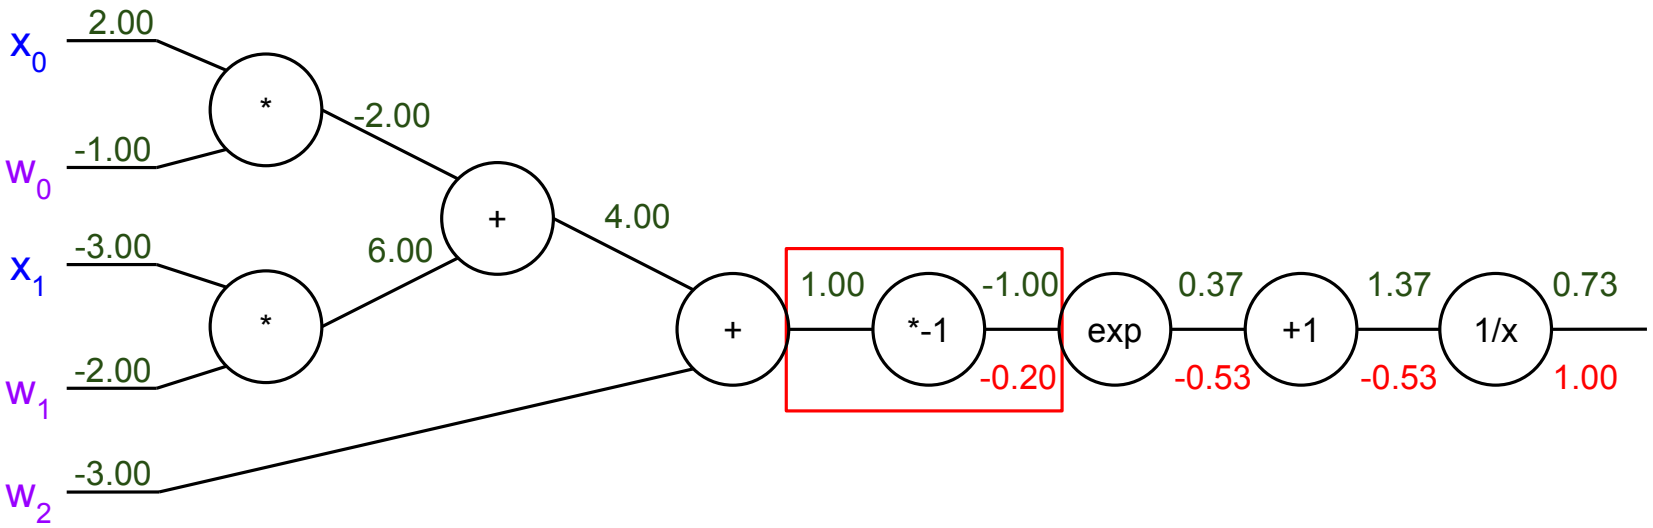

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x$$

$$f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$\boxed{f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a}$$

$$f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

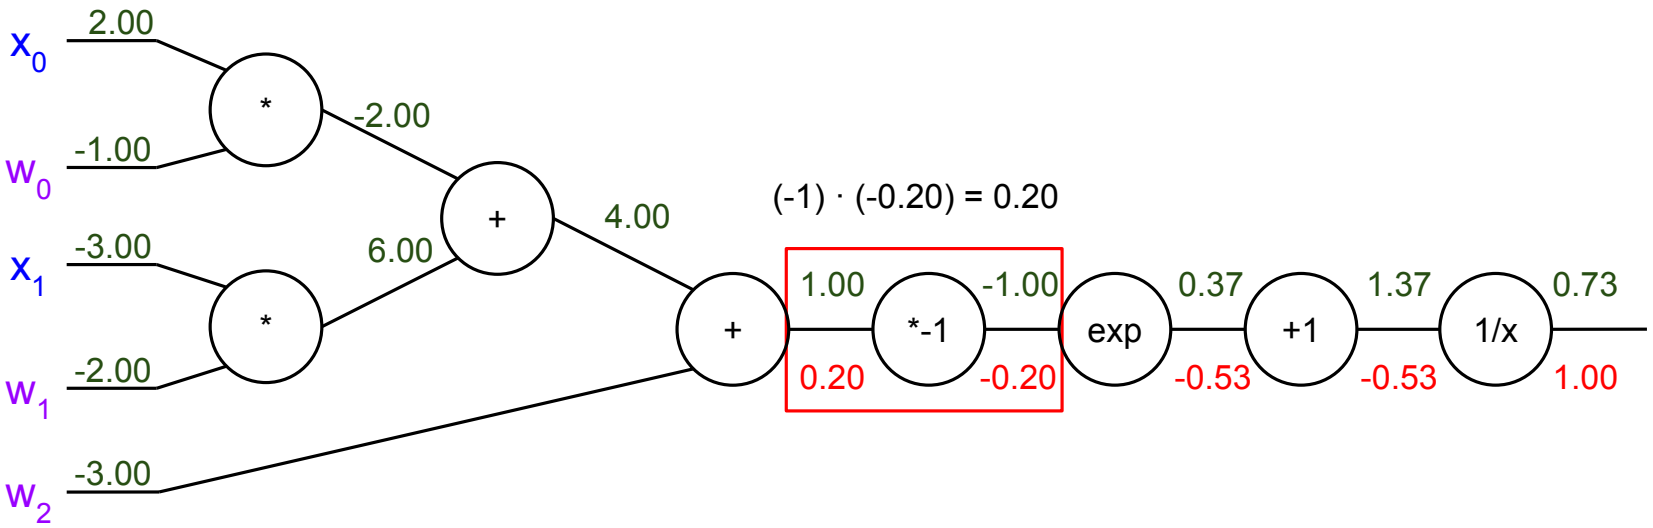

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x$$

$$f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$\boxed{f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a}$$

$$f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

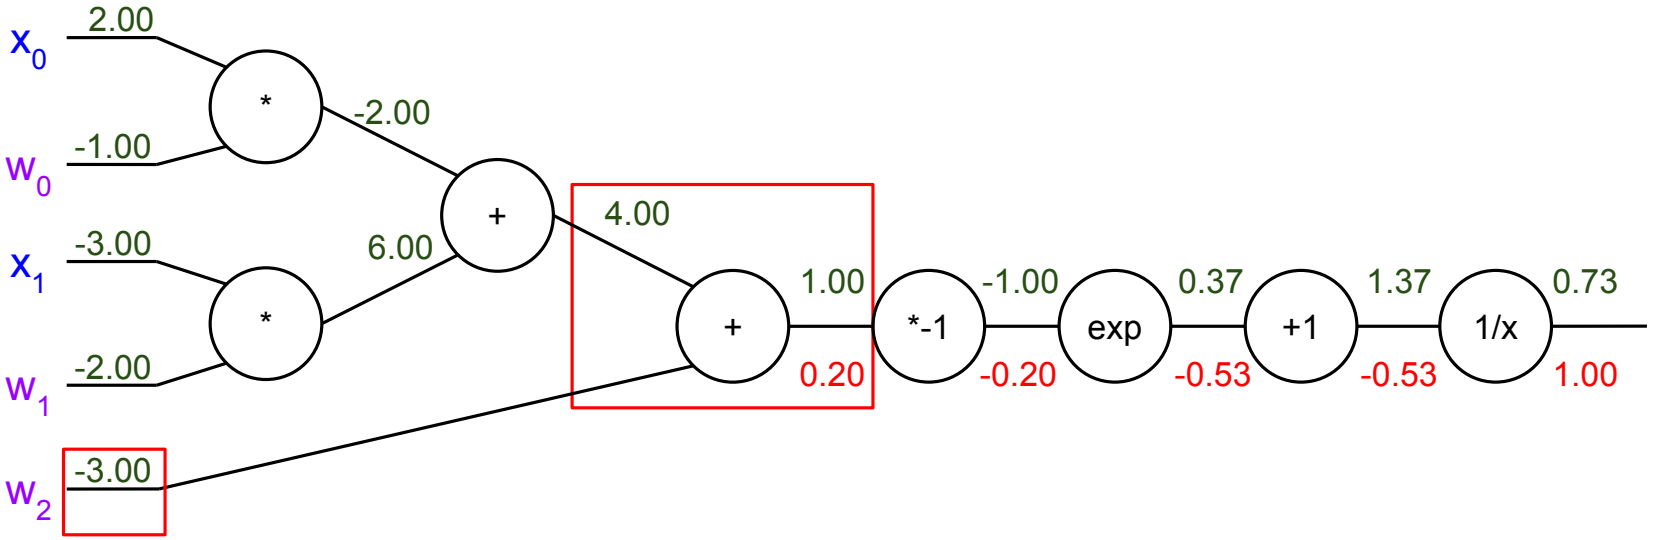

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x \qquad\qquad f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a \qquad\qquad f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

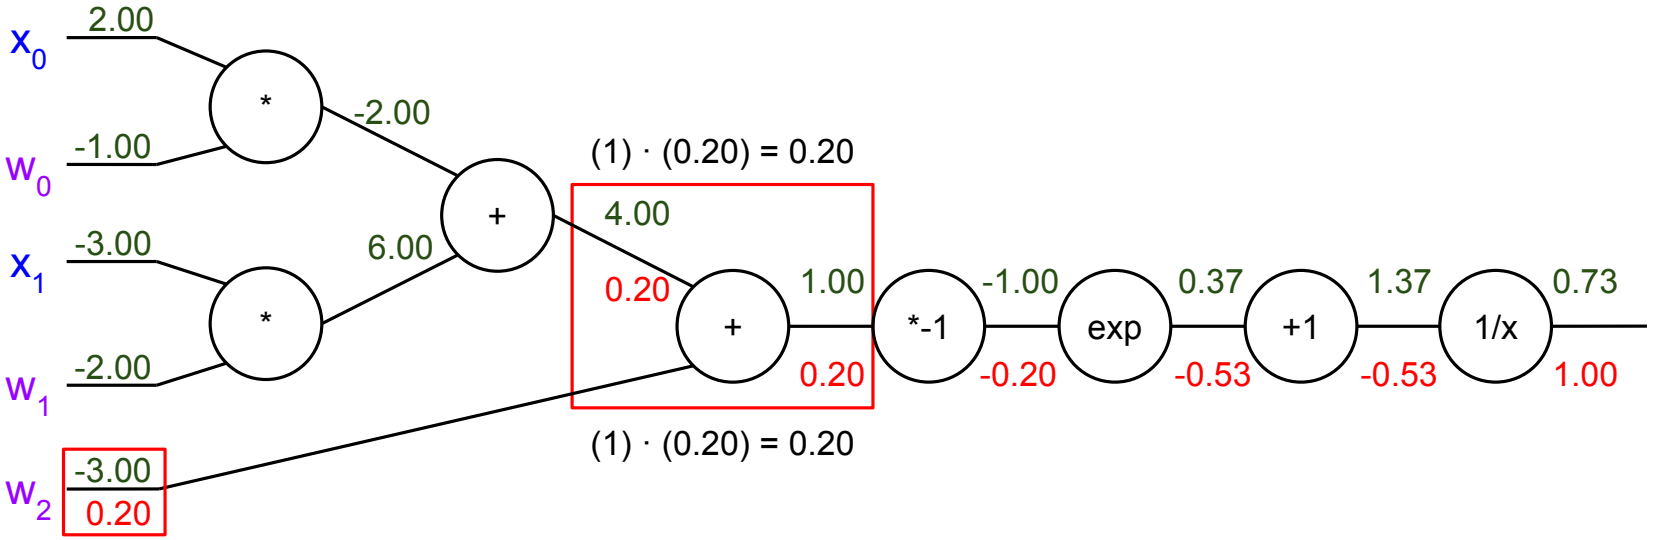

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x \qquad\qquad f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a \qquad\qquad f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

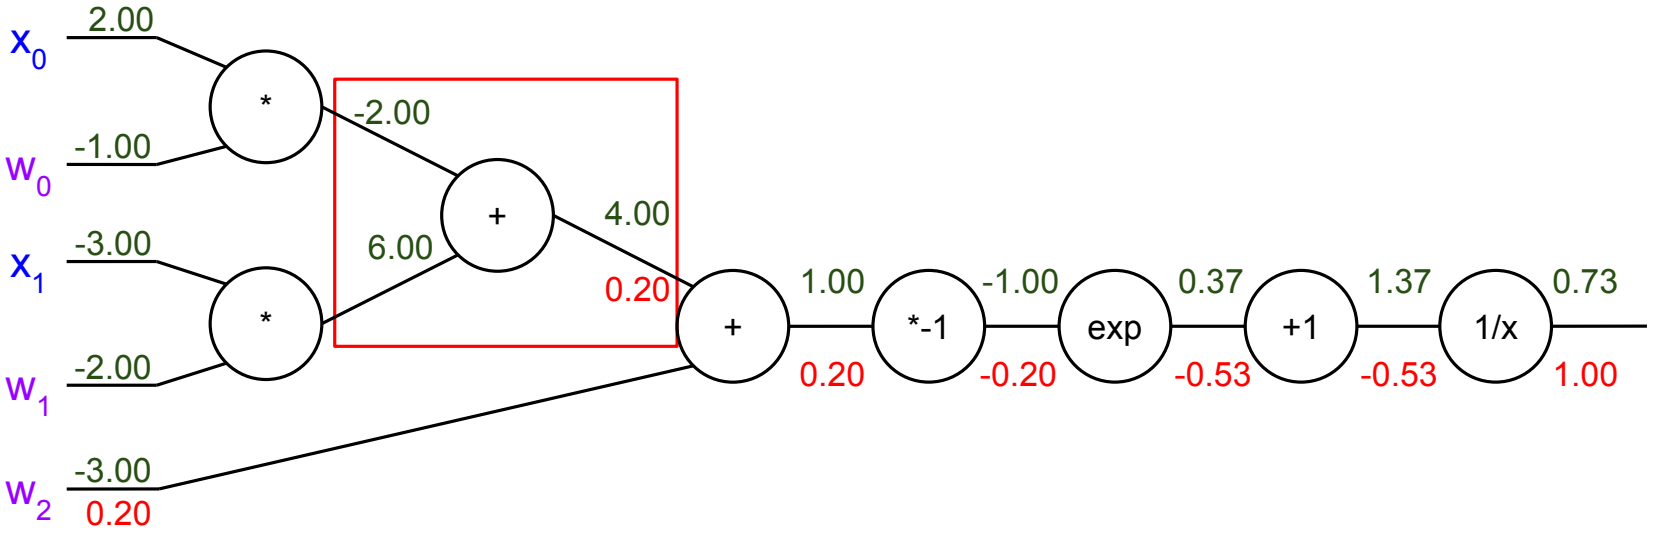

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x \qquad\qquad f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a \qquad\qquad f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

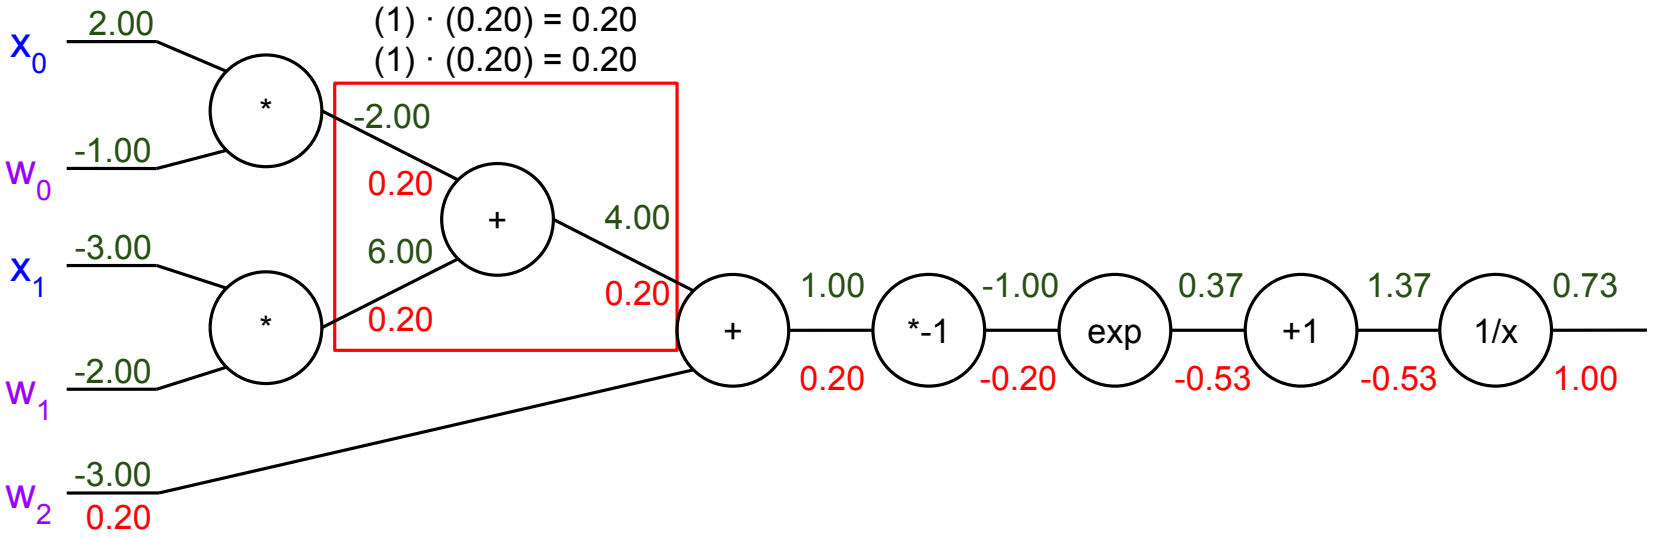

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x \qquad\qquad f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a \qquad\qquad f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

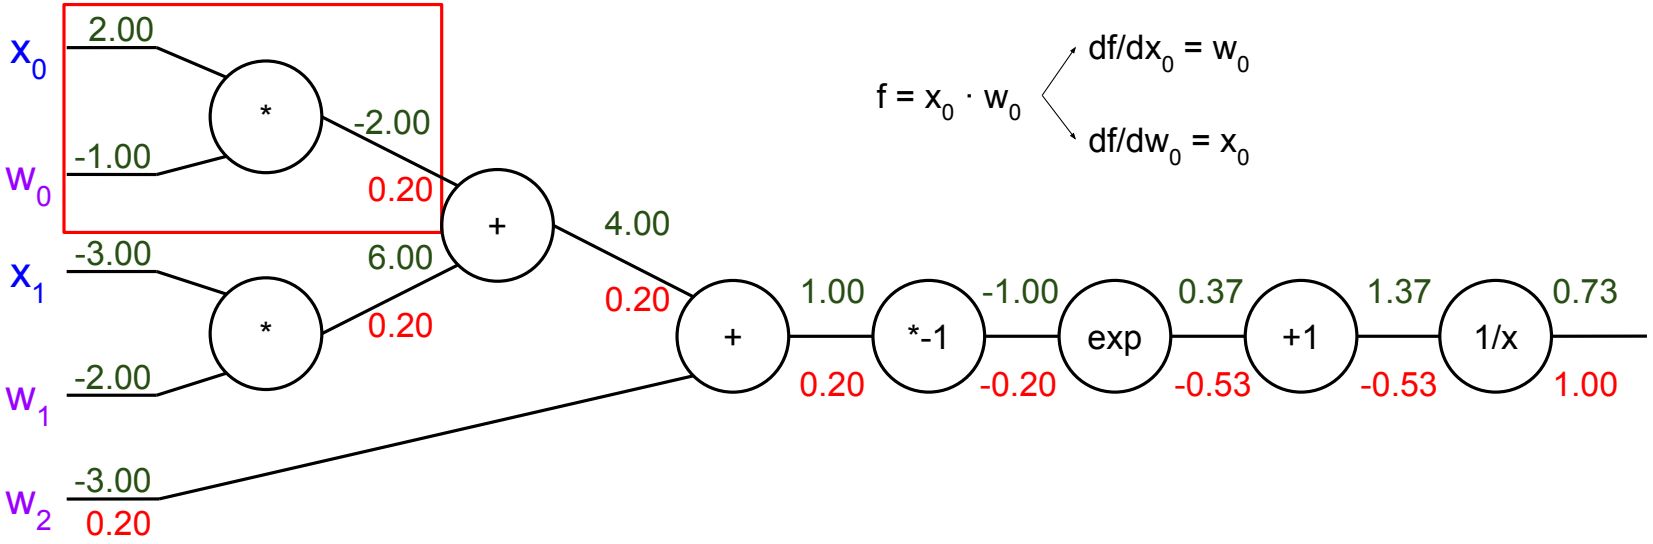

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x \qquad\qquad f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a \qquad\qquad f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

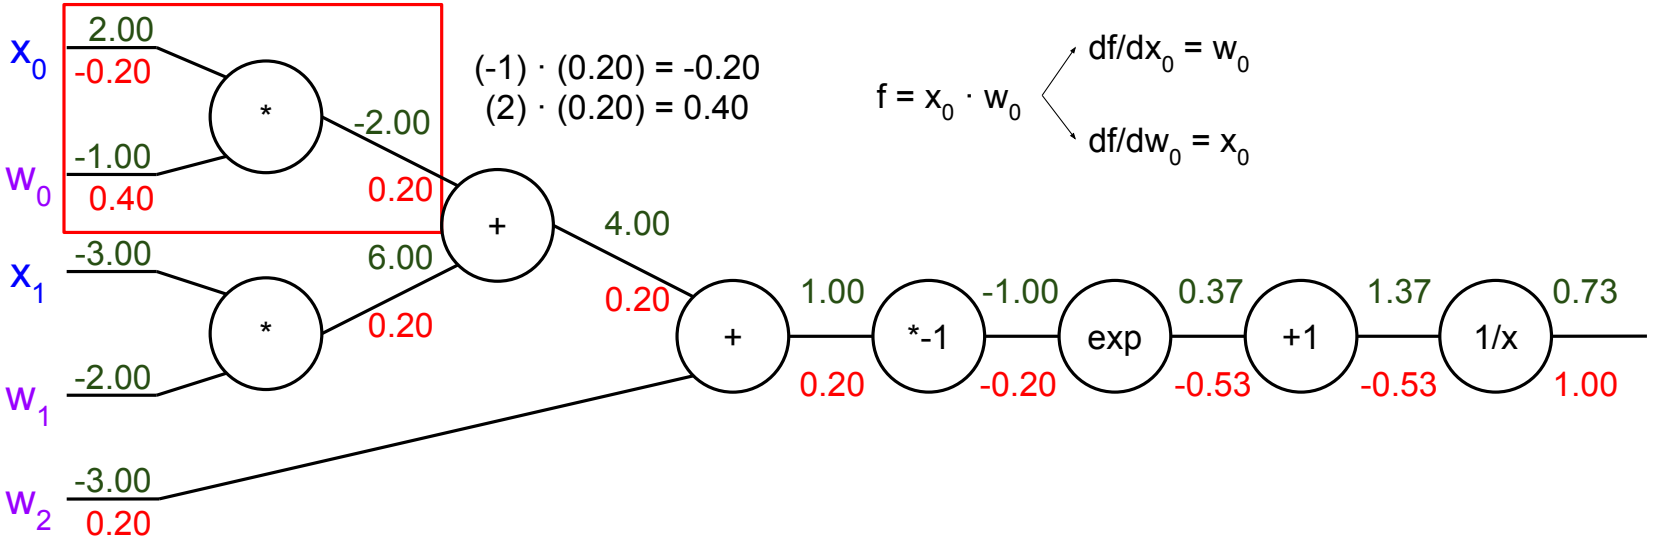

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x \qquad\qquad f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a \qquad\qquad f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

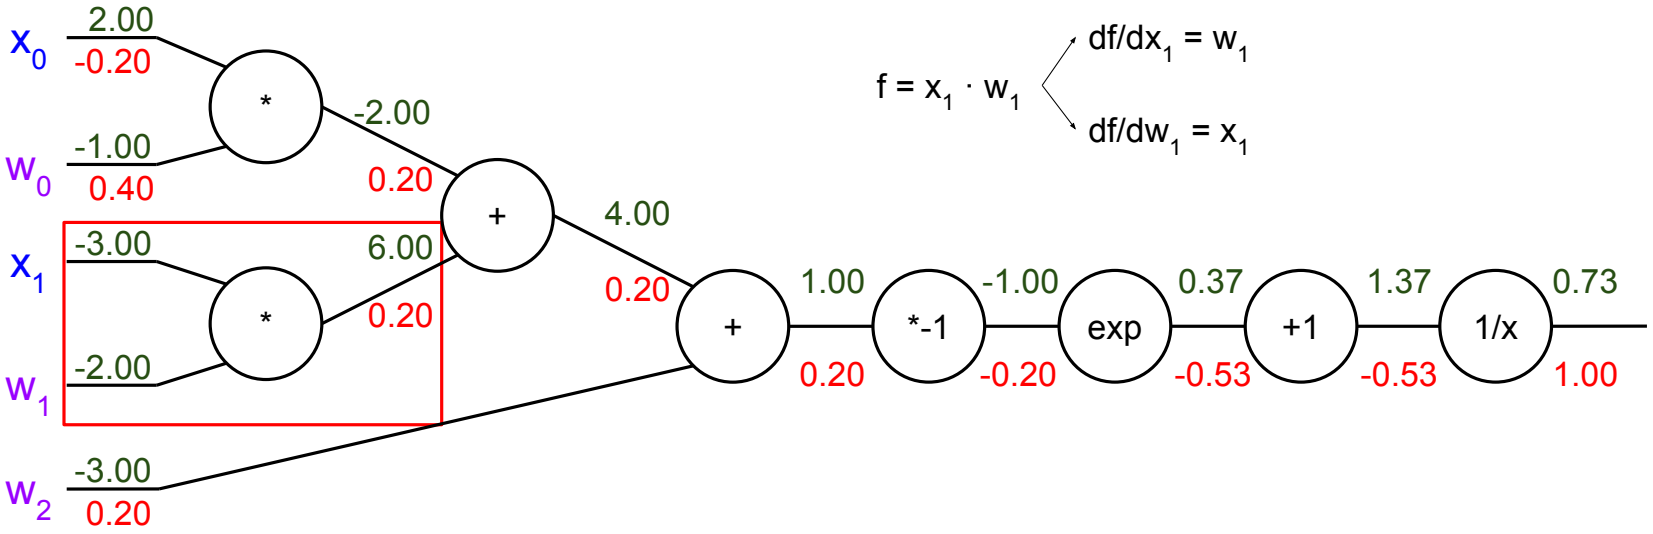

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x \qquad\qquad f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a \qquad\qquad f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

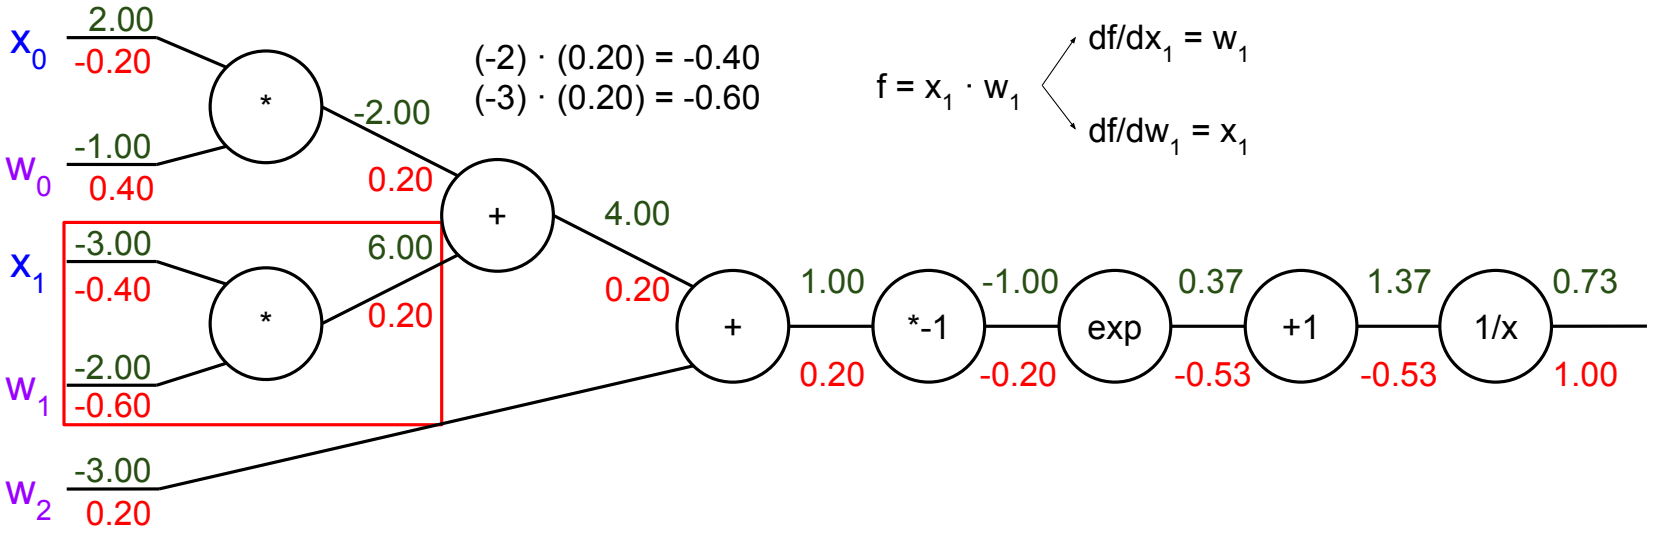

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x \qquad\qquad f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a \qquad\qquad f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

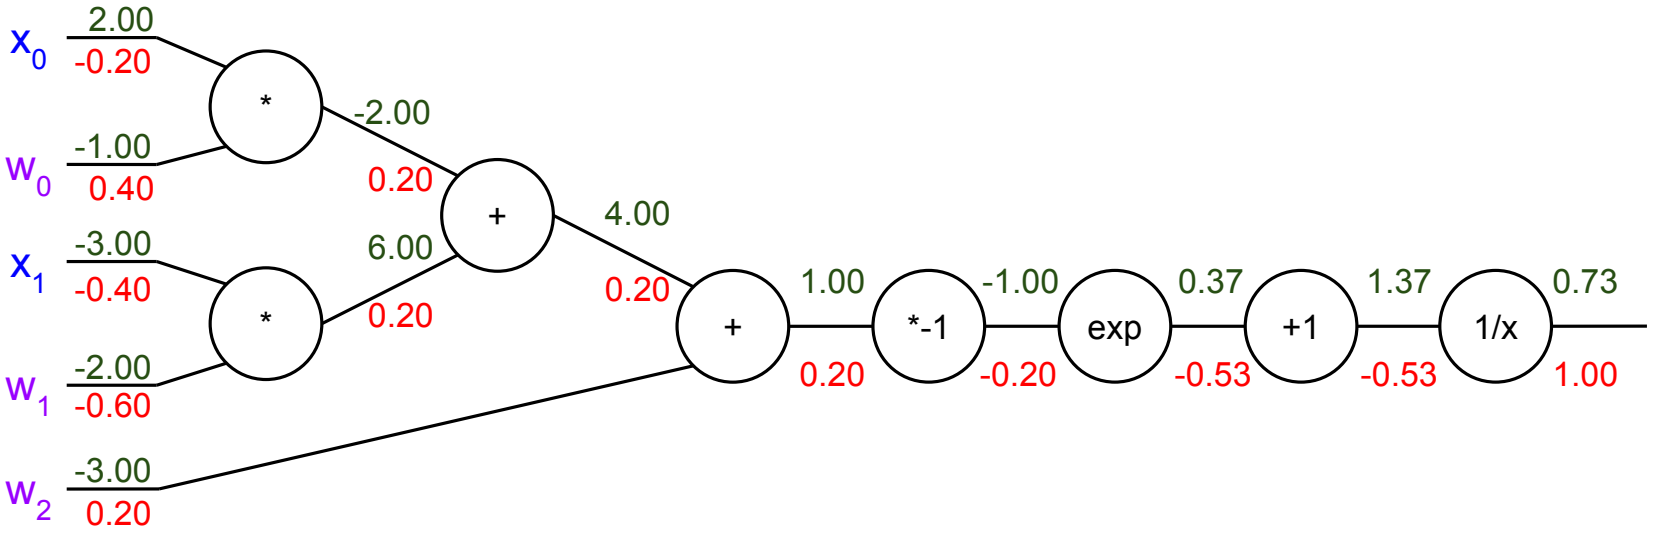

$$f(x) = e^x \quad \rightarrow \quad \frac{df}{dx} = e^x \qquad\qquad f(x) = \frac{1}{x} \quad \rightarrow \quad \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a \cdot x \quad \rightarrow \quad \frac{df}{dx} = a \qquad\qquad f(x) = x + c \quad \rightarrow \quad \frac{df}{dx} = 1$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

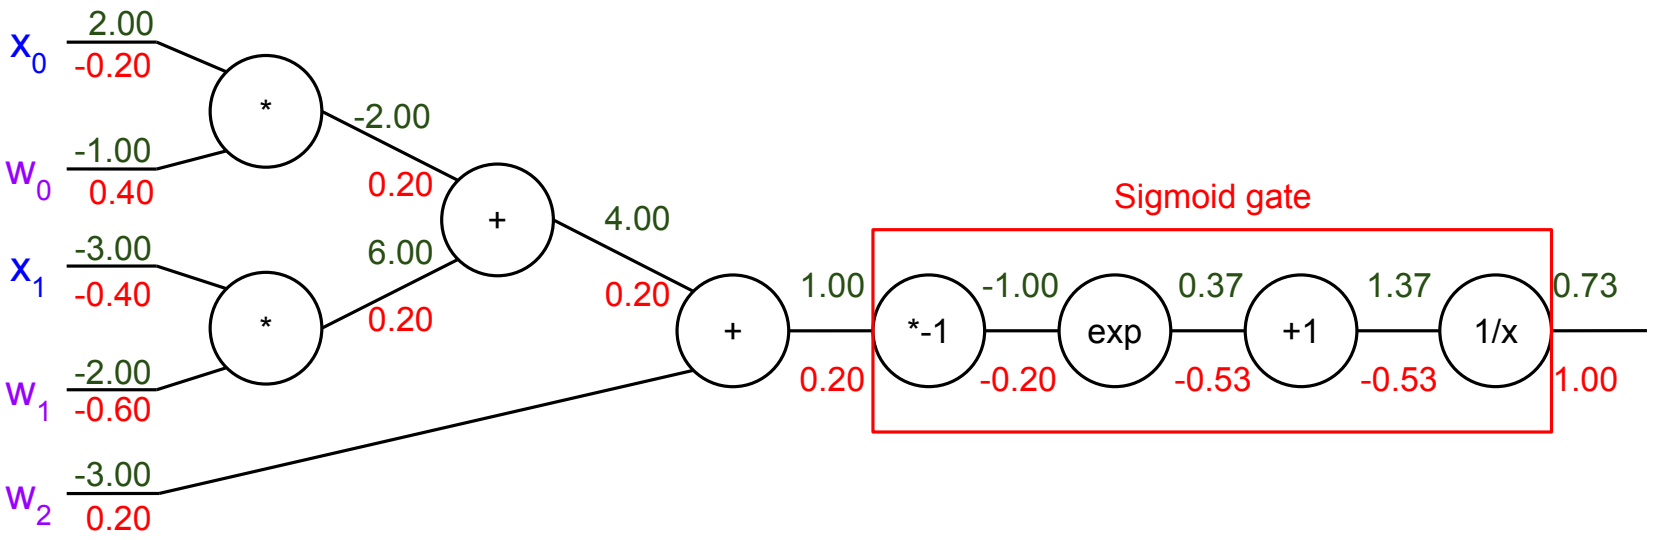

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

$$\frac{d\sigma(x)}{dx} = \frac{e^{-x}}{(1+e^{-x})^2} = \left(\frac{1}{1+e^{-x}}\right) \cdot \left(\frac{1+e^{-x}-1}{1+e^{-x}}\right) = \sigma(x) \cdot (1-\sigma(x))$$

Repasemos lo Anterior con un Ejemplo

$$f(w,x) = \frac{1}{1+e^{-(w_0 \cdot x_0 + w_1 \cdot x_1 + w_2)}}$$

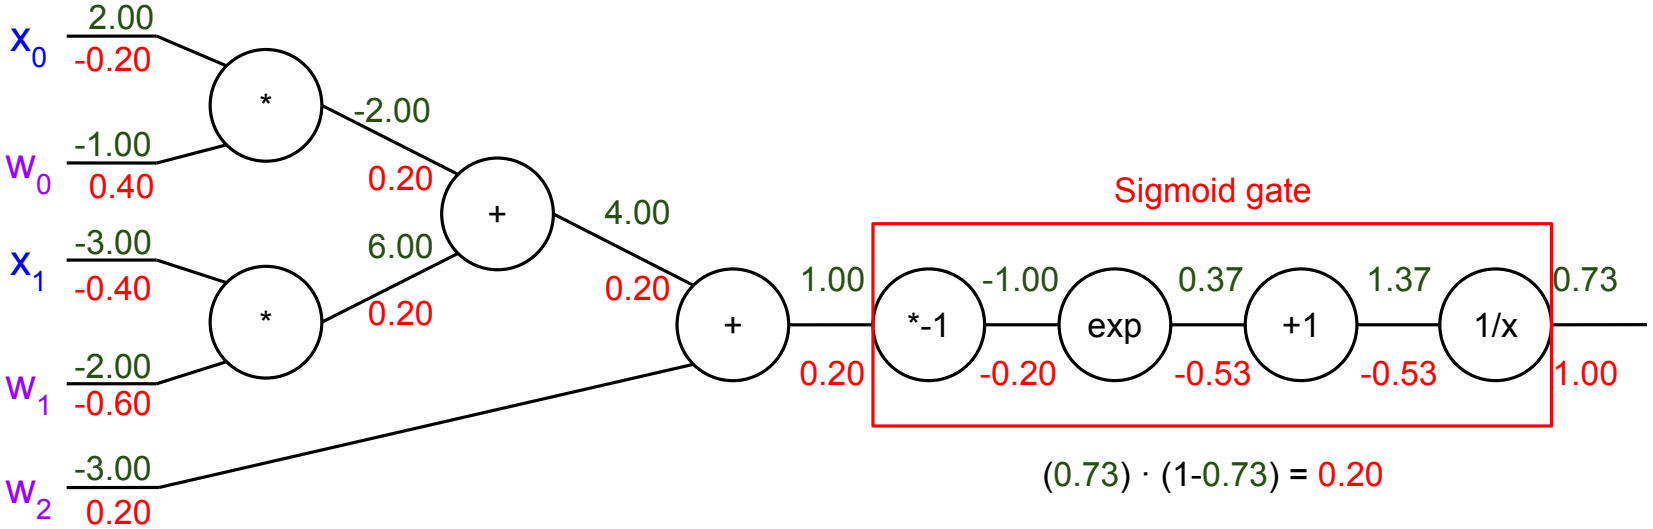

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

$$\frac{d\sigma(x)}{dx} = \frac{e^{-x}}{(1+e^{-x})^2} = \left(\frac{1}{1+e^{-x}}\right) \cdot \left(\frac{1+e^{-x}-1}{1+e^{-x}}\right) = \sigma(x) \cdot (1-\sigma(x))$$

Repasemos lo Anterior con un Ejemplo

En Resumen

- Nodos suma (+): gradiente pasa sin cambio
- Nodos producto (*): gradiente es multiplicado por el valor *opuesto*
- Nodos Sigmoide ($\sigma(x)$): Podemos expresar su gradiente en términos de su salida $\rightarrow \sigma(x) \cdot (1 - \sigma(x))$

Pontificia Universidad Católica de Chile
IA Lab

Grafos de Cómputo para Algoritmos de Aprendizaje

Gabriel Sepúlveda V.

IALab, Computer Science Department, PUC