ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

EDUCACIÓN PROFESIONAL

Otras Técnicas para Redes Profundas

ReLU - Dropout - Normalizaciones

Profesor:
Alain Raymond

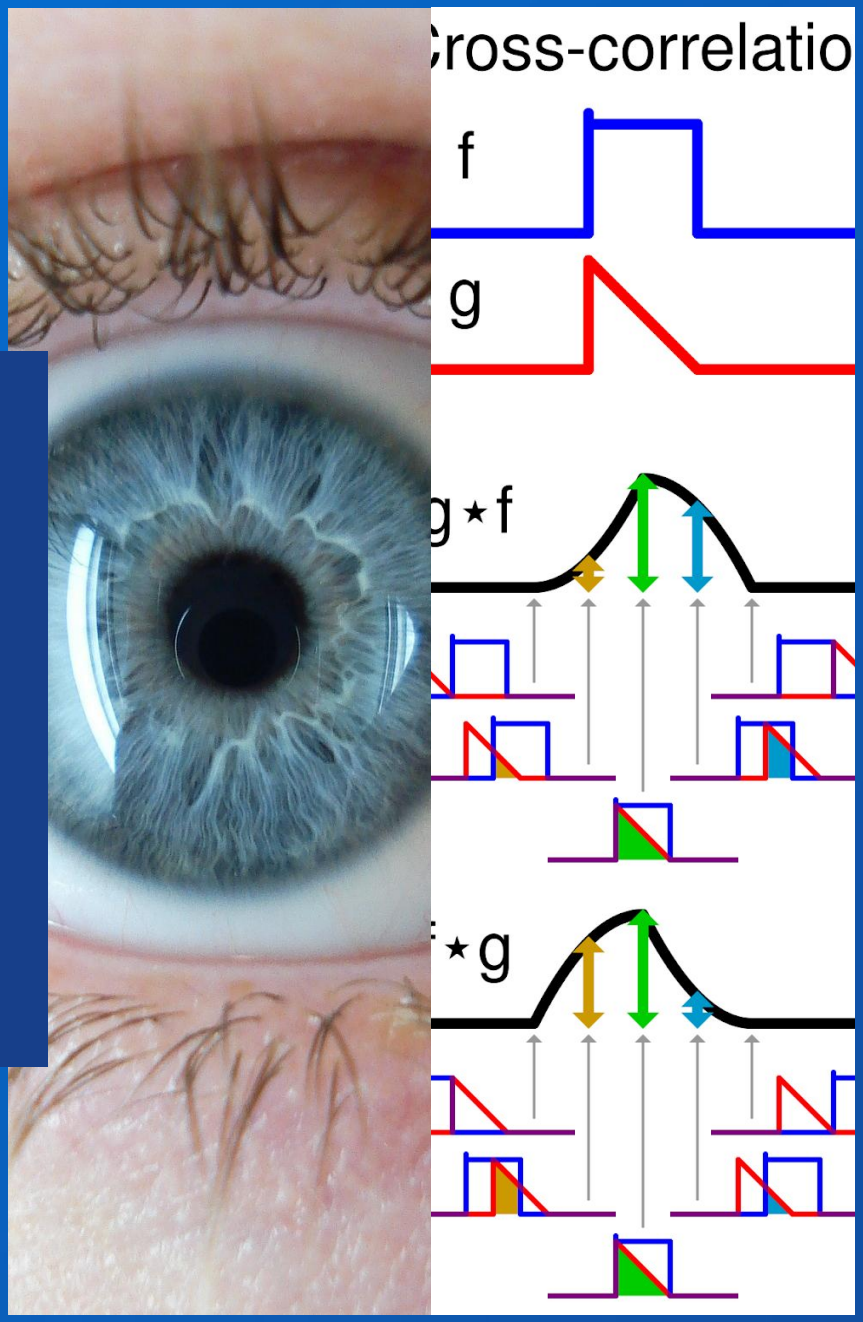

Agenda de Hoy

1. ReLU: nueva función de activación
2. Dropout
3. Normalizaciones durante entrenamiento: BatchNorm y LayerNorm

Una nueva función de Activación para Redes Profundas

- La función Sigmoide y otras similares usadas tradicionalmente presenta problemas:
  - **Saturación**: en sus extremos genera gradientes cercanos a 0, lo que ralentiza el aprendizaje.

Un ejemplo de función similar a Sigmoide.

Gradiente = Pendiente curva

¡SATURACIÓN!

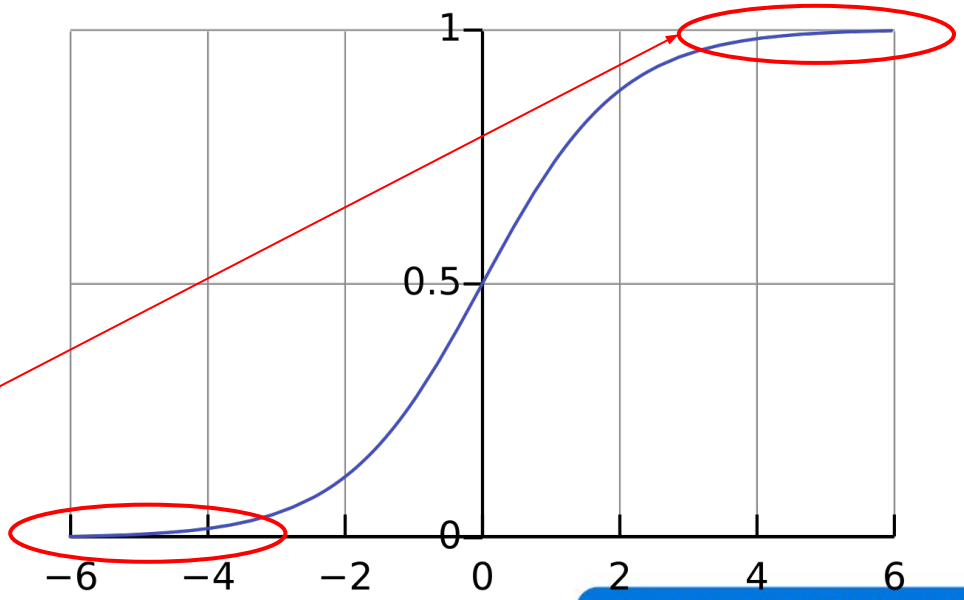

ReLU: Rectified Linear Unit

- ReLU fue un nuevo tipo de función de activación que tiene un par de ventajas.
  - Es muy fácil de computar, pues consiste en la función **ReLU(x) = Max(0, x)**
  - No se satura cuando la entrada es muy positiva.

Actualmente, la **función de activación más usada** o alguno de sus derivados: ELU, GELU, Leaky ReLU, etc.

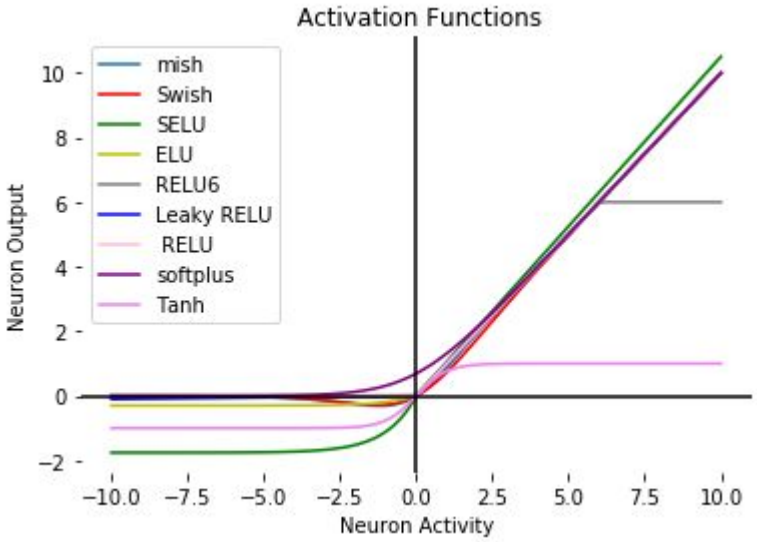

Dropout

- Dropout es una técnica de Regularización.
- Se agrega un módulo a la red que transforma la entrada:
  - En entrenamiento, para cada neurona de entrada con probabilidad ***p*** ésta es“ apagada” (su valor es 0).
  - En cada iteración, las neuronas que se apagan son distintas.
- Mejora rendimiento pero ralentiza el aprendizaje.

Nótese que en cada iteración apagar las neuronas es equivalente a eliminar conexiones entre neuronas.

Como si fuese una **arquitectura ligeramente distinta**…

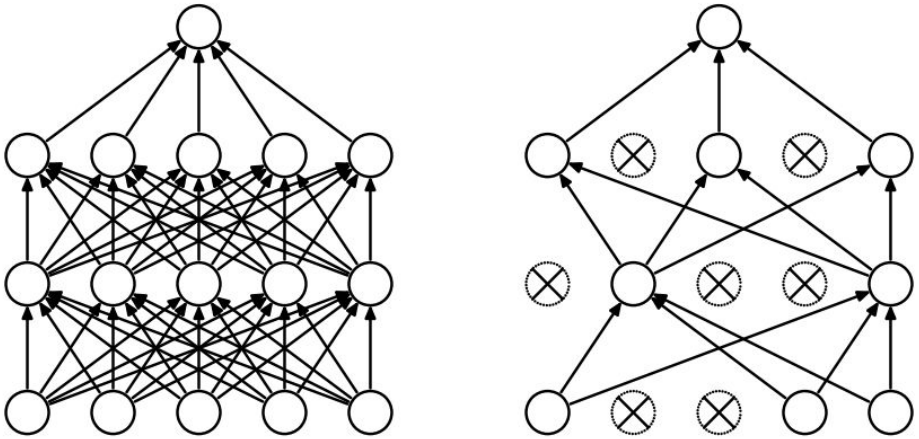

(a) Standard Neural Net (b) After applying dropout.

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). *Dropout: A simple way to prevent neural networks from overfitting*. Journal of Machine Learning Research, 15(56), 1929–1958.

Dropout: ¿Por qué debiera funcionar?

- Primera intuición: **Teoría de Ensambles**
  - Usar varios modelos distintos para resolver una tarea suele ayudar en generalización.
  - ¡Entre más modelos mejor! ⇒ ¡CARO!
  - Cada vez que apagamos neuronas al azar, estamos trabajando con una arquitectura ligeramente distinta.

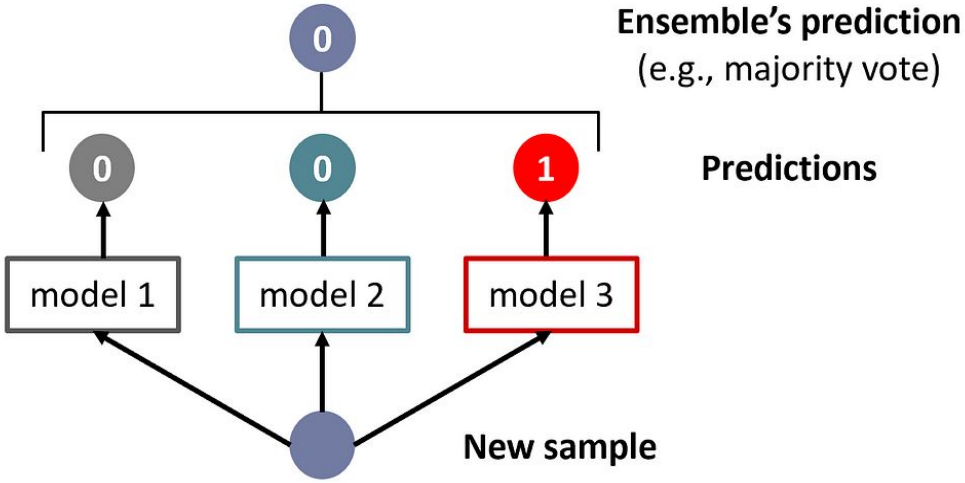

Dropout simula de alguna manera trabajar con un **ensamble potencialmente de infinitos modelos.**

Dropout: ¿Por qué debiera funcionar?

- Segunda intuición:
  - Dificulta la tarea.
    - Fomenta el aprendizaje de características más robustas.
    - No sólo me baso en un tipo de característica para predecir, porque puede ser que no esté disponible en entrenamiento.

Dropout: ¿Cómo funciona en inferencia?

- ¿Tengo que apagar neuronas al azar cuando quiero ocupar el modelo para predecir?
  - Suena que me estoy disparando en el pie…
- ¡NO! Dropout opera distinto en entrenamiento que en inferencia.
  - En inferencia queremos aprovechar toda la información.
  - Sin embargo, el modelo no está acostumbrado a que TODA la información esté disponible.
  - Para eso, lo que se hace es multiplicar el output de la entrada por ***p.***
    - ***La magnitud de información esperado se mantenga igual que en entrenamiento.***

Normalizaciones durante el Entrenamiento. Batch y Layer Normalization.

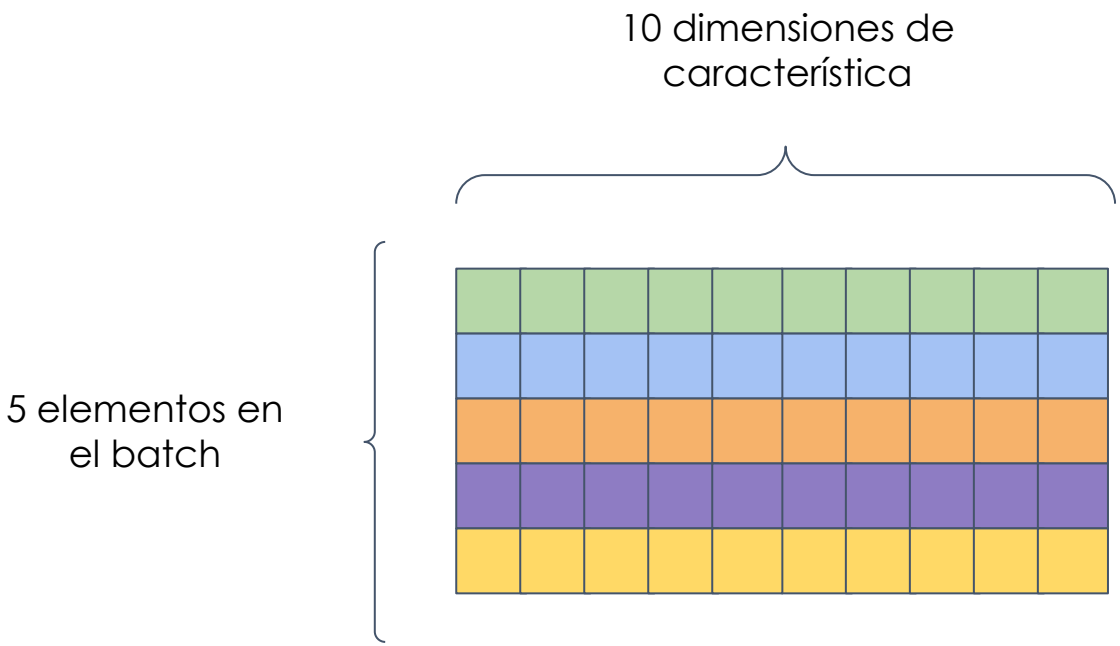

¿Qué es normalizar datos?

- Es transformar tus datos para que estén en una escala más fácil de manejar.
- Técnica usada usualmente en preprocesamiento de datos y en estadística.
- Una forma común es la normalización Z-score, que convierte los datos para que tengan media = 0 y desviación estándar = 1.
- Para hacer eso lo que debes hacer es:

$$x_{norm} = \frac{x - \mu}{\sigma}$$

- Si tus datos ya tienen media = 0 y desviación estándar = 1, si quieres que ahora tengan una media $\boldsymbol{\mu}$ y desviación estándar $\boldsymbol{\sigma}$:

$$\hat{x} = x \cdot \sigma + \mu$$

Ioffe, S., & Szegedy, C. (2015). *Batch normalization: Accelerating deep network training by reducing internal covariate shift*. In F. Bach & D. Blei (Eds.), *Proceedings of the 32nd International Conference on Machine Learning* (pp. 448–456). PMLR.

Normalización: un ejemplo.

x1	x2
1.0	-3.0
3.0	-2.0
-2.0	-1.0
1.5	-2.0
5.0	1.0

Ioffe, S., & Szegedy, C. (2015). *Batch normalization: Accelerating deep network training by reducing internal covariate shift*. In F. Bach & D. Blei (Eds.), *Proceedings of the 32nd International Conference on Machine Learning* (pp. 448–456). PMLR.

Normalización: un ejemplo.

```
Cálculo de la Media y Desviación Estándar

Datos:
x1 = [1, 3, -2, 1.5, 5]
x2 = [-3, -2, -1, -2, 1]

Media:
μ_x1 = (1 + 3 + (-2) + 1.5 + 5) / 5 = 8.5 / 5 = 1.7
μ_x2 = (-3 + (-2) + (-1) + (-2) + 1) / 5 = -7 / 5 = -1.4

Desviación estándar muestral:
s_x1 = sqrt(((1 - 1.7)^2 + (3 - 1.7)^2 + (-2 - 1.7)^2 + (1.5 - 1.7)^2 + (5 - 1.7)^2) / 4)
     = sqrt((0.49 + 1.69 + 13.69 + 0.04 + 10.89) / 4)
     = sqrt(26.8 / 4) = sqrt(6.7) ≈ 2.59

s_x2 = sqrt(((-3 + 1.4)^2 + (-2 + 1.4)^2 + (-1 + 1.4)^2 + (-2 + 1.4)^2 + (1 + 1.4)^2) / 4)
     = sqrt((2.56 + 0.36 + 0.16 + 0.36 + 5.76) / 4)
     = sqrt(9.2 / 4) = sqrt(2.3) ≈ 1.52
```


Ioffe, S., & Szegedy, C. (2015). *Batch normalization: Accelerating deep network training by reducing internal covariate shift*. In F. Bach & D. Blei (Eds.), *Proceedings of the 32nd International Conference on Machine Learning* (pp. 448–456). PMLR.

Normalización: un ejemplo.

x_1	x_1 (norm)	x_2	x_2(norm)
1	$\frac{(1-1.7)}{2.61} = 0{,}27$	-3	$\frac{(-3+1.4)}{1.52} = 1{,}05$
3	$\frac{(3-1.7)}{2.61} = 0{,}50$	-2	$\frac{(-2+1.4)}{1.52} = 0{,}39$
-2	$\frac{(-2-1.7)}{2.61} = 1{,}42$	-1	$\frac{(-1+1.4)}{1.52} = 0{,}26$
1,5	$\frac{(1.5-1.7)}{2.61} = 0{,}08$	-2	$\frac{(-2+1.4)}{1.52} = 0{,}39$
5	$\frac{(5-1.7)}{2.61} = 1{,}27$	1	$\frac{(1+1.4)}{1.52} = 1{,}58$

Ioffe, S., & Szegedy, C. (2015). *Batch normalization: Accelerating deep network training by reducing internal covariate shift*. In F. Bach & D. Blei (Eds.), *Proceedings of the 32nd International Conference on Machine Learning* (pp. 448–456). PMLR.

Normalización: un ejemplo.

x1	x1 (norm)	x2	x2 (norm)
1.0	-0.27	-3.0	-1.05
3.0	0.5	-2.0	-0.39
-2.0	-1.42	-1.0	0.26
1.5	-0.08	-2.0	-0.39
5.0	1.27	1.0	1.58

Ioffe, S., & Szegedy, C. (2015). *Batch normalization: Accelerating deep network training by reducing internal covariate shift*. In F. Bach & D. Blei (Eds.), *Proceedings of the 32nd International Conference on Machine Learning* (pp. 448–456). PMLR.

Batch Normalization (BN)

- Datos son normalizados en la dimensión del batch.
  a. Primero, son normalizados a media = 0 y desviación estándar 1.
  b. Luego, son renormalizados para tener media = $\boldsymbol{\mu}$ y desviación estándar = $\boldsymbol{\sigma}$.
  c. $\boldsymbol{\mu}$ y $\boldsymbol{\sigma}$ son parámetros aprendidos por el módulo.
- Para poder usar BN en inferencia, el módulo guarda un histórico de medias y desviaciones estándar.

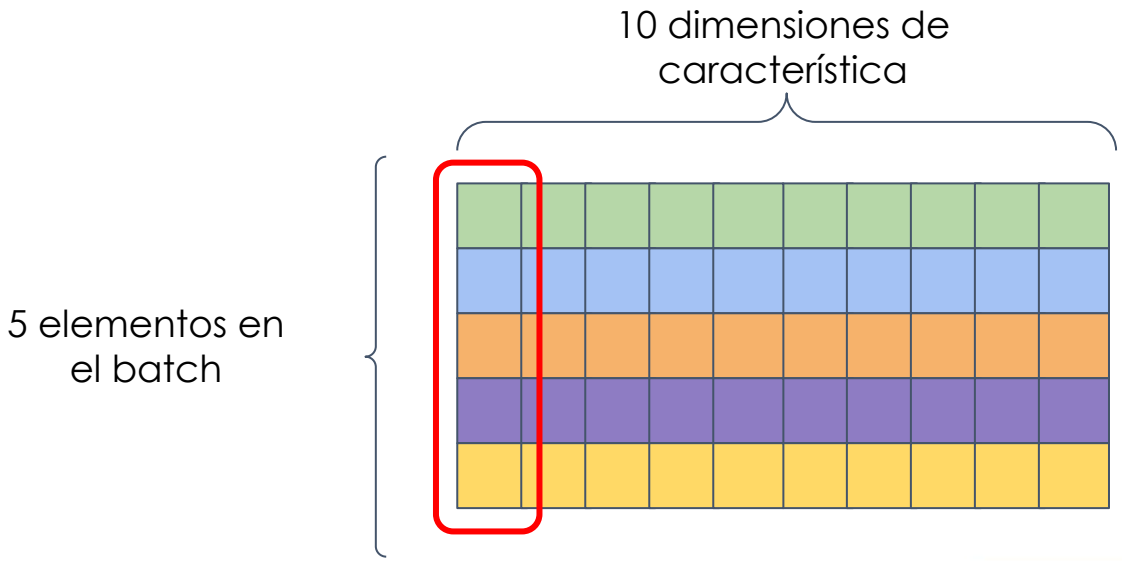

Ioffe, S., & Szegedy, C. (2015). *Batch normalization: Accelerating deep network training by reducing internal covariate shift*. In F. Bach & D. Blei (Eds.), *Proceedings of the 32nd International Conference on Machine Learning* (pp. 448–456). PMLR.

Layer Normalization (LN)

- Datos son normalizados en la dimensión de las características.
  a. Primero, son normalizados a media = 0 y desviación estándar 1.
  b. Luego, son renormalizados para tener media = $\boldsymbol{\mu}$ y desviación estándar = $\boldsymbol{\sigma}$.
  c. $\boldsymbol{\mu}$ y $\boldsymbol{\sigma}$ son parámetros aprendidos por el módulo.

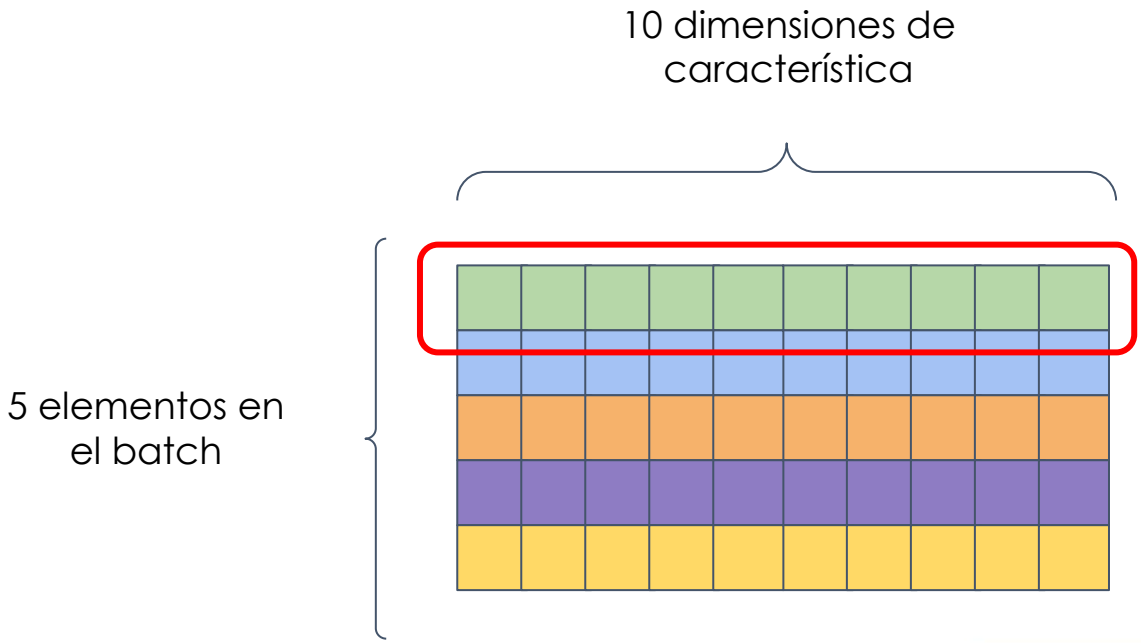

Ba, J. L., Kiros, J. R., & Hinton, G. E. (2016). *Layer normalization. arXiv preprint arXiv:1607.06450.*

Efectos de Normalizar

- Entrenamiento más rápido y de mayor calidad.
- LayerNorm ofrece ciertas ventajas para el entrenamiento de modelos de secuencias vs BatchNorm

Model	Steps to 72.2%	Max accuracy
Inception	$31.0 \cdot 10^6$	72.2%
BN-Baseline	$13.3 \cdot 10^6$	72.7%
BN-x5	$2.1 \cdot 10^6$	73.0%
BN-x30	$2.7 \cdot 10^6$	74.8%
BN-x5-Sigmoid		69.8%

Ambos métodos logran alcanzar niveles de rendimiento equivalentes en menos iteraciones. Además alcanzan mayor generalización.

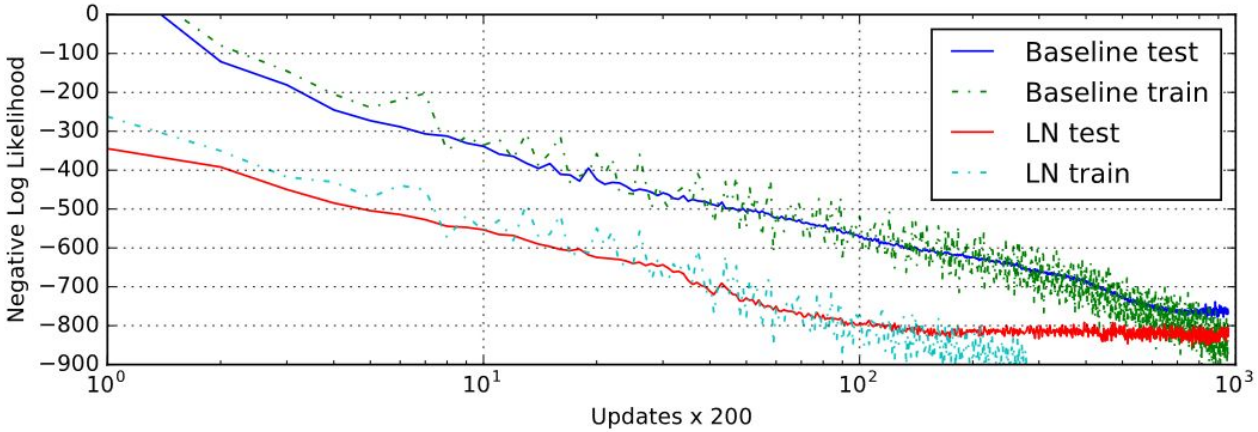

gure 5: Handwriting sequence generation model negative log likelihood with and without layer

ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

EDUCACIÓN PROFESIONAL

www.educacionprofesional.ing.uc.cl