



Pontificia Universidad Católica de Chile
Departamento de Ciencias de la Computación

Diplomado en Inteligencia Artificial

Clase 16

Introducción al Procesamiento de Lenguaje Natural (NLP)

Carlos Aspillaga



IA Lab



¿Qué estudiaremos en este curso?

Clase 1

Introducción a NLP

¿Qué es y por qué es una tarea difícil?

Aplicaciones

Técnicas clásicas

Herramientas concretas

Clase 2

Modelos de lenguaje

Modelos de Lenguaje

Representaciones Discretas v/s Continuas (Distribuidas)

W2V, GloVe

Clase 3

Modelos modernos

ELMo, GPT y BERT

Librería para usar estos modelos

Aplicaciones concretas

¿Qué estudiaremos en este curso?

Clase 4

Aplicaciones:
Generación de Resúmenes

Clase 5

Aplicaciones:
Modelos de Pregunta-Respuesta

Contenidos de la clase de hoy

1

Contexto

¿Qué es NLP?
¿Por qué es una tarea difícil?
Leyes del texto

2

Aplicaciones

Aplicaciones clásicas
Usos en la industria moderna

3

Técnicas clásicas

Eliminación de Stop-Words
Stemming y Lematización
N-Grams
Bag of Words

4

Herramientas Concretas

Introducción
Trabajo práctico

Contenidos de la clase de hoy

1

Contexto

¿Qué es NLP?
¿Por qué es una tarea difícil?
Leyes del texto

2

Aplicaciones

Aplicaciones clásicas
Usos en la industria moderna

3

Técnicas clásicas

Eliminación de Stop-Words
Stemming y Lematización
N-Grams
Bag of Words


4

Herramientas Concretas

Introducción
Trabajo práctico

Procesamiento de Lenguaje Natural ¿Qué es?


Intersección de 3 disciplinas



Objetivo: “Entender” el lenguaje para poder resolver tareas útiles.

Procesamiento de Lenguaje Natural ¿Qué es?

Objetivo: “Entender” el lenguaje para poder resolver tareas útiles.



clasificación

Soporte Técnico

Felicitaciones

Reclamos

Ventas

Servicio al Cliente

¡Demasiado trabajo hacerlo manualmente!

Procesamiento de Lenguaje Natural ¿Qué es?

Objetivo: “Entender” el lenguaje para poder resolver tareas útiles.




predicción
→




¡Demasiado complejo para hacerlo manualmente!

Procesamiento de Lenguaje Natural ¿Qué es?

Objetivo: “Entender” el lenguaje para poder resolver tareas útiles.



¡Queremos evitar hacerlo manualmente!



¿Por qué el NLP es una tarea difícil?

Lenguaje humano es ambiguo

¡Derecho al trabajo!

Delincentes hicieron seguimiento a vehículo

Impiden robo a camión Backus buscando botín de 30 mil

●TALARA. Cinco sujetos provistos con armas de fuego intentaron asaltar un camión distribuidor de la zona.



— Mi hijo está practicando natación.
— ¿Y qué tal le va?
— Nada mal.

LLEGARÁN CANTANTES DE OTROS PAÍSES

Gianmarco festejará sus 20 años cantando

LIMA. Un espectáculo diseñado con la más moderna tecnología en iluminación, en un escenario de 53 metros, ofrecerá el 17 de agosto el cantautor Gianmarco

mera vez una cumbia titulada "Al ritmo de mi corazón".

ACOMPAÑANTES. Las figuras internacionales que acompañan-

El mejor chef del mundo elabora bombones con niños tinerfeños

Fernán Adriá desamalgamó en Santa Cruz de la mano de CacaoBank y el Ayuntamiento, una hermosa jornada cultural que incluyó con la presentación de 400 bombones de su guía para emprendedores y prosiguió con una clase de cocina para 200 niños en el Auditorio

Cuente en la Cocina

Fernán Adriá



Los funcionarios mantienen su convocatoria de huelga en diciembre

La CEOE retiró su propuesta de abaratar el despido en 45 minutos

Madrid La propuesta de reforma laboral que la patronal trasladó el lunes a los sindicatos ha quedado reducida a la mitad. UGT y CC-OO reconocieron ayer que la medida más agresiva de los empresarios, la eliminación del despido impro-

dente, se retiró de la mesa el mismo día que se había presentado. Los sindicatos criticaron el lunes duramente esta propuesta sin aclarar que se había desmarcado. Por otra parte, los funcionarios mantendrán la huelga general de diciembre al fracasar ayer la negociación con el Gobierno.

Escríbele cartas a las personas que odias, y luego las quemas

¿Por qué el NLP es una tarea difícil?
Puede involucrar señales combinadas



¿Por qué el NLP es una tarea difícil?
Puede requerir conocimiento adicional

Common Sense

**Un muerto y tres
motoristas,
heridos en varios
accidentes**

MADRID.— Dos jóvenes **motoris-**
tas resultaron gravemente heri-
dos aver tras colisionar la moto-

Grounding al mundo físico

*The trophy cannot fit in the
suitcase because it is too big*

Conocimiento del contexto




Muere la cerda de Miley Cyrus
frml.tv/93838




Leyes del texto

Ley de Zipf




Leyes del texto

Stop-Words v/s Key-Words



Leyes del texto

Ley de Heaps / Ley de Herdan



Contenidos de la clase de hoy

1

Contexto

¿Qué es NLP?
¿Por qué es una tarea difícil?
Leyes del texto

2

Aplicaciones

Aplicaciones clásicas
Usos en la industria moderna

3

Técnicas clásicas

Eliminación de Stop-Words
Stemming y Lematización
N-Grams
Bag of Words

4


Herramientas Concretas

Introducción
Trabajo práctico

Aplicaciones de NLP

¿Qué se puede hacer con esta tecnología?

Part-of-Speech Tagging
(POS tagging)



No es una tarea trivial. Ej: la palabra "play"



Existen sistemas que alcanzan exactitudes $\approx 98\%$ en esta tarea

Nota: Para ver los "tipos" que existen por defecto en el modelo preentrenado de Spacy, pueden revisar <https://spacy.io/models/en> (inglés) o <https://spacy.io/models/es> (español), dentro de la sección "Label Scheme".

Aplicaciones de NLP

¿Qué se puede hacer con esta tecnología?

Parsing





Existen sistemas que alcanzan exactitudes $\approx 96\%$ en esta tarea

Nota: Para ver los “tipos” que existen por defecto en el modelo preentrenado de Spacy, pueden revisar <https://spacy.io/models/en> (inglés) o <https://spacy.io/models/es> (español), dentro de la sección “Label Scheme”.

Aplicaciones de NLP

¿Qué se puede hacer con esta tecnología?




Parsing



Aplicaciones de NLP

¿Qué se puede hacer con esta tecnología?


Parsing



Aplicaciones de NLP

¿Qué se puede hacer con esta tecnología?

Coreference Resolution



Aplicaciones de NLP

¿Qué se puede hacer con esta tecnología?

Named Entity Recognition (NER)

For most of their history on Wall Street, **LOC** computers have been strictly quantitative-dividing, say, prices by earnings and ranking the results. But that is destined to change. A dramatic demonstration of silicon's verbal potential came in **2011, Date** when an **IBM ORG** system called **Watson ORG** bested two human champions at Jeopardy! To accomplish this feat the computer had to grasp not just numbers but genealogical relationships, time, proximity, causality, taxonomy and a lot of other connections.

Last year **EquiBot ORG**'s software picked up a buzz around **Amarin Corp ORG**, an **Irish LOC** drug company with a prescription-only diet supplement that uses omega-3 fatty acids. The international ETF got in below **\$3, Price** well before the regulatory nod that sent the stock to **\$15 Price**. Another move involved adding **Visa ORG** to the domestic fund after the system measured ripples leading from announcements of chain-store closings toward higher credit card volume.


Nota 1: Para ver los “tipos” que existen por defecto en el modelo preentrenado de Spacy, pueden revisar <https://spacy.io/models/en> (inglés) o <https://spacy.io/models/es> (español), dentro de la sección “Label Scheme”.

Nota 2: Para entrenar un NER personalizado, pueden seguir este tutorial: <https://www.machinelearningplus.com/nlp/training-custom-ner-model-in-spacy/>

Aplicaciones de NLP

¿Qué se puede hacer con esta tecnología?

Sentiment Analysis



Loves the German bakeries in Sydney. Together with my imported honey it feels like home	Positive
@VivaLaLauren Mine is broken too! I miss my sidekick	Negative
Finished fixing my twitter...I had to unfollow and follow everyone again	Negative
@DinahLady I too, liked the movie! I want to buy the DVD when it comes out	Positive
@frugaldougal So sad to hear about @OscarTheCat	Negative
@Mofette brilliant! May the fourth be with you #starwarsday #starwars	Positive
Good morning thespians a bright and sunny day in UK, Spring at last	Positive
@DowneyisDOWNEY Me neither! My laptop's new, has dvd burning/ripping software but I just can't copy the files somehow!	Negative

Aplicaciones de NLP

¿Qué se puede hacer con esta tecnología?

Machine Translation

The screenshot displays a mobile application interface for 'ŪMANA HATU RE'O'. The app has a white header with the logo and a blue toggle switch. Below the header, there are tabs for 'Castellano', 'Rapa Nui', and 'Maori'. The 'Castellano' tab is selected, and the text in the main area reads: 'Visibilizar la problemática de la basura oceánica es parte de la vida cotidiana en Rapa Nui: las limpiezas costeras semanales han dado origen a obras completas realizadas con desechos marinos o bien, inspiradas en este momento histórico que estamos viviendo como humanidad.' A blue circular button with a refresh icon is positioned to the right of the text. The right side of the app is a blue panel with the 'Rapa Nui' tab selected. It displays the translated text: 'pau rō te mahana a mātou haka tikea i te 'ati nei o te iŋo-iŋo hoa i roto i te Moana Nui: te haka ma'itaki o te taha-tahatai pau rō te tāpati ko rova'a 'ā i te rāve'a 'āpi hai iŋo-iŋo o te vaikava 'ō, mo mana'u haka 'ou ki te ta'u ku'i-ku'i nei e ora nei tātou pa he tarata i runa i te ao'. At the bottom of the blue panel, there is a question '¿Qué te ha parecido esta traducción?' followed by thumbs up and thumbs down icons.

ŪMANA HATU RE'O

Castellano Rapa Nui Maori

Visibilizar la problemática de la basura oceánica es parte de la vida cotidiana en Rapa Nui: las limpiezas costeras semanales han dado origen a obras completas realizadas con desechos marinos o bien, inspiradas en este momento histórico que estamos viviendo como humanidad.

Rapa Nui Castellano Maori

pau rō te mahana a mātou haka tikea i te 'ati nei o te iŋo-iŋo hoa i roto i te Moana Nui: te haka ma'itaki o te taha-tahatai pau rō te tāpati ko rova'a 'ā i te rāve'a 'āpi hai iŋo-iŋo o te vaikava 'ō, mo mana'u haka 'ou ki te ta'u ku'i-ku'i nei e ora nei tātou pa he tarata i runa i te ao

¿Qué te ha parecido esta traducción?

Aplicaciones de NLP

¿Qué se puede hacer con esta tecnología?

Natural Language Processing



▶ See all 312 tasks

¡Muchas otras aplicaciones más!

Fuente: <https://paperswithcode.com/sota>

Contenidos de la clase de hoy

1

Contexto

¿Qué es NLP?
¿Por qué es una tarea difícil?
Leyes del texto

2

Aplicaciones

Aplicaciones clásicas
Usos en la industria moderna

3

Técnicas clásicas

Eliminación de Stop-Words
Stemming y Lematización
N-Grams
Bag of Words

4

Herramientas Concretas

Introducción
Trabajo práctico


Técnicas clásicas de NLP

¿Por qué es importante conocer el approach clásico?

- **Rápido** de implementar (y usar).
- Requiere significativamente **menos recursos** para entrenar y usar.
- Requiere significativamente **menos datos** para entrenarse.
- En muchos casos (tal vez la mayoría) es **suficiente**.
- Muchas veces entrega resultados más **interpretables**.


“
DON'T USE A
CANNON
TO KILL A FLY.”

~ CONFUCIUS



Técnicas clásicas de NLP

Eliminación de Stop-Words




Donald Trump es el 47vo y actual presidente de los Estados Unidos

Donald Trump 47vo actual presidente Estados Unidos

Técnicas clásicas de NLP

Eliminación de Stop-Words



Donald Trump es el 47vo y actual presidente de los Estados Unidos

Donald Trump 47vo actual presidente Estados Unidos

Opción 1: Definir un umbral y seleccionar las palabras a descartar según aquellas palabras con frecuencias mayores al umbral en el corpus de referencia.

Opción 2: Usar un listado predefinido de “stop-words”.

```
import nltk
nltk.download('stopwords')
from nltk.corpus import stopwords
print(stopwords.words('spanish'))
```

```
['de', 'la', 'que', 'el', 'en', 'y', 'a', 'los',  
'del', 'se', 'las', 'por', 'un', 'para', 'con',  
'no', 'una', 'su', 'al', 'lo', 'como', 'más',  
'pero', 'sus', 'le', 'ya', 'o', 'este', 'sí',  
'porque', 'esta', 'entre', 'cuando', 'muy', 'sin',  
'sobre', 'también', 'me', 'hasta', 'hay', 'donde',  
'quien', 'desde', 'todo', 'nos', 'durante', ...]
```

Técnicas clásicas de NLP

Stemming

interpretation
interpreted
interprets
interpreting
...
interpretable

} interpret

Input: Artificial intelligence is intelligence demonstrated by machines. Leading AI textbooks define the field as the study of intelligent agents: any device that perceives its environment and takes actions that maximize its chance of successfully achieving its goals.


Porter: artificial intelligence is intelligence demonstrated by machines. leading AI textbook defines the field as the study of intelligent agent: any device that perceives its environment and takes action that maximizes its chance of successfully achieving its goal.

Paice/Lancaster: artificial intelligence is intelligence demonstrated by machines. leading AI textbook defines the field as the study of intelligent agent: any device that perceives its environment and takes action that maximizes its chance of successfully achieving its goal.

Lovins/Snowball: artificial intelligence is intelligence demonstrated by machines. leading AI textbook defines the field as the study of intelligent agent: any device that perceives its environment and takes action that maximizes its chance of successfully achieving its goal.

Técnicas clásicas de NLP

Lematización




Input: Artificial intelligence is intelligence demonstrated by machines. Leading AI textbooks define the field as the study of intelligent agents: any device that perceives its environment and takes actions that maximize its chance of successfully achieving its goals.

WordNet Lemmatizer: Artificial intelligence **be** intelligence **demonstrate** by **machine**. **Leading** AI textbook define the field **a** the study of **intelligent** **agent**: any device that **perceive** **it** environment and **take** **action** that maximize **it** chance of **successfully** **achieve** **it** goal.

Técnicas clásicas de NLP

Bag of Words (BoW)



Técnicas clásicas de NLP


Bag of Words (BoW)



Fuente imagen: Carnegie Mellon University

Técnicas clásicas de NLP

n-Grams



¡Con esto también podemos hacer Bag of n-Grams!

Contenidos de la clase de hoy

1

Contexto

¿Qué es NLP?
¿Por qué es una tarea difícil?
Leyes del texto

2

Aplicaciones

Aplicaciones clásicas
Usos en la industria moderna

3

Técnicas clásicas

Eliminación de Stop-Words
Stemming y Lematización
N-Grams
Bag of Words

4

Herramientas Concretas

Introducción
Trabajo práctico

Herramientas de NLP
¡Existen muchas opciones!



AllenNLP



spaCy





Pontificia Universidad Católica de Chile
Departamento de Ciencias de la Computación

Diplomado en Inteligencia Artificial

Clase 16

Introducción al Procesamiento de Lenguaje Natural (NLP)

Carlos Aspillaga



IA Lab

