



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

EDUCACIÓN
PROFESIONAL

Diplomado en Inteligencia Artificial

Tópicos de profundización

Aprendizaje autosupervisado

Sebastián Amenábar (samenabar@uc.cl)



- Deep Learning funciona extraordinariamente bien **cuando tenemos muchos datos etiquetados**
 - ¿Costo de etiquetado?
 - ¿Consistencia de etiquetas?
 - ¿Nivel de detalle de las etiquetas?
- En cambio los humanos no usamos tantas etiquetas para aprender
 - Por ejemplo, Clerkin y Smith (2019) reportan que en 17 horas de video durante la hora de comida de niños entre 7-11 meses:
 - Se menciona el nombre de 351 objetos distintos 1.941 veces (5,5 veces c/u en promedio).
 - Pero de esos objetos, 213 nunca son mencionados al mismo tiempo que el niño tiene el objeto en su campo de visión



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

Motivación

EDUCACIÓN
PROFESIONAL

*“The **brain has about 10^{14} synapses** and we only **live for about 10^9 seconds**. So we have a lot more parameters than data. This motivates the idea that **we must do a lot of unsupervised learning** since the perceptual input (including proprioception) is the only place we can get 10^5 dimensions of constraint per second.”*

— Geoffrey Hinton 2014 Reddit AMA



Motivación

La mayoría del aprendizaje en humanos es sin supervisión

■ "Pure" Reinforcement Learning (cherry)

- ▶ The machine predicts a scalar reward given once in a while.
- ▶ **A few bits for some samples**

■ Supervised Learning (icing)

- ▶ The machine predicts a category or a few numbers for each input
- ▶ Predicting human-supplied data
- ▶ **10→10,000 bits per sample**

■ Unsupervised/Predictive Learning (cake)

- ▶ The machine predicts any part of its input for any observed part.
- ▶ Predicts future frames in videos
- ▶ **Millions of bits per sample**





ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

EDUCACIÓN
PROFESIONAL

Autosupervisión

Generar de manera automática el output que debe predecir el modelo



En esta clase

1. Autosupervisión para aprender representaciones

a. Tareas de predicción

i. Autoencoders

- ii. Otras tareas de predicción en imágenes
- iii. En lenguaje

b. Utilizando multimodalidad

- i. Audio-Visión

c. Utilizando transformaciones


- i. Rotación
- ii. Contrastive Learning

2. Autosupervisión para potenciar el aprendizaje supervisado



Autosupervisión con predicción

- Predecir una parte del input a partir de cualquier otra parte
- Predecir el **futuro** a partir del **pasado**
- Predecir partes **ocultas** a partir de las **visibles**






Autoencoders

- Red compuesta de dos partes:
 - Un encoder codifica el input en un **código** de menor tamaño
 - Un decoder que partir de ese **código reconstruye** el input
- La reconstrucción fuerza a que el código sea descriptivo del input
- El cuello de botella fuerza a que el código tenga un mayor nivel semántico

Mayor compresión, mayor nivel semántico
→



→
Reconstrucción de la entrada



Autoencoders

- Para medir la reconstrucción se calcula un error pixel a pixel
- Si la entrada es una imagen (I) de $50 \times 50 \times 3$, la salida ($\hat{I}$) es del mismo tamaño
- Las funciones de pérdida comúnmente usadas:

- Error cuadrático medio (MSE):

$$\sum_{(h,w,c) \in H \times W \times C} \frac{1}{2} (\text{reconstruccion}(I)[h, w, c] - I[h, w, c])^2$$

- Valor absoluto o norma $L1$:

$$\sum_{(h,w,c) \in H \times W \times C} |(\text{reconstruccion}(I)[h, w, c] - I[h, w, c])|$$

- En general estas dos obtienes resultados muy similares
- Estas son pérdidas conservadoras: tienden a predecir valores promedio por lo que pierden los detalles



Autoencoders



- ¿De qué sirve el autoencoder o la auto-supervisión?
 - Uno de sus usos es para transfer learning, inicializar un modelo con conocimiento mejor que aleatorio, sin necesidad de tener un gran dataset etiquetado

Inicialización pesos	Rendimiento
Aleatoria	53.3
Autoencoder	53.8
Pre Entrenamiento ImageNet	79.9

Evaluación de fine-tuning con distinta inicialización de pesos en dataset PASCAL VOC 2007 de clasificación de imágenes. Dataset con 20 clases y 9.963 imágenes



Otros ejemplos de auto-predicción en imágenes



Inpainting - Patak et al. 2016

- Oculta una parte de la imagen que debe ser reconstruida
- El modelo debe tener un mayor entendimiento para poder cumplir esta tarea

Colorización - Zhang et al. 2016

- A partir de la imagen en escala de grises generar los colores de la imagen

Posicionamiento relativo - Doersch et al. 2016

- Dos redes convolucionales con pesos compartidos, cada una recibe un parche de la imagen y el objetivo es predecir en cuál de las 8 posiciones posible está ubicado un parche con respecto al otro



Otros ejemplos de auto-predicción en imágenes


Inicialización pesos	Rendimiento
Inicialización aleatoria	53.3
Autoencoder	53.8
Inpainting	56.5
Posicionamiento relativo	65.3
Colorización (grises)	65.9
Colorización (color)	65.6
Pre Entrenamiento ImageNet	79.9

Evaluación de fine-tuning con distinta inicialización de pesos en dataset PASCAL VOC 2007 de clasificación de imágenes. Dataset con 20 clases y 9.963 imágenes



Qué se aprende?



Secciones más cercanas para tarea posicionamiento relativo







Autosupervisión en lenguaje

BERT Masked Language Modelling (MLM)




GPT Next Token Prediction (NTP)



En BERT cada token puede mirar (realizar atención) al futuro y al pasado

En GPT cada token solo puede mirar a los anteriores





En esta clase

1. Autosupervisión para aprender representaciones

- a. Tareas de predicción
 - i. Autoencoders
 - ii. Otras tareas de predicción en imágenes
 - iii. En lenguaje
- b. **Utilizando multimodalidad**
 - i. **Audio-Visión**
- c. Utilizando transformaciones
 - i. Rotación
 - ii. Contrastive Learning



2. Autosupervisión para potenciar el aprendizaje supervisado



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

Correspondencia Audio-Visual

EDUCACIÓN
PROFESIONAL





ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

Correspondencia Audio-Visual

EDUCACIÓN
PROFESIONAL

Utilizando este modelo se pueden buscar imágenes a partir de audio, o audio a partir de imágenes

Query
frame



Top 10 ranked audio clips



Query




Audio-to-image retrieval: Top 5 retrieved results






Correspondencia Audio-Visual



Modificando un poco la arquitectura podemos saber **en qué parte** está el objeto que produce el sonido






En esta clase

1. Autosupervisión para aprender representaciones

- a. Tareas de predicción
 - i. Autoencoders
 - ii. Otras tareas de predicción en imágenes
 - iii. En lenguaje
- b. Utilizando multimodalidad
 - i. Audio-Visión
- c. **Utilizando transformaciones**
 - i. **Rotación**
 - ii. Contrastive Learning

2. Autosupervisión para potenciar el aprendizaje supervisado

Rotaciones para autosupervisión




Unsupervised representation learning by predicting image rotations,
Spyros Gidaris, Praveer Singh, Nikos Komodakis, ICLR 2018

Rotaciones para autosupervisión

	Classification (%mAP)	
Trained layers	fc6-8	all
ImageNet labels	78.9	79.9
Random		53.3
Random rescaled Krähenbühl et al. (2015)	39.2	56.6
Egomotion (Agrawal et al., 2015)	31.0	54.2
Context Encoders (Pathak et al., 2016b)	34.6	56.5
Tracking (Wang & Gupta, 2015)	55.6	63.1
Context (Doersch et al., 2015)	55.1	65.3
Colorization (Zhang et al., 2016a)	61.5	65.6
BIGAN (Donahue et al., 2016)	52.3	60.1
Jigsaw Puzzles (Noroozi & Favaro, 2016)	-	67.6
NAT (Bojanowski & Joulin, 2017)	56.7	65.3
Split-Brain (Zhang et al., 2016b)	63.0	67.1
ColorProxy (Larsson et al., 2017)		65.9
Counting (Noroozi et al., 2017)	-	67.7
(Ours) RotNet	70.87	72.97

Accuracy en clasificación PASCAL VOC 2007




(a) Supervised



(b) Self-supervised to recognize rotations

Filtros aprendidos por entrenamiento supervisado (izquierda) vs. autosupervisión de rotación (derecha).

Contrastive Learning



La representación de una imagen debe ser más **cercana** a ella misma transformada, **ejemplo positivo**, (rotada, crop, saturación color, etc), que a otra imagen distinta, **ejemplo negativo**



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA


SimCLR

EDUCACIÓN
PROFESIONAL



Momentum Contrast (MoCo)

- Hay dos redes, un **encoder** y un **momentum encoder**
 - Solo fluye gradiente por el encoder y el momentum encoder es actualizado mediante momentum
- Para cada imagen se produce un par de dos aumentaciones y una aumentación es procesada por el encoder y la otra por el momentum encoder, estos serán los ejemplos positivos
- Hay una cola FIFO con K embeddings de imágenes previas que son usados como ejemplos negativos
- Ya que no fluye gradiente por las codificaciones de la cola, se puede comparar con miles de imágenes con menor requerimiento de memoria en comparación a SimCLR





SimCLR vs MoCo

Algorithm 1 SimCLR's main learning algorithm.

input: batch size N , constant τ , structure of $f, g, \mathcal{T}$.
for sampled minibatch $\{\mathbf{x}_k\}_{k=1}^N$ **do**
 for all $k \in \{1, \dots, N\}$ **do**
 draw two augmentation functions $t \sim \mathcal{T}, t' \sim \mathcal{T}$
 # the first augmentation
 $\tilde{\mathbf{x}}_{2k-1} = t(\mathbf{x}_k)$
 $\mathbf{h}_{2k-1} = f(\tilde{\mathbf{x}}_{2k-1})$ # representation
 $\mathbf{z}_{2k-1} = g(\mathbf{h}_{2k-1})$ # projection
 # the second augmentation
 $\tilde{\mathbf{x}}_{2k} = t'(\mathbf{x}_k)$
 $\mathbf{h}_{2k} = f(\tilde{\mathbf{x}}_{2k})$ # representation
 $\mathbf{z}_{2k} = g(\mathbf{h}_{2k})$ # projection
 end for
 for all $i \in \{1, \dots, 2N\}$ and $j \in \{1, \dots, 2N\}$ **do**
 $s_{i,j} = \mathbf{z}_i^T \mathbf{z}_j / (\|\mathbf{z}_i\| \|\mathbf{z}_j\|)$ # pairwise similarity
 end for
 define $\ell(i, j)$ **as** $\ell(i, j) = -\log \frac{\exp(s_{i,j}/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(s_{i,k}/\tau)}$
 $\mathcal{L} = \frac{1}{2N} \sum_{k=1}^N [\ell(2k-1, 2k) + \ell(2k, 2k-1)]$
 update networks f and g to minimize $\mathcal{L}$
end for
return encoder network $f(\cdot)$, and throw away $g(\cdot)$

Algorithm 1 Pseudocode of MoCo in a PyTorch-like style.

```
# f_q, f_k: encoder networks for query and key
# queue: dictionary as a queue of K keys (CxK)
# m: momentum
# t: temperature

f_k.params = f_q.params # initialize
for x in loader: # load a minibatch x with N samples
    x_q = aug(x) # a randomly augmented version
    x_k = aug(x) # another randomly augmented version

    q = f_q.forward(x_q) # queries: NxK
    k = f_k.forward(x_k) # keys: NxK
    k = k.detach() # no gradient to keys

    # positive logits: Nx1
    l_pos = bmm(q.view(N,1,C), k.view(N,C,1))

    # negative logits: NxK
    l_neg = mm(q.view(N,C), queue.view(C,K))

    # logits: Nx(1+K)
    logits = cat([l_pos, l_neg], dim=1)

    # contrastive loss, Eqn. (1)
    labels = zeros(N) # positives are the 0-th
    loss = CrossEntropyLoss(logits/t, labels)

    # SGD update: query network
    loss.backward()
    update(f_q.params)

    # momentum update: key network
    f_k.params = m*f_k.params+(1-m)*f_q.params

    # update dictionary
    enqueue(queue, k) # enqueue the current minibatch
    dequeue(queue) # dequeue the earliest minibatch
```



Detalles Importantes

- SimCLR alcanzó mejor rendimiento aumentando batch size hasta 4096 (muchas TPUs)
- MoCo tiene menos requisitos computacionales

Método	Top 1 Accuracy
Rotación	55.4
MoCo v1	60.2
SimCLR	69.3
MoCo v2	71.1
Entrenar con todos los labels	76.0


Evaluación de features en ImageNet
(clasificar lineal usando todos los labels)

	Top 5 con 1% labels	Top 5 con 10% labels
Sin preentrenamiento	48.4	80.4
SimCLR	75.5	91.2
Entrenando con todos los labels	93.1	

Evaluación en ImageNet con pocos labels

Contrastive Language-Image Pre-training (CLIP)


- Utiliza 400 millones de pares de texto-imagen
- El embedding de una imagen debe ser similar al embedding de su descripción






Contrastive Language-Image Pre-training (CLIP)

- Zero-shot: desempeño sin utilizar datos etiquetados a mano y seleccionando el texto más parecido a la imagen

DATASET	IMAGENET RESNET101	CLIP VIT-L
 ImageNet	76.2%	76.2%
 ImageNet V2	64.3%	70.1%
 ImageNet Rendition	37.7%	88.9%
 ObjectNet	32.6%	72.3%
 ImageNet Sketch	25.2%	60.2%
 ImageNet Adversarial	2.7%	77.1%

Contrastive Learning en otros dominios



- Dataset preentrenamiento 220.000 pares imagen-texto y tomó 3 días en una GPU Titan RTX (24GB)
- RSNA tiene 25.000 imágenes entrenamiento
- CheXpert tiene 220.000 imágenes entrenamiento
- COVIDx tiene 14.000 imágenes entrenamiento
- MURA tiene 33.000 imágenes entrenamiento

Method	RSNA (AUC)			CheXpert (AUC)			COVIDx (Accu.)		MURA (AUC)		
	1%	10%	all	1%	10%	all	10%	all	1%	10%	all
<i>General initialization methods</i>											
Random Init.	71.9	82.2	88.5	70.4	81.1	85.8	75.4	87.7	56.8	61.6	79.1
ImageNet Init.	83.1	87.3	90.8	80.1	84.8	87.6	84.4	90.3	72.1	81.8	87.0
<i>In-domain initialization methods</i>											
Caption-Transformer	86.3	89.2	92.1	81.5	86.4	88.2	88.3	92.3	75.2	83.2	87.6
Caption-LSTM	87.2	88.0	91.0	83.5	85.8	87.8	83.8	90.8	78.7	83.3	87.8
Contrastive-Binary	87.7	89.9	91.2	86.2	86.1	87.7	89.5	90.5	80.6	84.0	88.4
ConVIRT (Ours)	88.8	91.5	92.7	87.0	88.1	88.1	90.3	92.4	81.3	86.5	89.0





ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

Contrastive Learning en otros dominios


EDUCACIÓN
PROFESIONAL

Aprender métrica de distancia
utilizando imágenes que
corresponden a fotografías tomadas
en el mismo lugar a través del tiempo






Vision Transformer (ViT)






Masked Autoencoder (MAE)

- Reviviendo ideas de Denoising Autoencoder
- Tarea más adecuada a arquitectura de Transformer
 - No es trivial lidiar con los parches ocultos en un red convolucional
 - Ahorramos cómputo al procesar solamente información visible
- Funciona bien sin aumentaciones tan intensas





case	ft	lin
none	84.0	65.7
crop, fixed size	84.7	73.1
crop, rand size	84.9	73.5
crop + color jit	84.3	71.9

(e) **Data augmentation.** Our MAE works with minimal or no augmentation.





MAE en videos






En esta clase

1. Autosupervisión para aprender representaciones
 - a. Tareas de predicción
 - i. Autoencoders
 - ii. Otras tareas de predicción en imágenes
 - iii. En lenguaje
 - b. Utilizando multimodalidad
 - i. Audio-Visión
 - c. Utilizando transformaciones
 - i. Rotación
 - ii. Contrastive Learning
2. **Autosupervisión para potenciar el aprendizaje supervisado**



- Intuición bastante similar a contrastive learning, pero se usa como complemento cuando hay pocas etiquetas, por lo que es aprendizaje semi-supervisado
- El modelo debería realizar predicciones muy similares para un dato y ese mismo dato transformado
- Se agrega una regularización para que el modelo aprenda que debe cumplir esta **consistencia** en sus predicciones






- La salida del modelo es una distribución de probabilidad
- La KL divergencia es una métrica de la diferencia entre distribuciones de probabilidad. Toma valor 0 cuando son idénticas

$$KL (\text{Predicción imagen 1} , \text{Predicción imagen 2}) = \text{diff}$$







Fully supervised baseline							
Datasets (# Sup examples)	IMDb (25k)	Yelp-2 (560k)	Yelp-5 (650k)	Amazon-2 (3.6m)	Amazon-5 (3m)	DBpedia (560k)	
Pre-BERT SOTA	4.32	2.16	29.98	3.32	34.81	0.70	
BERT _{LARGE}	4.51	1.89	29.32	2.63	34.17	0.64	
Semi-supervised setting							
Initialization	UDA	IMDb (20)	Yelp-2 (20)	Yelp-5 (2.5k)	Amazon-2 (20)	Amazon-5 (2.5k)	DBpedia (140)
Random	✗	43.27	40.25	50.80	45.39	55.70	41.14
	✓	25.23	8.33	41.35	16.16	44.19	7.24
BERT _{BASE}	✗	18.40	13.60	41.00	26.75	44.09	2.58
	✓	5.45	2.61	33.80	3.96	38.40	1.33
BERT _{LARGE}	✗	11.72	10.55	38.90	15.54	42.30	1.68
	✓	4.78	2.50	33.54	3.93	37.80	1.09

Methods	SSL	10%
ResNet-50 w. RandAugment	✗	55.09 / 77.26 58.84 / 80.56
UDA (RandAugment)	✓	68.78 / 88.80

Top 1/Top 5 accuracy en ImageNet usando 10% de las etiquetas y los datos restantes como no etiquetados con la pérdida de UDA

Clasificación de texto usando back-translation para
aumentación



Resumen Aprendizaje Autosupervisado

- El output objetivo a predecir es generado automáticamente
- Nos ahorramos el costo de etiquetar
 - Puede llegar a ser más caro todavía si se necesitan profesionales (e.g. medicina)
- Aprender representaciones que pueden ser útiles para diversas tareas
- Luego de aprendidas, podemos usarlas para entrenar modelos con menos datos
 - (Tal como hemos hecho con features pre-entrenados)
- Podemos complementar el aprendizaje supervisado utilizando datos sin etiquetar
- Más que una solución común para todo, lo más importante es tener creatividad para diseñar formas distintas según las características del dominio en que va a ser utilizado



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

Más sobre Aprendizaje Autosupervisado

EDUCACIÓN
PROFESIONAL

- Tutorial OpenAI <https://www.youtube.com/watch?v=7l6fttRJzeU> (2021)
 - Presenta más técnicas, funciones de pérdida y en mayor profundidad
 - Duración 2 horas
- A Cookbook of Self-Supervised Learning <https://arxiv.org/abs/2304.12210> 2023
 - Presenta más técnicas, con fundamentos teóricos, y sugerencias sobre cómo entrenar efectivamente con SSL (aumento, batch size, hiperparámetros, evaluación, tiempo, etc.)
 - 45 páginas sin referencias
- Aprendizaje Semi-Supervisado
 - USB - Librería con distintas técnicas posteriores a UDA



Papers referenciados

- Pathak et al. 2016 - Context Encoders: Feature Learning by Inpainting <https://arxiv.org/abs/1604.07379>
- Zhang et al. 2016 - Colorful Image Colorization <https://arxiv.org/abs/1603.08511>
- Doersch et al. 2015 - Unsupervised Visual Representation Learning by Context Prediction <https://arxiv.org/abs/1505.05192>
- Mishra et al. 2016 - Shuffle and Learn: Unsupervised Learning using Temporal Order Verification <https://arxiv.org/abs/1603.08561>
- Arandjelovic et al. 2017 - Look, Listen and Learn <https://arxiv.org/abs/1705.08168>
- Arandjelovic et al. 2018 - Objects that Sound - <https://arxiv.org/abs/1712.06651>
- Li et al. 2019 - VisualBERT: A Simple and Performant Baseline for Vision and Language <https://arxiv.org/abs/1908.03557>
- Gidaris et al. 2018 - Unsupervised Representation Learning by Predicting Image Rotations <https://arxiv.org/abs/1803.07728>
- Ye et al. 2019 - Unsupervised Embedding Learning via Invariant and Spreading Instance Feature <https://arxiv.org/abs/1904.03436>
- Chen et al 2020 - A Simple Framework for Contrastive Learning of Visual Representations <https://arxiv.org/abs/2002.05709>
- He et al 2019 - Momentum Contrast for Unsupervised Visual Representation Learning <https://arxiv.org/abs/1911.05722>



Papers referenciados

- Chen et al. 2020 - Improved Baselines with Momentum Contrastive Learning <https://arxiv.org/abs/2003.04297>
- Zhang et al. 2020 - Contrastive Learning of Medical Visual Representations from Paired Images and Text <https://arxiv.org/abs/2010.00747>
- Radford et al. 2021 - Learning Transferable Visual Models From Natural Language Supervision <https://arxiv.org/abs/2103.00020>
- Xie et al. 2019 - Unsupervised Data Augmentation for Consistency Training <https://arxiv.org/abs/1904.12848>
- Dosovitskiy et al. 2021 - An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale <https://arxiv.org/abs/2010.11929>
- Stalder et al. 2023 - Self-supervised learning unveils change in urban housing from street-level images <https://arxiv.org/abs/2309.11354>
- He 2022 - Masked Autoencoders Are Scalable Vision Learners <https://arxiv.org/abs/2111.06377>
- Feichtenhofer 2022 - Masked Autoencoders As Spatiotemporal Learners <https://arxiv.org/abs/2205.09113>