



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

EDUCACIÓN
PROFESIONAL

Modelos Generativos en Visión por Computador

Profesor:


Francisca Cattán

fpcattan@uc.cl





"An expressive oil painting of a basketball player dunking, depicted as an explosion of a nebula." - **Dalle 3**







¿Qué hacen los modelos generativos?

Para qué se usan

- Generación de imágenes (rostros, paisajes, escenas, criaturas imaginarias, situaciones)
- Creación de texto (ChatGPT es un ejemplo basado en Transformers).
- Traducción automática.
- Conversión de voz.
- Generación de música.
- Modelado de proteínas, química y datos científicos.



¿Qué hacen los modelos generativos?

Objetivo de la clase

- Comprender qué son los modelos generativos, específicamente para visión por computador.
- Familiarizarse con distintas estrategias utilizadas para generar imágenes.
- Ver sus utilidades en la industria.



Agenda

01

¿Qué hacen los modelos generativos?:
Motivación, Objetivos y Agenda

02

Modelos generativos en CV

03

Autoencoders / Variational Autoencoders

04

Generative Adversarial Networks

05

Modelos de difusión + Latent/Stable diffusion

06

Usos en la industria



¿Qué hacen los modelos generativos?


- Aprenden la **distribución de probabilidad** de los datos de entrenamiento.
- A partir de eso, pueden **muestrear** (generar) nuevas instancias realistas.
- Pueden reconstruir, transformar o interpolar datos.

¿Qué hacen los modelos generativos?

Modelos de **clasificación**

→ Reconocen si algo pertenece a una distribución.

$$f(\text{img_dog}) \rightarrow \text{dog}$$





¿Qué hacen los modelos generativos?

Modelos de **clasificación**

→ Reconocen si algo pertenece a una distribución.

$$f(x) \mid x \in X$$



¿Qué hacen los modelos generativos?

Modelos de **generativos**

→ Aprenden a representar una distribución.

$$f(\cdot) \mid f(\cdot) \approx X$$

¿Qué hacen los modelos generativos?

Modelos de **generativos**

→ Aprenden a representar una distribución.

$$f(x)$$





Modelos generativos en CV

1. Autoencoders / Variational Autoencoders
2. Generative Adversarial Networks
3. Modelos de difusión
4. Latent / Stable Diffusion

Autoencoders / Variational Autoencoders

Autoencoder


Arquitectura de redes neuronales donde **se comprime y luego descomprime información, generando así una representación intermedia y comprimida de esta (espacio latente)**.



Autoencoders / Variational Autoencoders

Autoencoder

Arquitectura de redes neuronales donde **se comprime y luego descomprime información**, generando así una representación intermedia y comprimida de esta (**espacio latente**).




Autoencoders / Variational Autoencoders

Autoencoder


Arquitectura de redes neuronales donde **se comprime y luego descomprime información**, generando así una representación intermedia y comprimida de esta (**espacio latente**).

Espacio latente es un **espacio matemático** en el que se representan las características internas o abstractas de los datos de forma compacta.



Autoencoders / Variational Autoencoders

Autoencoder



Autoencoders / Variational Autoencoders


Variational Autoencoder (VAEs)

Reformulación de la arquitectura de los autoencoders, **que permite convertirlos en modelos generativos.**



Autoencoders / Variational Autoencoders

Variational Autoencoder (VAEs)



Autoencoders / Variational Autoencoders

Espacio latente


Espacio latente continuo: permite interpolación



Autoencoders / Variational Autoencoders

Espacio latente

Espacio latente continuo: permite interpolación




Generative Adversarial Networks (GANs)


Arquitectura de modelo generativo donde **se entrenan en conjunto un generador y un clasificador, mediante una competencia entre ambos.**



Generative Adversarial Networks (GANs)



Generative Adversarial Networks (GANs)





Generative Adversarial Networks (GANs)

Función de pérdida

$$\min_G \max_D V(D, G) := \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log(D(x))] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

z: Ruido / Vector Latente (modelado por una normal)

x : Datos reales

G : Generador

D: Discriminador

G(z): Datos sintéticos

D(x): Discriminador evaluando datos reales

D(G(z)): Discriminador evaluando datos sintéticos

Modelos de difusión


Modelo generativo que se construye diseñando un **procedimiento para gradualmente convertir datos en ruido, y luego entrenar una red neuronal que aprenda a invertir este proceso paso a paso.**



Modelos de difusión


Modelo generativo que se construye diseñando un **procedimiento para gradualmente convertir datos en ruido**, y luego **entrenar una red neuronal que aprenda a invertir este proceso paso a paso**.

Diffusion models:
Gradually add Gaussian noise and then reverse




Modelos de difusión

Modelo generativo que se construye diseñando un **procedimiento para gradualmente convertir datos en ruido**, y luego **entrenar una red neuronal que aprenda a invertir este proceso paso a paso**.



Modelos de difusión

Aprendiendo el paso inverso: U-Net




Modelos de difusión

Aprendiendo el paso inverso: U-Net



Comparando modelos

Generative learning trilemma



TACKLING THE GENERATIVE LEARNING TRILEMMA
WITH DENOISING DIFFUSION GANS

<https://arxiv.org/pdf/2112.07804>

Variational Autoencoders,
Normalizing Flows

Comparando modelos

Cómo evalúo la calidad

Fréchet inception distance (FID): Métrica para comparar la calidad de las imágenes creadas por un modelo generativo.

Compara la distribución de las imágenes generadas con las del dataset original utilizando representaciones de un modelo auxiliar (VGG x ejemplo).

Detecta overfitting, mide diversidad y realismo en un conjunto.



¿Qué indica el FID?

- **Cuanto menor es el FID, mejor.**
Un FID más bajo indica que las imágenes generadas tienen una **distribución de características más parecida** a las reales.
- FID = 0: distribución idéntica (ideal, pero prácticamente imposible)



Comparación - Fréchet inception distance [Imagenet]

Rank	Model	FID ↓	Inception score	Paper	Code	Result	Year	Tags
1	EDM2- XXL Autoguidance (M, T /3.5)	1.25		Guiding a Diffusion Model with a Bad Version of Itself			2024	
2	EDM2- S Autoguidance (XS, T /16)	1.34		Guiding a Diffusion Model with a Bad Version of Itself			2024	
3	EDM2-XXL w/ guidance interval	1.40		Applying Guidance in a Limited Interval Improves Sample and Distribution Quality in Diffusion Models			2024	
4	EDM2-S w/ guidance interval	1.68		Applying Guidance in a Limited Interval Improves Sample and Distribution Quality in Diffusion Models			2024	
5	PaGoDA	1.80		PaGoDA: Progressive Growing of a One-Step Generator from a Low-Resolution Diffusion Teacher			2024	GAN VAE Diffusion
6	EDM2-XXL	1.81		Analyzing and Improving the Training Dynamics of Diffusion Models			2023	
7	EDM2-XL	1.85		Analyzing and Improving the Training Dynamics of Diffusion Models			2023	
8	EDM2-L	1.88		Analyzing and Improving the Training Dynamics of Diffusion Models			2023	
9	MAGVIT-v2	1.91	324.3	Language Model Beats Diffusion -- Tokenizer is Key to Visual Generation			2023	
10	EDM2-M	2.01		Analyzing and Improving the Training Dynamics of Diffusion Models			2023	



Comparación - Fréchet inception distance [FFHQ]

Rank	Model	FID ↓	FD	Precision	Recall	IS	bits/ dimension	Paper	Code	Result	Year	Tags
1	StyleSAN-XL	1.68						SAN: Inducing Metrizability of GAN with Discriminative Normalized Linear Layer			2023	GAN
2	StyleNAT	2.05						StyleNAT: Giving Each Head a New Perspective			2022	GAN Transformer Neighborhood Attention
3	StyleGAN-XL	2.19						StyleGAN-XL: Scaling StyleGAN to Large Diverse Datasets			2022	GAN
4	PDM+CS	2.57						Compensation Sampling for Improved Convergence in Diffusion Models			2023	
5	HiT-L	2.58						Improved Transformer for High-Resolution GANs			2021	Transformer
6	Poly-INR	2.72						Polynomial Implicit Neural Representations For Large Diverse Datasets			2023	
7	StyleSwin	2.81						StyleSwin: Transformer-based GAN for High-resolution Image Generation			2021	Transformer Swin-Transformer
8	HiT-B	2.95						Improved Transformer for High-Resolution GANs			2021	Transformer
9	HiT-S	3.06						Improved Transformer for High-Resolution GANs			2021	Transformer
10	InsGen	3.31						Data-Efficient Instance Generation from Instance Discrimination			2021	



Comparación

	Velocidad generación imagen	Calidad imagen	Distribución imagenes generadas
VAEs	Rápida	Baja	Alta
GANs	Rápida	Alta	Baja
Difusión	Lenta	Alta	Alta


Latent Diffusion (Abril, 2022)

Combinan ideas de Autoencoders y difusión para generar imágenes, con muchos menos recursos. Se aplica el proceso de difusión en el espacio latente comprimido.

'A painting of the last supper by Picasso.'



'An oil painting of a latent space.'



'An epic painting of Gandalf the Black summoning thunder and lightning in the mountains.'



Stable Diffusion (Latent Diffusion)

Arquitectura generativa compuesta, que entrena un **modelo de difusión** en el espacio latente de un **autoencoder** que fue **pre-entrenado** mediante el esquema competitivo de una **GAN**.


Es la más popular y más usada en el mundo actualmente.




Stable Diffusion (Latent Diffusion)

Arquitectura generativa compuesta, que entrena un **modelo de difusión** en el espacio latente de un **autoencoder** que fue **pre-entrenado** mediante el esquema competitivo de una **GAN**.

VAE + U-Net con cross-attention + Text encoder (CLIP)



Stable Diffusion (Latent Diffusion)





Stable Diffusion (Latent Diffusion)


Flujo de trabajo de Stable Diffusion:

1. Un **prompt textual** es codificado como vector por un modelo de lenguaje (por ejemplo CLIP Text Encoder).
2. Se genera un vector de ruido en el espacio latente.
3. A través de múltiples pasos de difusión inversa (denoising), el modelo refina ese ruido hacia una representación latente coherente, condicionada por el texto.
4. Finalmente, el decoder del VAE convierte el resultado latente en una imagen.

Usos en la industria

Caso: quiero entrenar un clasificador, pero tengo pocos datos, o son de mala calidad.

Solución **data augmentation**: Un modelo generativo pre-entrenado puede ser *fine-tuneado* para generar datos sintéticos de alta calidad, permitiendo así entrenar un modelo competente.



DatasetGAN: Efficient Labeled Data Factory with Minimal Human Effort

<https://nv-tlabs.github.io/datasetGAN/>



Usos en la industria

- Autoencoders y VAEs: detección de **anomalías** en imágenes, detectar **defectos** en piezas industriales comparando la reconstrucción con la entrada (si el error es alto, podría indicar una anomalía), **compresión de imágenes**, y **filtro de ruido en imágenes médicas o de cámaras**, **sistemas de recomendación de contenido visual**, **sistemas de generación controlable**, por ejemplo generar variantes de rostros a partir de atributos (edad, sonrisa, etc.)
- GANs: **generación de arte y contenido visual** (ej. generar personajes, escenarios, diseños). En videojuegos y cine, pueden ayudar a generar texturas o incluso animaciones de rostros. En fotografía, hay aplicaciones de **foto enhancement** (de blanco y negro a color, fotos antiguas), imágenes sintéticas de resonancias o rayos X para aumentar datos respetando privacidad. **Sintetización de rostros o voces** para crear asistentes virtuales.
- Modelos de difusión: En fotografía y cine, se explora su uso para **restaurar filmaciones** antiguas (remasterización), cambiar rasgos faciales en video (*face swap* controlado). En medicina, se investiga su capacidad para **sintetizar datos médicos** raros (por ejemplo, generar imágenes de tumores poco comunes). Editores gráficos (GIMP, Photoshop) están integrando plugins de Stable Diffusion para generar y editar imágenes por texto.



Resumen

01

Los **Autoencoders** introdujeron la idea de compresión y reconstrucción. Los **VAEs** añadieron un marco probabilístico para generación controlada.

02

Las **GANs** llevaron la calidad visual a otro nivel mediante aprendizaje adversarial

03

Los **Modelos de Difusión** retomaron principios probabilísticos para lograr aun mejor fidelidad (a costo de cómputo). Y finalmente los **LDMs** optimizaron la difusión haciendo viable su uso en aplicaciones cotidianas.



Resumen

01

Los modelos generativos **aprenden a representar distribuciones.**

02

Es un área de constante estudio **sin una arquitectura “ganadora”**. Cada arquitectura tiene sus pro y contras.

03

Es útil para escenarios en los que quiero entrenar un modelo y tengo pocos datos. **Permite aumentar mi dataset con datos sintéticos de alta calidad.**

Problemas

01

No son útiles para todo tipo de datos; **por ejemplo, datos tabulares.**

02

Requieren muchos recursos para ser entrenados desde 0
(mejor usar un modelo de alguna compañía) 🧩.

03

Heredan los sesgos de los datos de entrenamiento.



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

EDUCACIÓN
PROFESIONAL

Modelos Generativos en Visión por Computador

Profesor:

Francisca Cattán

fpcattan@uc.cl





ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

EDUCACIÓN
PROFESIONAL



www.educacionprofesional.ing.uc.cl