



Pontificia Universidad Católica de Chile
Departamento de Ciencias de la Computación

Diplomado en Inteligencia Artificial

Clase 31

Aprendizaje Reforzado (RL)

Carlos Aspillaga



IA Lab

CENiA
CENTRO NACIONAL DE INTELIGENCIA ARTIFICIAL

Créditos de la clase de hoy

Cristóbal Eyzaguirre
Alvaro Soto
Rodrigo Toro

Contenidos de la clase de hoy

1

Introducción

Motivación
Ejemplos

2

Conceptos fundamentales

Paradigma de aprendizaje reforzado
Ambiente
Agente

3

Q-Learning

Q-Learning
Deep Q-Learning

4

Trabajo Práctico

Contenidos de la clase de hoy

1 **Introducción**

Motivación
Ejemplos

2 **Conceptos fundamentales**

Paradigma de aprendizaje reforzado
Ambiente
Agente

3 **Q-Learning**

Q-Learning
Deep Q-Learning


4 **Trabajo Práctico**

Aprendizaje Reforzado ¿Qué es?

Definición

Es una rama de la inteligencia artificial que estudia cómo crear agentes que aprenden a resolver problemas mediante ensayo y error.

Ejemplo ilustrativo




Aprendizaje Reforzado ¿Qué es?

Definición

Es una rama de la inteligencia artificial que estudia cómo crear agentes que aprenden a resolver problemas mediante ensayo y error.

Ejemplo ilustrativo




Aprendizaje Reforzado ¿Qué es?

Definición

Es una rama de la inteligencia artificial que estudia cómo crear agentes que aprenden a resolver problemas mediante ensayo y error.

Ejemplo ilustrativo




Aprendizaje Reforzado ¿Qué es?

Definición

Es una rama de la inteligencia artificial que estudia cómo crear agentes que aprenden a resolver problemas mediante ensayo y error.

Ejemplo ilustrativo




Aprendizaje Reforzado ¿Qué es?

Definición

Es una rama de la inteligencia artificial que estudia cómo crear agentes que aprenden a resolver problemas mediante ensayo y error.

Ejemplo ilustrativo




+1 recompensa

Aprendizaje Reforzado ¿Qué es?

Definición

Es una rama de la inteligencia artificial que estudia cómo crear agentes que aprenden a resolver problemas mediante ensayo y error.

Ejemplo ilustrativo




Aprendizaje Reforzado ¿Qué es?

Definición

Es una rama de la inteligencia artificial que estudia cómo crear agentes que aprenden a resolver problemas mediante ensayo y error.

Ejemplo ilustrativo




Aprendizaje Reforzado ¿Qué es?

Definición

Es una rama de la inteligencia artificial que estudia cómo crear agentes que aprenden a resolver problemas mediante ensayo y error.

Ejemplo ilustrativo



+1 recompensa

Aprendizaje Reforzado ¿Qué es?

Problemas de decisión

La vida está llena de problemas de decisión y el éxito (o fracaso) de lo que emprendemos depende de la calidad de nuestras decisiones.



Aprendizaje Reforzado ¿Qué es?

Problemas de decisión

La vida está llena de problemas de decisión y el éxito (o fracaso) de lo que emprendemos depende de la calidad de nuestras decisiones.

- ¿Cómo ruteo los camiones de la empresa?

Aprendizaje Reforzado ¿Qué es?

Problemas de decisión

La vida está llena de problemas de decisión y el éxito (o fracaso) de lo que emprendemos depende de la calidad de nuestras decisiones.

- ¿Cómo ruteo los camiones de la empresa?
- ¿Cómo distribuyo tareas en mi equipo de trabajo?

Aprendizaje Reforzado ¿Qué es?

Problemas de decisión

La vida está llena de problemas de decisión y el éxito (o fracaso) de lo que emprendemos depende de la calidad de nuestras decisiones.

- ¿Cómo ruteo los camiones de la empresa?
- ¿Cómo distribuyo tareas en mi equipo de trabajo?
- ¿Cómo asigno pacientes a doctores?

Aprendizaje Reforzado ¿Qué es?

Problemas de decisión

La vida está llena de problemas de decisión y el éxito (o fracaso) de lo que emprendemos depende de la calidad de nuestras decisiones.

- ¿Cómo ruteo los camiones de la empresa?
- ¿Cómo distribuyo tareas en mi equipo de trabajo?
- ¿Cómo asigno pacientes a doctores?
- ¿Cómo invierto mi dinero?

Aprendizaje Reforzado ¿Qué es?

Problemas de decisión

La vida está llena de problemas de decisión y el éxito (o fracaso) de lo que emprendemos depende de la calidad de nuestras decisiones.

- ¿Cómo ruteo los camiones de la empresa?
- ¿Cómo distribuyo tareas en mi equipo de trabajo?
- ¿Cómo asigno pacientes a doctores?
- ¿Cómo invierto mi dinero?
- ¿Cómo combino ingredientes de origen vegetal para recrear alimentos de origen animal?
- (...)

Aprendizaje Reforzado ¿Qué es?

Problemas de decisión


La vida está llena de problemas de decisión y el éxito (o fracaso) de lo que emprendemos depende de la calidad de nuestras decisiones.

- ¿Cómo ruteo los camiones de la empresa?
- ¿Cómo distribuyo tareas en mi equipo de trabajo?
- ¿Cómo asigno pacientes a doctores?
- ¿Cómo invierto mi dinero?
- ¿Cómo combino ingredientes de origen vegetal para recrear alimentos de origen animal?
- (...)

El aprendizaje reforzado permite resolver problemas de decisión de manera autónoma.


Aprendizaje Reforzado

Un ejemplo real: Edge computing




Aprendizaje Reforzado

Un ejemplo real: Edge computing




Aprendizaje Reforzado

Un ejemplo real: Edge computing



Aprendizaje Reforzado

Un ejemplo real: Edge computing



Es decir, el agente descubrió cómo repartir tareas mejor que los algoritmos pensados por humanos – ¡permitiendo ahorrar valiosos recursos!¹

¹ Sanabria et al. (2022). Solving Task Scheduling Problems in Dew Computing via Deep Reinforcement Learning. Applied Sciences, 12, 14, 7137.

Objetivos de esta clase

Objetivo principal:

Entender los fundamentos teóricos y prácticos del aprendizaje reforzado.

Objetivos de esta clase

Objetivo principal:

Entender los fundamentos teóricos y prácticos del aprendizaje reforzado.

Objetivos secundarios:

1. Identificar cuándo un problema puede ser resuelto usando aprendizaje reforzado.
2. Que puedan utilizar aprendizaje reforzado en un nuevo problema.

Objetivos de esta clase

¿Qué sabemos hasta ahora?

El aprendizaje reforzado permite resolver problemas de decisión de forma automática.

¿Cómo lo hace?

Contenidos de la clase de hoy

1 Introducción

Motivación
Ejemplos

2 Conceptos fundamentales

Paradigma de aprendizaje reforzado
Ambiente
Agente

3 Q-Learning

Q-Learning
Deep Q-Learning

4 Trabajo Práctico

Aprendizaje Reforzado

Definición de alto nivel

Agente

Aprendizaje Reforzado


Defnición de alto nivel

Agente

Ambiente


Aprendizaje Reforzado

Defnición de alto nivel




Aprendizaje Reforzado

Definición de alto nivel




Aprendizaje Reforzado

Definición de alto nivel



Aprendizaje Reforzado

Definición de alto nivel




El **objetivo** del agente es **obtener recompensas** del ambiente. Para ello, **ajusta su política para seleccionar acciones $\pi(a|s)$** con el fin de obtener más recompensa.

Aprendizaje Reforzado

Defnición de alto nivel


Agente
Política $\pi(a s)$



Ambiente
Transiciones entre estados
Función de recompensa


Aprendizaje Reforzado

Definición de alto nivel



Aprendizaje Reforzado

Definición de alto nivel




Aprendizaje Reforzado

Definición de alto nivel



Aprendizaje Reforzado

Definición de alto nivel




Aprendizaje Reforzado

Defnición de alto nivel



Aprendizaje Reforzado


Definición de alto nivel



Aprendizaje Reforzado

Definición de alto nivel


Agente
Política $\pi(a s)$



Enfoquémonos en
el **ambiente**

Aprendizaje Reforzado


Definición de alto nivel



Para usar aprendizaje reforzado hay que modelar el problema como un **ambiente**.

Aprendizaje Reforzado

Definición de alto nivel



Para usar aprendizaje reforzado hay que modelar el problema como un **ambiente**.

... pero ¿qué es un ambiente?

Ambiente

Markov Decision Process (MDP)

Un MDP es una tupla $\mathcal{M} = (S, A, r, p, \gamma)$ donde

- S es un conjunto finito de estados.
- A es un conjunto finito de acciones.
- $r(s, a, s')$ es la recompensa recibida al ejecutar $a \in A$ en $s \in S$ y llegar a $s' \in S$.
- $p(s'|s, a)$ es la probabilidad de pasar de $s \in S$ a $s' \in S$ si se ejecuta $a \in A$.
- $\gamma \in (0, 1]$ es el factor de descuento (generalmente se usa $\gamma = 0.99$).

Ambiente


Markov Decision Process (MDP)

Un MDP es una tupla $\mathcal{M} = (S, A, r, p, \gamma)$ donde

- S es un conjunto finito de estados.
- A es un conjunto finito de acciones.
- $r(s, a, s')$ es la recompensa recibida al ejecutar $a \in A$ en $s \in S$ y llegar a $s' \in S$.
- $p(s'|s, a)$ es la probabilidad de pasar de $s \in S$ a $s' \in S$ si se ejecuta $a \in A$.
- $\gamma \in (0, 1]$ es el factor de descuento (generalmente se usa $\gamma = 0.99$).

Ejemplo galletas:

Los estados son las 72 combinaciones posibles de posiciones del agente y la galleta.



Ambiente

Markov Decision Process (MDP)

Un MDP es una tupla $\mathcal{M} = (S, A, r, p, \gamma)$ donde

- S es un conjunto finito de estados.
- A es un conjunto finito de acciones.
- $r(s, a, s')$ es la recompensa recibida al ejecutar $a \in A$ en $s \in S$ y llegar a $s' \in S$.
- $p(s'|s, a)$ es la probabilidad de pasar de $s \in S$ a $s' \in S$ si se ejecuta $a \in A$.
- $\gamma \in (0, 1]$ es el factor de descuento (generalmente se usa $\gamma = 0.99$).

Ejemplo galletas:

Las acciones posibles son 4: izquierda, derecha, arriba, abajo.

Ambiente


Markov Decision Process (MDP)

Un MDP es una tupla $\mathcal{M} = (S, A, r, p, \gamma)$ donde

- S es un conjunto finito de estados.
- A es un conjunto finito de acciones.
- $r(s, a, s')$ es la recompensa recibida al ejecutar $a \in A$ en $s \in S$ y llegar a $s' \in S$.
- $p(s'|s, a)$ es la probabilidad de pasar de $s \in S$ a $s' \in S$ si se ejecuta $a \in A$.
- $\gamma \in (0, 1]$ es el factor de descuento (generalmente se usa $\gamma = 0.99$).

Ejemplo galletas:

La recompensa es **+1** si el agente come una galleta (cero en otro caso).



Ambiente


Markov Decision Process (MDP)

Un MDP es una tupla $\mathcal{M} = (S, A, r, p, \gamma)$ donde

- S es un conjunto finito de estados.
- A es un conjunto finito de acciones.
- $r(s, a, s')$ es la recompensa recibida al ejecutar $a \in A$ en $s \in S$ y llegar a $s' \in S$.
- $p(s'|s, a)$ es la probabilidad de pasar de $s \in S$ a $s' \in S$ si se ejecuta $a \in A$.
- $\gamma \in (0, 1]$ es el factor de descuento (generalmente se usa $\gamma = 0.99$).

Ejemplo galletas:

La recompensa es $+1$ si el agente come una galleta (cero en otro caso).



Ambiente

Markov Decision Process (MDP)

Un MDP es una tupla $\mathcal{M} = (S, A, r, p, \gamma)$ donde

- S es un conjunto finito de estados.
- A es un conjunto finito de acciones.
- $r(s, a, s')$ es la recompensa recibida al ejecutar $a \in A$ en $s \in S$ y llegar a $s' \in S$.
- $p(s'|s, a)$ es la probabilidad de pasar de $s \in S$ a $s' \in S$ si se ejecuta $a \in A$.
- $\gamma \in (0, 1]$ es el factor de descuento (generalmente se usa $\gamma = 0.99$).

Ejemplo galletas:

Las probabilidades $p(s'|s, a)$ modelan las dinámicas del mundo en que vive el agente.

Ambiente


Markov Decision Process (MDP)

Un MDP es una tupla $\mathcal{M} = (S, A, r, p, \gamma)$ donde

- S es un conjunto finito de estados.
- A es un conjunto finito de acciones.
- $r(s, a, s')$ es la recompensa recibida al ejecutar $a \in A$ en $s \in S$ y llegar a $s' \in S$.
- $p(s'|s, a)$ es la probabilidad de pasar de $s \in S$ a $s' \in S$ si se ejecuta $a \in A$.
- $\gamma \in (0, 1]$ es el factor de descuento (generalmente se usa $\gamma = 0.99$).

Ejemplo galletas:

Las probabilidades $p(s'|s, a)$ modelan las dinámicas del mundo en que vive el agente.



Ambiente


Markov Decision Process (MDP)

Un MDP es una tupla $\mathcal{M} = (S, A, r, p, \gamma)$ donde

- S es un conjunto finito de estados.
- A es un conjunto finito de acciones.
- $r(s, a, s')$ es la recompensa recibida al ejecutar $a \in A$ en $s \in S$ y llegar a $s' \in S$.
- $p(s'|s, a)$ es la probabilidad de pasar de $s \in S$ a $s' \in S$ si se ejecuta $a \in A$.
- $\gamma \in (0, 1]$ es el factor de descuento (generalmente se usa $\gamma = 0.99$).

Ejemplo galletas:

Las probabilidades $p(s'|s, a)$ modelan las dinámicas del mundo en que vive el agente.



Ambiente


Markov Decision Process (MDP)

Un MDP es una tupla $\mathcal{M} = (S, A, r, p, \gamma)$ donde

- S es un conjunto finito de estados.
- A es un conjunto finito de acciones.
- $r(s, a, s')$ es la recompensa recibida al ejecutar $a \in A$ en $s \in S$ y llegar a $s' \in S$.
- $p(s'|s, a)$ es la probabilidad de pasar de $s \in S$ a $s' \in S$ si se ejecuta $a \in A$.
- $\gamma \in (0, 1]$ es el factor de descuento (generalmente se usa $\gamma = 0.99$).

Ejemplo galletas:

Las probabilidades $p(s'|s, a)$ modelan las dinámicas del mundo en que vive el agente.



Ambiente

Markov Decision Process (MDP)

Un MDP es una tupla $\mathcal{M} = (S, A, r, p, \gamma)$ donde

- S es un conjunto finito de estados.
- A es un conjunto finito de acciones.
- $r(s, a, s')$ es la recompensa recibida al ejecutar $a \in A$ en $s \in S$ y llegar a $s' \in S$.
- $p(s'|s, a)$ es la probabilidad de pasar de $s \in S$ a $s' \in S$ si se ejecuta $a \in A$.
- $\gamma \in (0, 1]$ es el factor de descuento (generalmente se usa $\gamma = 0.99$).

Ejemplo galletas:

... y por ahora no nos preocupemos del factor de descuento :)

Ambiente

En la práctica, hay que implementar 3 funciones:

Ambiente

En la práctica, hay que implementar 3 funciones:

- 1) `action_space()`: Retorna las acciones disponibles para el agente.
`A = [izquierda, derecha, arriba, abajo]`


Ambiente

En la práctica, hay que implementar 3 funciones:

1) `action_space()`: Retorna las acciones disponibles para el agente.

`A = [izquierda, derecha, arriba, abajo]`

2) `reset()`: Reinicia el ambiente y retorna el estado inicial.




Ambiente

En la práctica, hay que implementar 3 funciones:


1) `action_space()`: Retorna las acciones disponibles para el agente.

$A = [\text{izquierda}, \text{derecha}, \text{arriba}, \text{abajo}]$

2) `reset()`: Reinicia el ambiente y retorna el estado inicial.




3) `step(s,a)`: Retorna el siguiente estado y recompensa luego de ejecutar la acción a en el estado s . Además indica si el episodio ha terminado.




Aprendizaje Reforzado

Definición de alto nivel



Aprendizaje Reforzado

Definición de alto nivel



Aprendizaje Reforzado

Agentes

Todo agente intenta aprender una política “óptima”

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \right]$$

Aprendizaje Reforzado

Agentes

Todo agente intenta aprender una política “óptima”

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \right]$$

Recordemos que una política $\pi(a|s)$ simplemente indica la probabilidad con la que el agente elige la acción a en el estado s .

Aprendizaje Reforzado

Agentes

Todo agente intenta aprender una política “óptima”

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \right]$$

Para todo problema interesante, existirán políticas que son mejores que otras.


Entonces, el problema de fondo es cómo definir que una política es mejor que otra.

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



Experiencia:


- Asignamos un cliente a e_1 y obtuvimos 2 estrellas.
- Asignamos un cliente a e_2 y obtuvimos 3 estrellas.

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



Experiencia:

- Asignamos un cliente a e_1 y obtuvimos 2 estrellas.
- Asignamos un cliente a e_2 y obtuvimos 3 estrellas.


¿Es esto suficiente para inferir que $\pi_1(e_1|c) < \pi_2(e_2|c)$?

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



Experiencia:

- Asignamos un cliente a e_1 y obtuvimos 2 estrellas.
- Asignamos un cliente a e_2 y obtuvimos 3 estrellas.

¿Es esto suficiente para inferir que $\pi_1(e_1|c) < \pi_2(e_2|c)$?


No! Quizás a e_1 le tocó un cliente difícil

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



Digamos que obtenemos datos de 1000 clientes atendidos por e_1 y e_2 y calculamos su satisfacción:

- Satisfacción clientes de e_1 es **4.12** en promedio.
- Satisfacción clientes de e_2 es **3.04** en promedio.


¿Es esto suficiente para inferir que $\pi_1(e_1|c) > \pi_2(e_2|c)$?

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



Digamos que obtenemos datos de 1000 clientes atendidos por e_1 y e_2 y calculamos su satisfacción:

- Satisfacción clientes de e_1 es **4.12** en promedio.
- Satisfacción clientes de e_2 es **3.04** en promedio.

¿Es esto suficiente para inferir que $\pi_1(e_1|c) > \pi_2(e_2|c)$?


Con bastante confianza podemos inferir que al llegar un nuevo cliente, es mejor asignarlo a e_1 que a e_2 .

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



Ahora consideremos una versión simplificada de la ecuación de una política óptima:

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi}[R_1]$$


La expresión $\mathbb{E}_{\pi}[R_1]$ representa el promedio de la recompensa que obtendría la política π si la ejecutamos muchas veces (infinitas veces) al atender un solo cliente.

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



Sin embargo, el objetivo **no** es maximizar la recompensa de **un** cliente, sino que maximizar la recompensa de los n clientes que llegan a la sucursal.

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi}[R_1] \Rightarrow \pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^n R_{t+1} \right]$$


¿Qué pasa si no conocemos n a priori?

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



En la definición general se asume que queremos maximizar la recompensa recibida hasta el infinito.

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} R_{t+1} \right]$$


El problema es que la suma anterior puede *divergir*.

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



En la definición general se asume que queremos maximizar la recompensa recibida hasta el infinito.

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} R_{t+1} \right]$$

E.j., si π_{1*} siempre obtiene 1 estrella:


$$\sum_{t=0}^{\infty} R_{t+1} = 1 + 1 + 1 + 1 + 1 + 1 + \dots = \infty$$

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



En la definición general se asume que queremos maximizar la recompensa recibida hasta el infinito.

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} R_{t+1} \right]$$

E.j., si π_{5*} siempre obtiene 5 estrellas:


$$\sum_{t=0}^{\infty} R_{t+1} = 5 + 5 + 5 + 5 + 5 + 5 + \dots = \infty$$

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



En la definición general se asume que queremos maximizar la recompensa recibida hasta el infinito.

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} R_{t+1} \right]$$


Por lo tanto, **no** podemos inferir que $\pi_{5*} > \pi_{1*}$:(

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



$\gamma \in (0, 1)$ se introduce para evitar que la suma diverja.

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \right]$$

E.j., si $\gamma = 0.99$ y π_{5*} siempre obtiene 5 de recompensa:


$$\sum_{t=0}^{\infty} \gamma^t R_{t+1} = 5 + 5 \cdot 0.99 + 5 \cdot 0.99^2 + \dots = 500$$

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



$\gamma \in (0, 1)$ se introduce para evitar que la suma diverja.

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \right]$$

E.j., si $\gamma = 0.99$ y π_{1*} siempre obtiene 1 de recompensa:


$$\sum_{t=0}^{\infty} \gamma^t R_{t+1} = 1 + 0.99 + 0.99^2 + 0.99^3 + \dots = 100$$

Aprendizaje Reforzado

Agentes

Ejemplo

Una empresa tiene un módulo de servicio al cliente que cuenta con 2 empleados. Cada cliente que llega debe ser asignado a un empleado. Luego de ser atendidos, los clientes reportan su nivel de satisfacción dando entre 1 y 5 estrellas. El objetivo es asignar clientes a empleados tal que se maximice la satisfacción total de los clientes.



$\gamma \in (0, 1)$ se introduce para evitar que la suma diverja.

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \right]$$

Por lo tanto, agregar γ nos permite inferir que $\pi_{5*} > \pi_{1*}$

Contenidos de la clase de hoy

1 **Introducción**
Motivación
Ejemplos

2 **Conceptos fundamentales**
Paradigma de aprendizaje reforzado
Ambiente
Agente

3 **Q-Learning**
Q-Learning
Deep Q-Learning


4 **Trabajo Práctico**

Agentes de Aprendizaje Reforzado

(recapitulando)

Aprendizaje Reforzado

Agentes




Objetivo: Mediante interactuar con un ambiente
Queremos encontrar una política óptima π^* :

$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \right]$$

Aprendizaje Reforzado

Agentes



Objetivo: Mediante interactuar con un ambiente
Queremos encontrar una política óptima π^* :


$$\pi^* = \arg \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \right]$$

¿Cómo lo hacemos?

Aprendizaje Reforzado

Agentes

Enfoquemos la discusión en un problema más pequeño.




En esta situación:

- ¿Qué tan buena es la acción derecha?

Aprendizaje Reforzado

Agentes

Enfoquemos la discusión en un problema más pequeño.




En esta situación:

- ¿Qué tan buena es la acción derecha?
- ¿Es mejor la acción izquierda o derecha? ¿Por qué?

Aprendizaje Reforzado

Agentes

Enfoquemos la discusión en un problema más pequeño.




En esta situación:

- ¿Qué tan buena es la acción derecha?
- ¿Es mejor la acción izquierda o derecha? ¿Por qué?
- ¿Cómo podemos definir esta intuición matemáticamente?

Aprendizaje Reforzado

Agentes

Enfoquemos la discusión en un problema más pequeño.



En esta situación:

- ¿Qué tan buena es la acción derecha?
- ¿Es mejor la acción izquierda o derecha? ¿Por qué?
- ¿Cómo podemos definir esta intuición matemáticamente?


Los Q-values nos permiten definir qué *tan buena* es una acción en cierto estado.

$$q_*(s, a) = \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \middle| S_0 = s, A_0 = a \right]$$

Aprendizaje Reforzado

Agentes

Enfoquemos la discusión en un problema más pequeño.



En esta situación:

- ¿Qué tan buena es la acción derecha?
- ¿Es mejor la acción izquierda o derecha? ¿Por qué?
- ¿Cómo podemos definir esta intuición matemáticamente?

Los Q-values nos permiten definir qué *tan buena* es una acción en cierto estado.

... para ilustrar esta idea, consideremos una variante del problema de la galleta, en la que la galleta no reaparece al ser “comida”


Aprendizaje Reforzado

Agentes

Optimal Action Value

$$q_*(s, a) = \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \middle| S_0 = s, A_0 = a \right]$$

Si ejecutamos la acción derecha y luego seguimos una política óptima:





Aprendizaje Reforzado

Agentes

Optimal Action Value

$$q_*(s, a) = \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \middle| S_0 = s, A_0 = a \right]$$

Si ejecutamos la acción derecha y luego seguimos una política óptima:




$$R_1 = 0$$

Aprendizaje Reforzado



Agentes

$$q_*(s, a) = \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \middle| S_0 = s, A_0 = a \right]$$

Si ejecutamos la acción derecha y luego seguimos una política óptima:



$R_1 = 0$





$R_2 = 1$

Aprendizaje Reforzado


Agentes

$$q_*(s, a) = \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \middle| S_0 = s, A_0 = a \right]$$

Si ejecutamos la acción derecha y luego seguimos una política óptima:



$$R_1 = 0$$



$$R_2 = 1$$

$$q_*(s, \text{derecha}) = R_1 + \gamma \cdot R_2 + \sum_{t=2}^{\infty} \gamma^t R_{t+1} = 0 + \gamma \cdot 1 = \gamma = 0.99.$$


Aprendizaje Reforzado

Agentes

Q-Learning

$$q_*(s, a) = \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \middle| S_0 = s, A_0 = a \right]$$

Si ejecutamos la acción izquierda y luego seguimos una política óptima:





Aprendizaje Reforzado

Agentes

$$q_*(s, a) = \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \middle| S_0 = s, A_0 = a \right]$$

Si ejecutamos la acción izquierda y luego seguimos una política óptima:




$$R_1 = 0$$

Aprendizaje Reforzado


Agentes

$$q_*(s, a) = \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \middle| S_0 = s, A_0 = a \right]$$


Si ejecutamos la acción izquierda y luego seguimos una política óptima:




$$R_1 = 0$$




$$R_2 = 0$$



$$R_3 = 0$$



$$R_4 = 1$$




Aprendizaje Reforzado

Agentes

$$q_*(s, a) = \max_{\pi \in \Pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \middle| S_0 = s, A_0 = a \right]$$

Si ejecutamos la acción izquierda y luego seguimos una política óptima:




$$\begin{aligned} q_*(s, \text{izquierda}) &= R_1 + \gamma \cdot R_2 + \gamma^2 \cdot R_3 + \gamma^3 \cdot R_4 + \sum_{t=4}^{\infty} \gamma^t R_{t+1} \\ &= 0 + \gamma \cdot 0 + \gamma^2 \cdot 0 + \gamma^3 \cdot 1 = \gamma^3 = 0.99^3 \approx 0.97. \end{aligned}$$

Aprendizaje Reforzado

Agentes

Acabamos de demostrar los siguiente:



En esta situación:

- $q_*(s, \text{derecha}) = 0.99$
- $q_*(s, \text{izquierda}) = 0.97$

Como $q_*(s, \text{derecha}) > q_*(s, \text{izquierda})$, podemos inferir que la acción derecha es *mejor* que la acción izquierda.

De hecho, si conocemos q_* podemos extraer una política óptima de la siguiente forma:

$$\pi^*(a|s) = \arg \max_{a \in A} q_*(s, a)$$

... entonces, para encontrar π^* podemos intentar aprender $q_*(s, a)$.

Q-Learning

Q-Learning

Los Q-values óptimos cumplen con la siguiente propiedad (si el ambiente es un MDP):

$$q_*(s, a) = \sum_{s' \in S} p(s'|s, a) \left[r(s, a, s') + \gamma \max_{a' \in A} q_*(s', a') \right] \quad \text{para todo } s \in S, a \in A.$$

Q-Learning

Los Q-values óptimos cumplen con la siguiente propiedad (si el ambiente es un MDP):

$$q_*(s, a) = \sum_{s' \in S} p(s'|s, a) \left[r(s, a, s') + \gamma \max_{a' \in A} q_*(s', a') \right] \quad \text{para todo } s \in S, a \in A.$$

Es decir, si de alguna forma encontramos un conjunto de valores $Q(s, a)$ tal que:

$$Q(s, a) = \sum_{s' \in S} p(s'|s, a) \left[r(s, a, s') + \gamma \max_{a' \in A} Q(s', a') \right] \quad \text{para todo } s \in S, a \in A.$$

Q-Learning

Los Q-values óptimos cumplen con la siguiente propiedad (si el ambiente es un MDP):

$$q_*(s, a) = \sum_{s' \in S} p(s'|s, a) \left[r(s, a, s') + \gamma \max_{a' \in A} q_*(s', a') \right] \quad \text{para todo } s \in S, a \in A.$$


Es decir, si de alguna forma encontramos un conjunto de valores $Q(s, a)$ tal que:

$$Q(s, a) = \sum_{s' \in S} p(s'|s, a) \left[r(s, a, s') + \gamma \max_{a' \in A} Q(s', a') \right] \quad \text{para todo } s \in S, a \in A.$$

... entonces Q es igual a q_* (y de Q podemos extraer π^*).

Q-Learning


s	a	$Q(s, a)$
...	...	...
	arriba	0.04
	derecha	0.1
	abajo	0.06
	izquierda	0.01
...	...	...
	arriba	0.0
	derecha	-0.9
	abajo	0.0
	izquierda	-0.1
...	...	...




derecha

Q-Learning

s	a	$Q(s, a)$
...	...	...
	arriba	0.04
	derecha	0.1
	abajo	0.06
	izquierda	0.01
...	...	...
	arriba	0.0
	derecha	-0.9
	abajo	0.0
	izquierda	-0.1
...	...	...




derecha +1




Q-Learning

s	a	$Q(s, a)$
...	...	...
	arriba	0.04
	derecha	0.1
	abajo	0.06
	izquierda	0.01
...	...	...
	arriba	0.0
	derecha	-0.9
	abajo	0.0
	izquierda	-0.1
...	...	...




derecha +1




Experiencia: (s, a, r, s')

Q-Learning

s	a	$Q(s, a)$
...	...	...
	arriba	0.04
	derecha	0.1
	abajo	0.06
	izquierda	0.01
...	...	...
	arriba	0.0
	derecha	-0.9
	abajo	0.0
	izquierda	-0.1
...	...	...



derecha +1



Experiencia: (s, a, r, s')


$Q(s, a) \xleftarrow{\alpha}$ regla de actualización (siguiente slide)

$$Q(s, a) = 0.1 + 0.7(1 - 0.1) = 0.73$$


El objetivo es lograr que $Q(s, a)$ se parezca cada vez más a $r + \gamma \max_{a'} Q(s', a')$. Cuando sean iguales, $Q = q_*$.

Q-Learning

s	a	$Q(s, a)$
...	...	...
	arriba	0.04
	derecha	0.1
	abajo	0.06
	izquierda	0.01
...	...	...
	arriba	0.0
	derecha	-0.9
	abajo	0.0
	izquierda	-0.1
...	...	...



derecha +1



Experiencia: (s, a, r, s')

$Q(s, a) \xleftarrow{\alpha}$ regla de actualización (siguiente slide)

$$Q(s, a) = 0.1 + 0.7(1 - 0.1) = 0.73$$

El objetivo es lograr que $Q(s, a)$ se parezca cada vez más a $r + \gamma \max_{a'} Q(s', a')$. Cuando sean iguales, $Q = q_*$.

Q-Learning

Q-learning (off-policy TD control) for estimating $\pi \approx \pi_*$

Algorithm parameters: step size $\alpha \in (0, 1]$, small $\varepsilon > 0$

Initialize $Q(s, a)$, for all $s \in \mathcal{S}^+$, $a \in \mathcal{A}(s)$, arbitrarily except that $Q(\text{terminal}, \cdot) = 0$

Loop for each episode:

 Initialize S

 Loop for each step of episode:

 Choose A from S using policy derived from Q (e.g., ε -greedy)

 Take action A , observe R, S'

$Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma \max_a Q(S', a) - Q(S, A)]$

$S \leftarrow S'$

 until S is terminal

Q-Learning

Q-learning (off-policy TD control) for estimating $\pi \approx \pi_*$

Algorithm parameters: step size $\alpha \in (0, 1]$, small $\varepsilon > 0$

Initialize $Q(s, a)$, for all $s \in \mathcal{S}^+$, $a \in \mathcal{A}(s)$, arbitrarily except that $Q(\text{terminal}, \cdot) = 0$

Loop for each episode:

Initialize S

Loop for each step of episode:

Choose A from S using policy derived from Q (e.g., ε -greedy)

Take action A , observe R, S'

$$Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma \max_a Q(S', a) - Q(S, A)]$$

$S \leftarrow S'$

until S is terminal

Q-Learning

Sin embargo, Q-learning tiene un problema que lo hace sumamente impráctico :(

s	a	$Q(s, a)$
...	...	...
	arriba	0.04
	derecha	0.1
	abajo	0.06
	izquierda	0.01
...	...	...

Q-Learning

Sin embargo, Q-learning tiene un problema que lo hace sumamente impráctico :(

s	a	$Q(s, a)$
...	...	...
	arriba	0.04
	derecha	0.1
	abajo	0.06
	izquierda	0.01
...	...	...

Para todo problema interesante esta tabla será **enorme!**



Q-Learning

Sin embargo, Q-learning tiene un problema que lo hace sumamente impráctico :(

s	a	$Q(s, a)$
...	...	...
	arriba	0.04
	derecha	0.1
	abajo	0.06
	izquierda	0.01
...	...	...


Para todo problema interesante esta tabla será **enorme!**



Este problema se solucionó usando deep learning :)

Deep Q-Networks

Deep Q-Learning




Experience buffer: $\langle \dots, (s, a, r, s'), \dots \rangle$

Minimize $(r + \gamma \max_{a'} Q_{\theta'}(s', a') - Q_{\theta}(s, a))^2$



<https://www.youtube.com/watch?v=TmPfTpjtdgg>



<https://www.youtube.com/watch?v=Ih8EfvOzBOY>



<https://www.youtube.com/watch?v=kopoLzvh5jY>



<https://www.youtube.com/watch?v=gn4nRCC9TwQ&t=3s>



<https://www.youtube.com/watch?v=x4O8pojMF0w>

Contenidos de la clase de hoy

1 Introducción

Motivación
Ejemplos

2 Conceptos fundamentales

Paradigma de aprendizaje reforzado
Ambiente
Agente

3 Q-Learning

Q-Learning
Deep Q-Learning

4 Trabajo Práctico