



Redes Convolucionales para reconocimiento en video

Modelos pre-entrenados

Profesor:

Bianca Del Solar Medrano

bsdelsolar@uc.cl



Contenido

1

¿Qué es la comprensión de video?

2

¿Por qué es útil?

3

Introducción a las CNN para comprensión de video

4

Evolución de la arquitectura de video

- CNN2D + agrupación temporal
- CNN2D + RNN Dos corrientes (Two-Stream)
- C3D
- I3D




¿Qué es la comprensión de video?

El objetivo es comprender lo que sucede en un video. La acción que se lleva a cabo, quién la realizó, dónde se lleva a cabo y en qué parte del video sucede.



¿Por qué es útil?

La comprensión de video es útil porque permite entender y analizar acciones, eventos y situaciones que ocurren en los videos. Esto es valioso en una variedad de campos, como seguridad, análisis deportivo, conducción autónoma, entre otros, ya que proporciona información importante para la toma de decisiones, la mejora de sistemas y la optimización de procesos



Introducción a las Redes Neuronales Convolucionales (CNN) para la Comprensión de Video (Visual Understanding-VU)

Las Redes Neuronales Convolucionales (CNN) han revolucionado el campo de la visión por computadora, permitiendo avances significativos en el reconocimiento de objetos, clasificación de imágenes y, más recientemente, en la comprensión de video. La comprensión de video implica no solo identificar objetos en imágenes estáticas, sino también comprender la dinámica temporal de los eventos en movimiento.

**¿Cómo funcionan las CNN
para el reconocimiento de
imágenes?**



Primeros modelos CNN para VU

Los primeros modelos convolucionales para la comprensión de video son una extensión de aquellos utilizados para el reconocimiento de imágenes.




CNN Model

Necesidad de
entender la
imagen (objetos-
sustantivos)

Train	99.99
Train tracks	0.004
Car	0.003
Countryside	0.002
Bicycles	0.001

CNN

Para ello, la CNN contiene varias capas ocultas especializadas y con una jerarquía: esto quiere decir que las **primeras capas** pueden **detectar líneas**, curvas y se van especializando hasta llegar a **capas más profundas** que reconocen formas complejas como un **rostro o la silueta de un animal**.



Una imagen...





		0.6	0.6		
	0.6			0.6	
	0.6	0.6	0.6	0.6	
	0.6			0.6	

...es una matriz de pixeles.

El valor de los pixeles va de 0 a 255 pero se normaliza para la red neuronal de 0 a 1

Imagen a color

Si tenemos una imagen con apenas 28×28 píxeles de alto y ancho, eso equivale a 784 neuronas. Y eso es si sólo tenemos 1 color (escala de grises). Si tuviéramos una imagen a color, necesitaríamos 3 canales (red, green, blue) y entonces usaríamos $28 \times 28 \times 3 = 2352$ neuronas de entrada.




Si la imagen es a color, estará compuesta de tres canales: rojo, verde, azul.

Convoluciones

Conjunto de Kernels


Ahora comienza el “procesado distintivo” de las CNN. Es decir, haremos las llamadas “convoluciones”: Estas consisten en tomar “**grupos de píxeles cercanos**” de la imagen de entrada e ir operando matemáticamente (producto escalar) contra una pequeña matriz que se llama kernel.



UN DETALLE: en realidad, no aplicaremos 1 sólo kernel, si no que tendremos muchos kernel (su conjunto se llama filtros). Por ejemplo en esta primer convolución podríamos tener 32 filtros, con lo cual realmente obtendremos 32 matrices de salida (este conjunto se conoce como “feature mapping”), cada una de 28x28x1 dando un total del 25.088 neuronas para nuestra PRIMER CAPA OCULTA de neuronas.


Introducción CNN para VU

Sin embargo, los videos incluyen una dimensión adicional, que es el tiempo. Por lo tanto, el modelo necesita aprovechar esta dimensión.



CNN2D + temporal pooling

Sin embargo, los videos incluyen una dimensión adicional, que es el tiempo. Por lo tanto, el modelo necesita aprovechar esta dimensión.



CNN2D + temporal pooling

Ventajas:

- Fácil de implementar.
- No es computacionalmente costoso.




Desventajas:

- No aprovecha la información temporal.
- Tiende a tener un rendimiento deficiente

CNN2D + RNN

Utiliza la Red Neuronal Recurrente (RNN) para modelar la secuencia temporal del video y la relación entre cada fotograma.



CNN2D + RNN

Ventajas:

- Fácil de implementar.
- Es una extensión natural de los modelos de imágenes.
- Modela la información temporal.



Desventajas:

- No puede capturar movimientos finos de bajo nivel y relaciones temporales largas.
- Es computacionalmente costoso porque requiere desplegar la red a través de múltiples fotogramas para la retropropagación durante el entrenamiento.

La evolución de la arquitectura de video

Two-Stream

Este modelo maneja la información espacial y temporal utilizando dos corrientes individuales e iguales.




Figure 1: Two-stream architecture for video classification.



La evolución de la arquitectura de video

Two-Stream

- Selecciona aleatoriamente un solo fotograma del video completo y lo pasa a través de los stream espacial.
- Calcula un conjunto de flujo óptico a partir de 10 fotogramas.
- Realiza un promedio de agrupación a partir de la predicción de ambas streams.

Two-Stream

Ventajas:


- Fácil de implementar.
- Aprovecha la información temporal detallada a través del flujo óptico.




Desventajas:

- Necesita calcular el flujo óptico de cada video.
- Solo considera la apariencia de un fotograma.
- No puede capturar relaciones temporales largas.


C3D




(a) 2D convolution on
Grayscale Image ($1 \times n \times n$);
1 Video Frame



(b) 2D Convolution on RGB
Image ($3 \times n \times n$);
1 Video Frame



(c) 2D Convolution on L-frame
RGB Video Segment ($b \times L \times n \times n$)



(d) 3D Convolution on L-frame
RGB Video segment ($b \times L \times n \times n$)



C3D

Las redes convolucionales en 3D (3D ConvNets) parecen ser un enfoque natural para el modelado de video, ya que son similares a las redes convolucionales estándar, pero con filtros espacio-temporales.



C3D

Las redes convolucionales en 3D (3D ConvNets) parecen ser un enfoque natural para el modelado de video, ya que son similares a las redes convolucionales estándar, pero con filtros espacio-temporales.



C3D

Ventajas:

- Aprovechar la información temporal detallada.
- Crear representaciones jerárquicas de datos espacio-temporales.




Desventajas:

- No puede aprovechar el pre-entrenamiento de ImageNet.
- Tiene muchos más parámetros que Conv2D debido a la dimensión adicional.
- Es más difícil de entrenar.


I3D

Es una extensión de los modelos Conv2D para el procesamiento de imágenes. Para aprovechar el pre-entrenamiento de ImageNet y disminuir el número de parámetros, se propuso el modelo I3D, que infla esos modelos basados en CNN 2D como Inception y ResNet.

Inflated Inception-V1



Inception Module (Inc.)





I3D

- Una imagen puede convertirse en un video (aburrido) copiándola repetidamente en una secuencia de video.
- Por lo tanto, los modelos 3D pueden ser pre-entrenados implícitamente en ImageNet, satisfaciendo el punto fijo del video aburrido.
- Esto puede lograrse, gracias a la linealidad, repitiendo los pesos de los filtros 2D N veces a lo largo de la dimensión temporal y escalándolos dividiendo por N .

Ventajas:

- Aprovechar la información temporal detallada.
- Crear representaciones jerárquicas de datos espacio-temporales.
- Puede utilizar el pre-entrenamiento de ImageNet.
- Reducir el número de parámetros.
- Reducir la complejidad del entrenamiento.




Desventajas:


- Tiene una gran cantidad de parámetros.
- Es computacionalmente costoso.
- La inferencia no es más rápida que los modelos anteriores

Overview


a) LSTM




b) 3D-ConvNet




c) Two-Stream



d) 3D-Fused Two-Stream



e) Two-Stream 3D-ConvNet





Results

Method	#Params	Training		Testing	
		# Input Frames	Temporal Footprint	# Input Frames	Temporal Footprint
ConvNet+LSTM	9M	25 rgb	5s	50 rgb	10s
3D-ConvNet	79M	16 rgb	0.64s	240 rgb	9.6s
Two-Stream	12M	1 rgb, 10 flow	0.4s	25 rgb, 250 flow	10s
3D-Fused	39M	5 rgb, 50 flow	2s	25 rgb, 250 flow	10s
Two-Stream I3D	25M	64 rgb, 64 flow	2.56s	250 rgb, 250 flow	10s

Architecture	UCF-101			HMDB-51			Kinetics		
	RGB	Flow	RGB + Flow	RGB	Flow	RGB + Flow	RGB	Flow	RGB + Flow
(a) LSTM	81.0	–	–	36.0	–	–	63.3	–	–
(b) 3D-ConvNet	51.6	–	–	24.3	–	–	56.1	–	–
(c) Two-Stream	83.6	85.6	91.2	43.2	56.3	58.3	62.2	52.4	65.6
(d) 3D-Fused	83.2	85.8	89.3	49.2	55.5	56.8	–	–	67.2
(e) Two-Stream I3D	84.5	90.6	93.4	49.8	61.9	66.4	71.1	63.4	74.2



References

- Joao Carreira, Andrew Zisserman; Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset; 2018.
- Du Tran, Lubomir Bourdev, Rob Fergus, Lorenzo Torresani, Manohar Paluri; Learning Spatiotemporal Features with 3D Convolutional Networks; 2015
- Deep Learning in Computer Vision; Coursera



Redes Convolucionales para reconocimiento en video

Modelos pre-entrenados

Profesor:

Bianca Del Solar Medrano

bsdelsolar@uc.cl





ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

EDUCACIÓN
PROFESIONAL



www.educacionprofesional.ing.uc.cl