



Analítica de Videos

Reconocimiento de acciones

Profesor:

Bianca Del Solar Medrano

bsdelsolar@uc.cl



Contenido

- 1 Introducción
- 2 ¿Cuál es la ruta actual?
- 3 TSN - TSM
- 4 Principales conjuntos de datos para reconocimiento de acción y actividad
 - Kinetics
 - Something-Somethings





Introducción

El objetivo es comprender lo que sucede en un video. La acción que se lleva a cabo, quién la realizó, dónde se lleva a cabo y en qué parte del video sucede.



¿Cuál es la ruta actual?

1

Aumentar el rendimiento de los modelos

- Mejorar la modelización temporal
- Información multimodal
- Causalidad

2

Reduce el tamaño de los modelos



Enfoques Anteriores

¿Cómo modelan los enfoques anteriores estructuras temporales de largo alcance?

Aumentar el tamaño del modelo

Es necesario realizar cálculos adicionales.

Se necesita más memoria y no necesariamente se aumenta el rendimiento

Necesita más memoria



Enfoques anteriores

Muestreo de fotogramas a una tasa fija



Enfoques anteriores



Epoch 1



Enfoques anteriores




Epoch 1




TSN- Temporal Segment Network

Este es el nuevo modelo que propone un nuevo paradigma para la modelización de estructuras temporales, llamado muestreo basado en segmentos.



TSN- Temporal Segment Network

¿Qué propone este modelo? Una nueva forma de muestreo de vídeo: un muestreo basado en segmentos.




TSN- Temporal Segment Network

¿Qué propone este modelo? Una nueva forma de muestreo de vídeo: un muestreo basado en segmentos.



Epoch 1




TSN- Temporal Segment Network

¿Qué propone este modelo? Una nueva forma de muestreo de vídeo: un muestreo basado en segmentos.




Epoch 2




TSN- Temporal Segment Network

Este es el nuevo modelo que propone un nuevo paradigma para la modelización de estructuras temporales, llamado muestreo basado en segmentos.




TSN- Temporal Segment Network




TSN- Temporal Segment Network

Este es el nuevo modelo que propone un nuevo paradigma para la modelización de estructuras temporales, llamado muestreo basado en segmentos.



TSN- Temporal Segment Network




TSM- Temporal Shift Module



TSM- Temporal Shift Module

Propone un Módulo de Cambio Temporal (TSM) genérico y eficaz que combina tanto alta eficiencia como alto rendimiento. Específicamente, puede lograr el rendimiento de una CNN en 3D pero mantener la complejidad de una CNN en 2D.



(a) The original tensor without shift.

(b) Offline temporal shift (bi-direction).

(c) Online temporal shift (uni-direction).



TSM- Temporal Shift Module

Supongamos que tenemos un vector unidimensional, por lo tanto, la convolución de este vector podría aproximarse mediante dos pasos, que son el desplazamiento y la multiplicación.


$$X_i^{-1} = X_{i-1}, \quad X_i^0 = X_i, \quad X_i^{+1} = x_{i+1}$$

$$Y = w_1 X^{-1} + w_2 X^0 + w_3 X^{+1}$$

TSM- Temporal Shift Module

Modelos offline con desplazamiento bidireccional


- Muestrear T fotogramas del vídeo.
- Se inserta un módulo de cambio temporal para cada bloque residual. Se añade información futura y pasada al fotograma actual.
- Para cada TSM insertado, el campo receptivo temporal se ampliará en 2.
- TSM puede convertir fácilmente cualquier modelo CNN en 2D en un modelo pseudo-3D.




TSM- Temporal Shift Module

Modelos offline con desplazamiento unidireccional

- Solo se añade información sobre el pasado al fotograma actual.
- TSM reemplaza 1/8 del mapa de características del fotograma actual con información antigua.
- Baja latencia para estimación en tiempo real.



TSM- Temporal Shift Module



Comparación de Modelos

Estos son los resultados del modelo TSM en comparación con la red TSN.

Table 1. Our method consistently outperforms 2D counterparts on multiple datasets at zero extra computation (protocol: ResNet-50 8f input, 10 clips for Kinetics, 2 for others, full-resolution).

	Dataset	Model	Acc1	Acc5	Δ Acc1
Less Temporal	Kinetics	TSN	70.6	89.2	+3.5
		Ours	74.1	91.2	
	UCF101	TSN	91.7	99.2	+4.2
		Ours	95.9	99.7	
	HMDB51	TSN	64.7	89.9	+8.8
		Ours	73.5	94.3	
More Temporal	Something V1	TSN	20.5	47.5	+28.0
		Ours	47.3	76.2	
	Something V2	TSN	30.4	61.0	+31.3
		Ours	61.7	87.4	
	Jester	TSN	83.9	99.6	+11.7
		Ours	97.0	99.9	

Comparación de Modelos

Estos son los resultados del modelo TSM en comparación con la red 3D.

Table 2. Comparing TSM against other methods on Something-Something dataset (center crop, 1 clip/video unless otherwise specified).

Model	Backbone	#Frame	FLOPs/Video	#Param.	Val Top-1	Val Top-5	Test Top-1
TSN [58]	BNInception	8	16G	10.7M	19.5	-	-
TSN (our impl.)	ResNet-50	8	33G	24.3M	19.7	46.6	-
TRN-Multiscale [58]	BNInception	8	16G	18.3M	34.4	-	33.6
TRN-Multiscale (our impl.)	ResNet-50	8	33G	31.8M	38.9	68.1	-
Two-stream TRN _{RGB+Flow} [58]	BNInception	8+8	-	36.6M	42.0	-	40.7
ECO [61]	BNIncep+3D Res18	8	32G	47.5M	39.6	-	-
ECO [61]	BNIncep+3D Res18	16	64G	47.5M	41.4	-	-
ECO _{En} Lite [61]	BNIncep+3D Res18	92	267G	150M	46.4	-	42.3
ECO _{En} Lite _{RGB+Flow} [61]	BNIncep+3D Res18	92+92	-	300M	49.5	-	43.9
I3D from [50]	3D ResNet-50	32×2clip	153G ¹ ×2	28.0M	41.6	72.2	-
Non-local I3D from [50]	3D ResNet-50	32×2clip	168G ¹ ×2	35.3M	44.4	76.0	-
Non-local I3D + GCN [50]	3D ResNet-50+GCN	32×2clip	303G ² ×2	62.2M ²	46.1	76.8	45.0
TSM	ResNet-50	8	33G	24.3M	45.6	74.2	-
TSM	ResNet-50	16	65G	24.3M	47.2	77.1	46.0
TSM _{En}	ResNet-50	24	98G	48.6M	49.7	78.5	-
TSM _{RGB+Flow}	ResNet-50	16+16	-	48.6M	52.6	81.9	50.7

Principales conjuntos de datos para reconocimiento de acciones

Kinetics

Cepillando los dientes



Something-Something

Girando una pulsera





Principales conjuntos de datos para reconocimiento de acciones

Kinetics

- Algunas investigaciones han demostrado que Kinetics no requiere un análisis temporal laborioso para entenderlo.
- Sus etiquetas son una referencia general a los vídeos.
- Contiene vídeos cortos y reales.
- Vídeos reales == vídeos en la naturaleza.
- Solo una acción por vídeo.
- Cada acción se centra en una persona.



Principales conjuntos de datos para reconocimiento de acciones

Something-Something

- Requiere modelado temporal detallado.
- Sus etiquetas están muy correlacionadas con lo que sucede en cada vídeo.
- Contiene vídeos cortos y reales.
- Vídeos reales == vídeos en entornos naturales.
- Solo una acción por vídeo.
- Cada acción se centra en una persona.



Referencias

- Ji Lin, Chuang Gan, Song Han; TSM: Temporal Shift Module for Efficient Video Understanding; 2019.
- Limin Wang, Yuanjun Xiong, Zhe Wang, Yu Qiao, Dahua Lin, Xiaoou Tang, Luc Van Gool; Temporal Segment Networks for Action Recognition in Videos; 2017



ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA


EDUCACIÓN
PROFESIONAL



www.educacionprofesional.ing.uc.cl

Material Extra: Mask Autoencoder (MAE)

¿Cómo aprende un niño a completar un rompecabezas al que le faltan piezas?



¿QUÉ ES UN MASKED AUTOENCODER (MAE)?

Un MAE es un modelo de aprendizaje auto-supervisado que aprende a comprender imágenes reconstruyendo las partes que han sido ocultas.



IDEA PRINCIPAL

El modelo ve solo una pequeña parte de la imagen y aprende a predecir (el reconstruir) el resto.



CARACTERÍSTICAS

- No necesita etiquetas
- Aprende representaciones muy útiles
- Basado en Transformers (ViT)
- Oculta típicamente el 75% de la imagen

¿CÓMO FUNCIONA?

1 Imagen original



Se toma una imagen completa.

2 Dividir en patches



La imagen se divide en pequeños cuadrados (patches).

3 Ocultar 75%



Se eliminan aleatoriamente ~75% de los patches.

4 Encoder



Solo los patches visibles entran al encoder (ViT).

5 Decoder



El decoder intenta reconstruir todos los patches.

6 Reconstrucción




Se obtiene la imagen reconstruida.



El modelo se entrena minimizando el error entre la imagen original y la reconstruida.

ARQUITECTURA GENERAL



EJEMPLO VISUAL

Imagen original



Entrada al modelo
(25% visible)



Reconstrucción
(del modelo)



El modelo solo vio el 25% de la imagen y fue capaz de reconstruir el 100%.

¿CÓMO MAE SE RELACIONA CON LOS MODELOS TEXT-TO-IMAGE?

Del aprendizaje visual auto-supervisado a la generación de imágenes desde texto

1. ¿QUÉ APRENDE MAE?



MAE ve solo una pequeña parte de la imagen y aprende a reconstruir las partes faltantes.



Al hacerlo, aprende:

- Formas
- Texturas
- Estructuras
- Relaciones espaciales



Resultado: representaciones visuales muy potentes sin necesidad de etiquetas (auto-supervisado).




Idea clave: MAE entrena encoders visuales (ej. ViT) que entienden muy bien las imágenes.

¿CÓMO MAE SE RELACIONA CON LOS MODELOS TEXT-TO-IMAGE?

Del aprendizaje visual auto-supervisado a la generación de imágenes desde texto

2. BASE DE LOS MODELOS TEXT-TO-IMAGE

Los modelos text-to-image modernos (ej. Stable Diffusion) siguen este esquema:




Estos modelos necesitan comprender imágenes a un nivel profundo para poder generarlas desde texto.

¿CÓMO MAE SE RELACIONA CON LOS MODELOS TEXT-TO-IMAGE?


Del aprendizaje visual auto-supervisado a la generación de imágenes desde texto

3. ¿DÓNDE ENTRA MAE EN ESTA HISTORIA? ★

1 MAE se usa para pre-entrenar un encoder visual (ViT).



2 Este encoder aprende a entender muy bien las imágenes sin etiquetas.



Ese conocimiento visual se **transfiere** a los modelos generativos (text-to-image).



Mejor comprensión de objetos, formas y contextos



Representaciones más robustas y generales



Mejores resultados en generación de imágenes

3



MAE no genera imágenes desde texto, pero es una pieza fundamental que hace posible que el modelo entienda y genere imágenes de alta calidad.

EN RESUMEN



MAE aprende a "completar" imágenes ocultas → aprende representaciones visuales.



Estas representaciones se usan para entrenar modelos generativos.



El modelo generativo usa el texto para guiar la creación de nuevas imágenes.



Sin MAE (u otros pre-entrenamientos similares), los modelos tendrían mucho más difícil entender el mundo visual.

¿CÓMO MAE SE RELACIONA CON LOS MODELOS TEXT-TO-IMAGE?

Del aprendizaje visual auto-supervisado a la generación de imágenes desde texto

EN RESUMEN



- ✓ **MAE** aprende a “completar” imágenes ocultas → aprende representaciones visuales.



- ✓ Estas **representaciones** se usan para entrenar **modelos generativos**.



- ✓ El modelo generativo usa el **texto** para guiar la creación de nuevas imágenes.




- ✓ **Sin MAE** (u otros pre-entrenamientos similares), los modelos tendrían mucho más difícil entender el mundo visual.

RELACIÓN MAE → TEXT-TO-IMAGE EN UNA FRASE


MAE enseña al modelo a comprender imágenes; los modelos text-to-image usan ese conocimiento para crear nuevas imágenes cuando les damos una descripción en lenguaje natural.




Aprende representaciones visuales potentes sin necesidad de etiquetas.



El modelo entiende mejor objetos, formas, texturas, contextos y relaciones espaciales.



Usa estas representaciones junto con el texto para guiar la generación de imágenes paso a paso.



A partir de un prompt en lenguaje natural, genera imágenes nuevas de alta calidad.



Ejemplo de imagen generada desde texto



Es un ciclo de mejora continua: mejores representaciones → mejores generaciones → más aplicaciones.