



Pontificia Universidad Católica de Chile
Departamento de Ciencias de la Computación

Diplomado en Inteligencia Artificial

Curso Audio y Video

Deep Learning para Tracking de Objetos en video

Carlos Aspillaga



IA Lab



Contenidos de la clase de hoy

1

Introducción

2

Offline Tracking y Online Tracking

3

Sort y DeepSort

4

Modelos Integrados

5

Trabajo Prácticp

Contenidos de la clase de hoy

1

Introducción

2

Offline Tracking y Online Tracking

3

Sort y DeepSort

4

Modelos Integrados

5


Trabajo Práctico

Fuentes consultadas:

- Tomás Vergara Brown
- Alvaro Soto
- Papers originales de cada modelo

Introducción

Objetivo final



Nuestro objetivo es trackear objetos en un video.

Introducción

¿Qué significa trackear un objeto?

- ▶ Reconocer objetos
- ▶ Mantener identidades de los objetos

Introducción

percepción visual automática

Razonamiento Espacial

Detección de Objetos: Tarea de localización espacial sin componente temporal.

Comprende snapshots aisladas, objetivos estáticos e inferencia directa. No hay consciencia de la componente temporal





Razonamiento Espacio-Temporal

Object Tracking: Tarea de asociación continua de detecciones en el tiempo.

Requiere preservación de identidad, comprensión de dinámicas de movimiento, y recuperación de la asociación ante oclusión.

Introducción

¿Por qué querríamos trackear objetos?




Introducción

¿Por qué querríamos trackear objetos?



Introducción

¿Por qué querríamos trackear objetos?



Introducción

¿Por qué querríamos trackear objetos?



Introducción

¿Por qué querríamos trackear objetos?



Introducción

¿Por qué querríamos trackear objetos?



Introducción

¿Por qué querríamos trackear objetos?




Introducción

¿Por qué querríamos trackear objetos?

Trackear objetos puede ser importante, útil e interesante.

Introducción

¿Por qué querríamos trackear objetos?



Trackear objetos puede ser importante, útil e interesante.



Introducción

¿Una única tarea?

Formulamos el trackeo de objetos como un solo gran problema, pero eso no es la realidad.

Introducción

¿Una única tarea?

Formulamos el trackeo de objetos como un gran problema, pero eso no es la realidad.

Variaciones:

- ▶ Un objeto v/s múltiples objetos
- ▶ Una cámara v/s múltiples cámaras
- ▶ Cámara dinámica v/s cámara estática

Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Desafíos:

- ▶ Cambios en la iluminación
- ▶ Variaciones en la pose
- ▶ Oclusiones
- ▶ Variaciones en escala
- ▶ Deformaciones
- ▶ Variaciones intra-clase
- ▶ Restricciones de tiempo real
- ▶ Muchos objetos
- ▶ ...

Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Cambios en la iluminación



Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Variaciones de pose



Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Oclusiones



(a) Occluded Face 1




(c) Person

Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Variaciones de escala



Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Deformaciones



Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Variaciones intra-clase



Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Restricciones de tiempo real



Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Muchos objetos



Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Y lo peor... ¡es que todo puede ocurrir al mismo tiempo!

Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Parece imposible de resolver. Sin embargo...

Introducción

Los Desafíos del Tracking

Trackear objetos es difícil.

Los seres humanos no tenemos ningún problema trackeando objetos, y efectivamente ya hay métodos que lo resuelven relativamente bien.

Introducción

Los Desafíos del Tracking

Hay una gran distinción entre los algoritmos existentes:

- ▶ **Online Tracking:** Tracking en tiempo real. No se pueden utilizar frames del *futuro* para hacer el tracking.
- ▶ **Offline Tracking:** Tenemos acceso a todo un video, y queremos hacer tracking de este.

Introducción

Online v/s offline

Vamos a empezar con **offline tracking**, pero después nos vamos a enfocar más con **online tracking**, pues tiene más casos de uso.

Contenidos de la clase de hoy

1

Introducción

2

Offline Tracking y Online Tracking

3

Sort y DeepSort

4

Modelos Integrados

5

Trabajo Práctico

Offline Tracking

Primero, notemos que el tracking de objetos es un subproblema del reconocimiento de objetos.

Entonces, podemos usar los mismos modelos de reconocimiento de objetos.

Offline Tracking

Tenemos el reconocimiento de objetos listo.



Offline Tracking

Tenemos el reconocimiento de objetos listo.



Qué problemas faltan resolver?

- ▶ Múltiples objetos
- ▶ Mantener las identidades

Offline Tracking


Queremos encontrar los *caminos* de los objetos en un video.

Offline Tracking


Podemos partir el problema en 2:

- ▶ Encontrar los objetos en cada frame
- ▶ Hacer asociaciones entre objetos en distintos frames para formar *caminos*.

Offline Tracking



Offline Tracking



Necesitamos una
buena manera
de asociar
puntos.

Offline Tracking

Podríamos *aprender* cómo asociar puntos correctamente.

Offline Tracking

Podríamos *aprender* cómo asociar puntos correctamente.

¿cómo?

Offline Tracking

Podríamos *aprender* cómo asociar puntos correctamente.

¿cómo?

Aprendiendo una métrica de distancia.


(Paréntesis: Aprender una métrica de distancia)

Son estos pares de imágenes de la misma persona?




(Paréntesis: Aprender una métrica de distancia)

Red siamesa



(Paréntesis: Aprender una métrica de distancia)

Red siamesa



- ▶ Queremos que las imágenes de la **misma** clase estén **cerca**
- ▶ Queremos que las imágenes de clases **diferentes** estén **lejos**

(Paréntesis: Aprender una métrica de distancia)

Pairwise ranking loss

Si las imágenes de la misma clase:

$$L(f(l_1), f(l_2)) := |f(l_1) - f(l_2)|$$

Si las imágenes son de clases diferentes:

$$L(f(l_1), f(l_2)) := \max\{0, m - |f(l_1) - f(l_2)|\}$$

(Paréntesis: Aprender una métrica de distancia)

Pero la red siamesa es bastante inestable de entrenar (por qué?).


(Paréntesis: Aprender una métrica de distancia)

Pero la red siamesa es bastante inestable de entrenar (por qué?).
Hay shortcuts!

- ▶ Si estás usando imágenes de la misma clase, tira todo al mismo punto.
- ▶ Si estás usando imágenes de distintas clases, simplemente aleja todo del centro.

(Paréntesis: Aprender una métrica de distancia)

Triplet network




(Paréntesis: Aprender una métrica de distancia)

Triplet ranking loss

$$L(f(l_1), f(l_2), f(l_3)) := \max\{0, m - |f(l_1) - f(l_3)| + |f(l_1) - f(l_2)|\}$$


(Paréntesis: Aprender una métrica de distancia)

Espacio de features en una Triplet network



(Paréntesis: Aprender una métrica de distancia)


Espacio de features en una Triplet network



Esto es
generalizable a
cualquier tipo de
objetos



(Paréntesis: Aprender una métrica de distancia)




Esto es
generalizable a
cualquier tipo de
objetos



Offline Tracking

Volvamos al *offline tracking*.


Offline Tracking



Podemos usar una red siamesa/triplet network para tener features de los objetos y conectar los más similares.


Offline Tracking

Una variación interesante es cuando tenemos *múltiples cámaras*.



Offline Tracking

Una variación interesante es cuando tenemos *múltiples cámaras*.



Podemos seguir
usando los features
de la red
siamesa/triplet
network para
conectar puntos!



Online Tracking

Online Tracking

A diferencia de *offline tracking*, ahora no podemos acceder a frames futuros. Eso hace más difícil la detección, pues tenemos que *predecir* las nuevas localizaciones.

Esto se puede resolver con modelos de movimiento.

Online Tracking

A gran escala, nuestra solución tiene que tener ésto:

1. Detección de objetos

- 1.1 Localización en el espacio

- 1.2 Representación del objeto

2. Búsqueda de objetos


- 2.1 Asociación de datos (modelo de movimiento)

- 2.2 Medida de similaridad

Online Tracking



Online Tracking



1.1 Localización en el espacio: Usando un modelo preentrenado

Online Tracking



1.2 Representación del objeto: Podríamos representarlo como el bounding box obtenido.

Online Tracking



2.1 Asociación de datos (modelo de movimiento): Podemos estimar la nueva localización del objeto en base a sus últimas localizaciones.

Online Tracking



2.2 Medida de similaridad: Podríamos medir qué tanto se asemejan la bounding box predicha con la de los objetos detectados en el nuevo frame.

Contenidos de la clase de hoy

1

Introducción

2

Offline Tracking y Online Tracking

3

Sort y DeepSort

4

Modelos Integrados

5

Trabajo Práctico

Online Tracking

Algoritmo SORT


SORT: Simple Online Realtime Tracking.

Fue un paper muy influyente en el área, que con un algoritmo sencillo tenían buenos resultados.

Online Tracking

Algoritmo SORT

Usando **FasterR-CNN** obtienen detecciones de objetos en un frame.



Online Tracking

Algoritmo SORT

Inician una identificación del objeto, mediante una estimación del bounding box, y su velocidad:

$$x = [u, v, s, r, \dot{u}, \dot{v}, \dot{s}]$$

Donde:

- ▶ u, v representa la ubicación del centro del bounding box.
- ▶ s representa el área del bounding box.
- ▶ r representa la razón ancho/alto del bounding box.
- ▶ $\dot{u}, \dot{v}, \dot{s}$ representan las velocidades de cada medición.

Todas las velocidades se inicializan en 0, y se calculan después a partir del frame anterior.

Online Tracking

Algoritmo SORT

Con esto, pueden aproximar bounding box correspondiente a cada objeto en su siguiente frame.

Online Tracking

Algoritmo SORT

Pueden asociar cada nueva detección con los objetos anteriores haciendo:

- ▶ Calculando la métrica de costo de *Intersection over Union* (IOU), entre la bounding box predicha, y todas las nuevas detecciones.
- ▶ Usando el Algoritmo Húngaro para hacer asignaciones óptimas que minimicen este costo.

Online Tracking

Algoritmo SORT

Algoritmo Húngaro Tenemos que asignar n objetos a otros n objetos, intentando de minimizar un *costo*.

	Object 1	Object 2	Object 3
Object 1	c_{11}	c_{12}	c_{13}
Object 2	c_{21}	c_{22}	c_{23}
Object 3	c_{31}	c_{32}	c_{33}

El algoritmo toma la matriz, y retorna las asignaciones óptimas de tal forma de minimizar el costo.

Online Tracking

Algoritmo SORT

Un par de detalles:

- ▶ Establecen un mínimo de intersección necesaria entre la bounding box predicha y la nueva bounding box.
- ▶ Si el objeto no tiene match por más de n frames, se considera que desapareció.

Online Tracking

Algoritmo SORT

Una gran ventaja es que SORT es extremadamente directo de implementar, y muy rápido en la práctica, por lo que tuvo mucho impacto.

Sin embargo, SORT no es muy bueno para manejar largas oclusiones, y se propusieron nuevos algoritmos para mejorarlo.

Online Tracking

Algoritmo DeepSORT

DeepSORT: Una ligera modificación de SORT que agrega features *aprendidos* para mantener mejores identificaciones de objetos.

Online Tracking

Algoritmo DeepSORT

Un problema con SORT es que el modelo de movimiento es demasiado simple: calculan una velocidad y así aproximan la nueva localización.

Eso no considera las *incertezas* existentes en las mediciones. Por ejemplo, objetos de alta velocidad, van a tener mayor incerteza en su nueva localización.

Online Tracking


Algoritmo DeepSORT

En lugar de usar IOU, usan la distancia de **Mahalanobis**, que mide cuántas desviaciones estándar está la localización predicha en comparación a cada bounding box detectado.

Online Tracking

Algoritmo DeepSORT


En lugar de usar IOU, usan la distancia de **Mahalanobis**, que mide cuántas desviaciones estándar está la localización predicha en comparación a cada bounding box detectado.



Online Tracking

Algoritmo DeepSORT

En lugar de usar IOU, usan la distancia de **Mahalanobis**, que mide cuántas desviaciones estándar está la localización predicha en comparación a cada bounding box detectado.




Se puede pensar como si estuviera estimando regiones de probabilidad de la siguiente localización, en lugar de un lugar en particular.

Online Tracking

Algoritmo DeepSORT

Además, consideran usar un vector de embedding *aprendido* para identificar un objeto.



Online Tracking

Algoritmo DeepSORT

Entonces, al calcular la similaridad entre un objeto existente y una nueva detección, mezclan:

- ▶ La distancia Mahalanobis
- ▶ La similaridad entre los embeddings.


Online Tracking

Algoritmo DeepSORT

En la practica DeepSORT es más robusto que SORT para mantener identidades, y sigue siendo muy eficiente y relativamente sencillo de implementar.

Online Tracking

Algoritmo DeepSORT



Online Tracking

Algoritmo DeepSORT

Pero este approach sigue teniendo problemas. Supone que el *objeto se movió poco*.

Es razonable suponer eso?

Tal vez... pero qué si la cámara se mueve mucho? O si hay periodos grandes de oclusión del objeto?

Online Tracking

Algoritmo DeepSORT

Hay maneras de mejorar esas situaciones, mejorando el modelo de movimiento:

- ▶ Un modelo que compense el movimiento de la cámara.
- ▶ Un modelo que considere zonas ciegas.

Otra técnica es usar *algoritmos de re-identificación de objetos*.

Contenidos de la clase de hoy

1

Introducción

2

Offline Tracking y Online Tracking

3

Sort y DeepSort

4

Modelos Integrados

5

Trabajo Práctico


Métodos integrados

SUTrack (2024)

El framework de SUTrack

En SuTrack se mueven hacia la multimodalidad (RGB, Profundidad, Termal, Eventos, Language) con una tokenización universal.

- Consolida 5 tareas en un solo Transformer.
- Usan un soft token type embedding para conseguir tracking agnóstico a la modalidad.
- Paradigma integrado supera a modelos especializados (sinergia multimodal).



Métodos integrados

Ideas novedosas para dominios específicos

UAV Aéreos

SocialTrack usa la dinámicas de movimiento de grupos

Vehículos Autónomos 3D

MCTrack proyecta la velocidad de los pixeles a la velocidad real 3D


Biología

Cell-TRACTR segmenta células de forma end-to-end

Métodos más avanzados

YOLO11 a YOLO26

- **Remueven el NMS**
(Non-Maxima Supression)
- **Mecanismo STAL:**
Small-Target-Aware-Labeling
mantiene persistencia del
tracking cuando los objetos
se pierden en la distancia



Métodos más avanzados


SAM3: Segmentación con apoyo de prompting

Agregan una cabecera de “Presencia”

Detector y Tracker con arquitecturas separadas, que permite hacer tracking de conceptos complejos mediante lenguaje natural.

"Track all yellow buses" – SAM 3 asigna IDs a cada instancia que coincide con el prompt semántico.

Obtiene 22% de mejora en LVIS Zero-Shot AP vs. el mejor modelo anterior.



Métodos más avanzados

SAM3



Contenidos de la clase de hoy

1

Introducción

2

Offline Tracking y Online Tracking

3

Sort y DeepSort

4

Modelos Integrados

5

Trabajo Práctico



Pontificia Universidad Católica de Chile
Departamento de Ciencias de la Computación

Diplomado en Inteligencia Artificial

Curso Audio y Video

Deep Learning para Tracking de Objetos en video

Carlos Aspillaga



IA Lab

