




Pontificia Universidad Católica de Chile
Departamento de Ciencias de la Computación




IA Lab

Diplomado en Inteligencia Artificial

Curso 4: Aplicaciones de Inteligencia Artificial II

Clase 44: Aplicaciones de Audio y Video

Carlos Aspillaga



¿Qué hemos visto en este diplomado?

Deep Learning

Aprendizaje de Máquina y Deep Learning

Redes neuronales

CNNs

RNN

Resnet, Inception, etc

Transformer

Pytorch

Grafos de cómputo

Inicialización de Pesos

Funciones de Activación

Funciones de Pérdida

Regularización

Tareas auxiliares

Visualización de pesos

Mecanismos de optimización

Paradigma Sequence-to-Sequence

Fine-tuning

Data Augmentation

Mecanismos de Atención

Hardware para Deep Learning

Texto

NLP clásico

Modelos de Lenguaje

Embeddings de palabras

EIMo, BERT, GPT

Summarization

Modelos pregunta-respuesta

Imágenes

Redes Fully-Convolutional

Reconocimiento de Objetos

Detección de poses y rostros

Reconocimiento visual de texto

Recomendación usando imágenes y texto

VQA, Captions

¿Qué hemos visto en este diplomado?

Deep Learning

Aprendizaje de Máquina y Deep Learning

Redes neuronales

CNNs

RNN

Resnet, Inception, etc

Transformer

Pytorch

Grafos de cómputo

Inicialización de Pesos

Funciones de Activación

Funciones de Pérdida

Regularización

Tareas auxiliares

Visualización de pesos

Mecanismos de optimización

Paradigma Sequence-to-Sequence

Fine-tuning

Data Augmentation

Mecanismos de Atención

Hardware para Deep Learning

Texto

NLP clásico

Modelos de Lenguaje

Embeddings de palabras

EIMo, BERT, GPT

Summarization

Modelos pregunta-respuesta

Imágenes

Redes Fully-Convolutional

Reconocimiento de Objetos

Detección de poses y rostros

Reconocimiento visual de texto

Recomendación usando imágenes y texto

VQA, Captions



¿Qué hemos visto en este diplomado?

IA Avanzado

Redes Relacionales
Olvido Catastrófico
Aprendizaje Incremental
Redes Neuronales de Grafos
Meta-Learning
GANs
Self-Supervised Learning
Aprendizaje Reforzado
Imitation Learning
Modelos con memoria externa
Computadores neuronales
Razonamiento en Deep Learning

Aplicaciones

Clasificación de imágenes
Clasificación de texto
Generación de texto
Generación de resúmenes
Pregunta-Respuesta
Visual Question Answering
Recomendación
etc...

Audio y Video

Introducción a audio y video
Datasets y herramientas públicas para audio y video
CNNs para audio y video
Modelos pre-entrenados para audio y video
Reconocimiento de acciones en video
Tracking en video
Reconocimiento de voz
Transcripción de audio
Aplicaciones de audio

¿Qué hemos visto en este diplomado?

IA Avanzado

- Redes Relacionales
- Olvido Catastrófico
- Aprendizaje Incremental
- Redes Neuronales de Grafos
- Meta-Learning
- GANs
- Self-Supervised Learning
- Aprendizaje Reforzado
- Imitation Learning
- Modelos con memoria externa
- Computadores neuronales
- Razonamiento en Deep Learning

Aplicaciones

- Clasificación de imágenes
- Clasificación de texto
- Generación de texto
- Generación de resúmenes
- Pregunta-Respuesta
- Visual Question Answering
- Recomendación
- etc...

Audio y Video

- Introducción a audio y video
- Datasets y herramientas públicas para audio y video
- CNNs para audio y video
- Modelos pre-entrenados para audio y video
- Reconocimiento de acciones en video
- Tracking en video
- Reconocimiento de voz
- Transcripción de audio
- Aplicaciones de audio

USTEDES



¿Qué veremos en la clase de hoy?

Aplicaciones sorprendentes de Audio y Video usando las cosas que ya conocemos

- Speech Reconstruction from Silent Videos
- Face Reconstruction from Voice
- Source Separation in Video
- Audio Visual Speech Enhancement
- Audio-Video Synchronization
- Upscaling
- Deep Fakes

Let's have fun with Deep Learning...


- Deep Fakes
- Laboratorio práctico Deep Fakes



Un pequeño anticipo...

Speech Reconstruction from Silent Videos

¿Qué es?



Objetivo:

Reconstruir los features de **audio** a partir del video

Speech Reconstruction from Silent Videos

Ejemplos

Vocoder-Based Speech Synthesis from Silent Videos

<https://danmic.github.io/vid2voc/>

Paper: <https://arxiv.org/pdf/2004.02541.pdf>

Arquitectura: 3D Conv + GRU

Vid2Speech: Speech reconstruction from silent video

www.vision.huji.ac.il/vid2speech/

Paper: <https://arxiv.org/abs/1701.00495>

Arquitectura: Encoder-Decoder CNNs

Speech Reconstruction from Silent Videos

Demo: Vocoder-Based Speech Synthesis from Silent Videos

Input



<https://www.youtube.com/watch?v=dBhBCH-agc4>

Speech Reconstruction from Silent Videos


Demo: Vid2Speech: Speech Reconstruction from Silent Video



<https://www.youtube.com/watch?v=Xjbn7h7tpg0>

Face Reconstruction from Voice

¿Qué es?



Objetivo:

Reconstruir la **cara** a partir de la voz

Face Reconstruction from Voice

Ejemplo

Speech2Face: Learning the Face Behind a Voice


<https://speech2face.github.io/>

Paper: <https://arxiv.org/pdf/1905.09773.pdf>

Arquitectura: Encoder-Decoder CNNs

Face Reconstruction from Voice


Resultados



<https://speech2face.github.io/>

Audio Source Separation in Video

¿Qué es?



Objetivo:

Identificar las distintas fuentes de sonido
y obtener su **sonido aislado**

Audio Source Separation in Video

Ejemplos

Looking to Listen at the Cocktail Party: A Speaker-Independent Audio-Visual Model for Speech Separation

<https://looking-to-listen.github.io/>

Paper: <https://arxiv.org/abs/1804.03619>

Arquitectura: CNNs + Bidirectional LSTMs

Learning to Separate Object Sounds by Watching Unlabeled Video


http://vision.cs.utexas.edu/projects/separating_object_sounds

Paper: http://vision.cs.utexas.edu/projects/separating_object_sounds/sound-sep-eccv2018.pdf

Arquitectura: CNNs + NMF (Non-Negative Matrix Factorization)

Audio Source Separation in Video

Demo



<https://www.youtube.com/watch?v=rVQVAPiJWКУ>

Audio Source Separation in Video


Demo



<https://www.youtube.com/watch?v=skeTh2B9rj0>

Audio Speech Enhancement

¿Qué es?



Objetivo:

Aislar la voz en un video ruidoso

Audio Speech Enhancement

Ejemplos

CochleaNet: A Robust Language-independent Audio-Visual Model for Speech Enhancement

<https://cochleanet.github.io/>

Paper: <https://arxiv.org/pdf/1909.10407.pdf>

Arquitectura: CNNs + LSTMs + MLPs

Face Landmark-based Speaker-Independent Audio-Visual Speech Enhancement in Multi-Talker Environments

https://dr-pato.github.io/audio_visual_speech_enhancement/

Paper: <https://arxiv.org/pdf/1811.02480.pdf>

Arquitectura: Stacked BiLSTMs.

Audio Speech Enhancement

Demo



<https://vimeo.com/357546330>

Audio Speech Enhancement


Demo



<https://www.youtube.com/watch?v=YQ0q-OFphKM>

Audio-Video Synchronization

¿Qué es?



Objetivo:

Alinear audio y video cuando hay **desfase** entre ellos.

Audio-Video Synchronization

Ejemplo

Out of time: automated lip sync in the wild

www.robots.ox.ac.uk/~vgg/software/lipsync/

Paper: <https://www.robots.ox.ac.uk/~vgg/publications/2016/Chung16a/>

Arquitectura: CNNs.

Audio-Video Synchronization


Demo



<https://www.youtube.com/watch?v=AAVZDhGld0U>

Upscaling / Super-resolution

¿Qué es?




Objetivo:

Incrementar resolución de instancias de audio y video

Upscaling / Super-resolution

¿Qué es?



Upscaling / Super-resolution

Ejemplo

DLSS in NVidia video cards or DirectML for AMD cards.

www.nvidia.com/es-la/geforce/technologies/dlss/

Código: <https://github.com/microsoft/DirectML>

Arquitectura: Convolutional Autoencoder.

Audio Super Resolution with Neural Networks

<https://kuleshov.github.io/audio-super-res/>

Paper: <https://arxiv.org/abs/1708.00853>

Arquitectura: Convolutional Upsampling and Downsampling Blocks.

Upscaling / Super-resolution


Demo



<https://www.youtube.com/watch?v=IMi3JpNBQeM>

Deep Fakes

¿Qué es?



Objetivo:

Reemplazar partes de **audio y/o video** por una versión **modificada intencionalmente**

Deep Fakes

Aplicaciones

Aunque es altamente controversial, existen aplicaciones muy útiles:

- Reemplazo de actores que murieron o envejecieron (cine).



Deep Fakes

Aplicaciones

Aunque es altamente controversial, existen aplicaciones muy útiles:

- Reemplazo de actores que murieron o envejecieron (cine).
- **Recrear personajes históricos con fines educativos.**



Deep Fakes

Aplicaciones

Aunque es altamente controversial, existen aplicaciones muy útiles:

- Reemplazo de actores que murieron o envejecieron (cine).
- Recrear personajes históricos con fines educativos.
- **Visualización de cómo se vería la persona usando el producto.**



Deep Fakes

Aplicaciones

Aunque es altamente controversial, existen aplicaciones muy útiles:

- Reemplazo de actores que murieron o envejecieron (cine).
- Recrear personajes históricos con fines educativos.
- Visualización de cómo se vería la persona usando el producto.
- **Inmortalidad digital.**



Deep Fakes

Aplicaciones

Aunque es altamente controversial, existen aplicaciones muy útiles:

- Reemplazo de actores que murieron o envejecieron (cine).
- Recrear personajes históricos con fines educativos.
- Visualización de cómo se vería la persona usando el producto.
- Inmortalidad digital.
- **Traducción simultánea: Sintetizar video para que gesticule la frase traducida por un intérprete.**

Deep Fakes

Aplicaciones

Aunque es altamente controversial, existen aplicaciones muy útiles:

- Reemplazo de actores que murieron o envejecieron (cine).
- Recrear personajes históricos con fines educativos.
- Visualización de cómo se vería la persona usando el producto.
- Inmortalidad digital.
- Traducción simultánea: Sintetizar video para que gesticule la frase traducida por un intérprete.
- **Sintetizador de voz para personas que perdieron la voz.**

Deep Fakes

Demo



<https://www.youtube.com/watch?v=bC3uH4Xw4Xo>

Deep Fakes

El paper que usaremos

<https://papers.nips.cc/paper/2019/file/31c0b36aef265d9221af80872ceb62f9-Paper.pdf>

Dataset: VoxCeleb (Nagrani et. al)



Nota: En realidad también usan datasets de videos a cuerpo completo

Deep Fakes

Método


Tracking de puntos



Deep Fakes

Método


Estimación de la transformación afín entre cada frame (y para cada keypoint)



Deep Fakes

Método

Entrenar para regenerar el video






Deep Fakes

Método


información de
aspecto

información de
movimiento

Entrada




Salida



Deep Fakes

Método

Generación del Deep Fake: ¡Reemplazar frame inicial y listo!






Deep Fakes

Método

información de
aspecto

información de
movimiento

Entrada





Salida



Deep Fakes


Generación de audio

Jia et al.: Transfer Learning from Speaker Verification to Multispeaker Text-To-Speech Synthesis



Deep Fakes

Método



Deep Fakes: Laboratorio

